Multimodal Orchestration in STEM Accessibility: from Architectural-Performance Decoupling to Differential Cognitive Yield

Orchestration multimodale en accessibilité STEM : du découplage architecture-performance au rendement cognitif différentiel

Madjid Sadallah
Université Claude Bernard Lyon 1, CNRS, INSA Lyon, LIRIS, UMR5205
69622 Villeurbann, France
madjid.sadallah@liris.cnrs.fr

Benoît Encelle
Universite Claude Bernard Lyon 1, CNRS, INSA Lyon, LIRIS, UMR5205
69622 Villeurbanne, France
benoit.encelle@liris.cnrs.fr

Abstract

Multimodal STEM accessibility for blind and visually impaired users faces a persistent paradox: increasing architectural sophistication does not systematically reduce cognitive load. We argue that two structural causes underlie this gap. First, an *additive illusion* pervades design practice, equating the mere accumulation of sensory channels with purposeful orchestration, that is, the temporal and semantic coordination of information streams into a unified mental representation. Second, evaluation relies predominantly on task-completion metrics that are insensitive to the underlying cognitive costs. We introduce ARC (*Architectural Readiness for perceptual Convergence*), a diagnostic framework that operationalizes multimodal orchestration quality across four architectural dimensions: temporal synchrony, informational coherence, structural preservation, and modal relevance, plus one external performance variable. Applied to a corpus of 66 empirical studies (2015–2025) on non-visual STEM interfaces, our descriptive analysis identifies three qualitatively distinct regimes of architectural maturity. Despite large structural differences across regimes, performance metrics show no systematic variation, revealing a consistent decoupling between architectural sophistication and task success. We formalize this as the *Differential Cognitive Yield* (DCY) hypothesis: architecturally divergent systems yield equivalent observable performance while likely imposing fundamentally different cognitive costs—a construct requiring experimental validation with multi-metric protocols. ARC contributes a reproducible scoring protocol with codified inter-rater procedures, empirically derived classification thresholds, and hierarchical design guidelines.

Résumé

L'accessibilité des contenus STEM pour les personnes aveugles ou malvoyantes se heurte à un paradoxe persistant : l'accroissement de la sophistication architecturale des interfaces multimodales ne réduit pas systématiquement la charge cognitive. Deux causes structurelles expliquent ce paradoxe. D'une part, une *illusion additive* traverse implicitement la conception : accumuler des canaux sensoriels est confondu avec leur orchestration, c'est-à-dire la coordination temporelle et sémantique des flux d'information en vue d'une représentation mentale unifiée. D'autre part, l'évaluation repose sur des métriques de complétion de tâche insensibles aux coûts cognitifs sous-jacents. Nous introduisons ARC (*Architectural Readiness for perceptual Convergence*), un cadre diagnostique opérationnalisant la qualité de l'orchestration multimodale selon quatre dimensions architecturales : cohérence temporelle, cohérence informationnelle, préservation structurelle et pertinence modale, ainsi qu'une variable de performance externe. Appliqué à un corpus de 66 études empiriques (2015–2025) portant sur des interfaces STEM non visuelles, notre analyse descriptive identifie trois régimes de maturité architecturale qualitativement distincts. Malgré des écarts structurels majeurs entre régimes, les métriques de performance ne varient pas significativement, révélant un découplage systématique entre ces dernières et sophistication architecturale. Nous formalisons ce résultat sous l'hypothèse du *Rendement Cognitif Différentiel* : des systèmes architecturalement distincts produisent des performances équivalentes tout en imposant des coûts cognitifs fondamentalement différents — un construit théoriquement fondé, appelant une validation expérimentale par des protocoles multi-métriques.

CCS Concepts

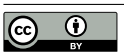
• **Human-centered computing** → **Empirical studies in accessibility**; **HCI design and evaluation methods**; **Accessibility systems and tools**; • **Computing methodologies** → *Cognitive science.*

Keywords

Non-visual STEM interfaces, Blind and visually impaired users, Multimodal orchestration, Cognitive load, Diagnostic framework, Differential Cognitive Yield

Mots clés

Interfaces STEM non visuelles, Personnes aveugles et malvoyantes, Orchestration multimodale, Charge cognitive, Cadre diagnostique, Rendement cognitif différentiel



This work is licensed under a Creative Commons Attribution 4.0 International License.
IHM '26, Villeneuve-d'Ascq, France
© 2026 Copyright held by the owner/author(s).
ACM ISBN 979-8-4007-2965-2/2026/10
https://doi.org/10.1145/3845948.3845951

ACM Reference Format:
Madjid Sadallah and Benoît Encelle. 2026. Multimodal Orchestration in STEM Accessibility: from Architectural-Performance Decoupling to Differential Cognitive Yield: Orchestration multimodale en accessibilité STEM : du découplage architecture-performance au rendement cognitif différentiel. In *Proceedings of the 37th Conference on l'Interaction Humain-Machine (IHM '26), October 19–23, 2026, Villeneuve-d'Ascq, France.* ACM, New York, NY, USA, 16 pages. https://doi.org/10.1145/3845948.3845951

1 Introduction

Rendre les contenus STEM (STIM en français : provenant des Sciences, Technologies, de l'Ingénierie, des Mathématiques) accessibles aux personnes aveugles ou malvoyantes constitue l'un des défis fondamentaux de l'interaction humain-machine. Il s'agit de reconstituer, par des modalités exclusivement non visuelles, l'expérience que procure naturellement la vision pour des contenus intrinsèquement spatiaux et complexes [31, 48]. Ce défi a engendré une diversification rapide des interfaces multimodales combinant canaux auditifs, tactiles et haptiques, dont la sophistication architecturale s'est considérablement accrue au cours de la dernière décennie. Pourtant, les études menées en conditions écologiques rapportent de manière récurrente une charge cognitive élevée, des difficultés persistantes dans la construction de modèles mentaux cohérents, ainsi qu'une appropriation souvent laborieuse, y compris pour des systèmes technologiquement avancés [13, 18, 22]. Dans cet article, *tactile* désigne les dispositifs passifs de restitution par contact (surfaces en relief, graphiques tactiles imprimés en 3D), tandis que *haptique* désigne les dispositifs actifs à retour de force ou vibrotactile (bras haptiques, actionneurs).

Ce constat met en évidence un paradoxe central : l'augmentation de la sophistication multimodale ne garantit pas une meilleure accessibilité cognitive.Nous expliquons ce paradoxe par deux causes structurelles encore insuffisamment articulées dans la littérature. La première est conceptuelle : une *illusion additive* sous-tend implicitement de nombreux travaux de conception, postulant que l'accumulation des modalités sensorielles améliore mécaniquement l'accessibilité [67]. Cette hypothèse, en apparence évidente, n'a, à notre connaissance, pas encore fait l'objet d'un examen empirique systématique et reste rarement traduite en critères de conception opérationnels. La seconde cause est d'ordre méthodologique : les évaluations empiriques privilégient des métriques de performance immédiate (temps de complétion, précision, taux d'erreur), qui rendent peu compte des différences entre architectures multimodales et tendent à masquer les coûts cognitifs sous-jacents, en particulier lorsque les utilisateurs développent des stratégies compensatoires [34]. Des travaux de synthèse confirment ce biais : les protocoles expérimentaux intègrent encore peu de mesures directes de la charge cognitive et de l'efficience informationnelle [12].

Sur le plan conceptuel, les cadres théoriques de l'ergonomie cognitive suggèrent que l'efficacité d'une interface multimodale dépend moins du nombre de modalités mobilisées que de la qualité de leur *orchestration* : la manière dont les flux informationnels sont articulés dans le temps et par rapport au sens, afin de former une représentation mentale unifiée tout en minimisant la charge cognitive extrinsèque [56, 84]. Lorsque cette orchestration est déficiente, les modalités entrent en compétition pour les ressources attentionnelles au lieu de se renforcer mutuellement [83, 96, 97]. Sur le plan méthodologique, la discipline manque donc d'outils permettant de distinguer la performance *observable* de l'efficience *cognitive*, entendue comme le rapport entre l'information effectivement traitée et le coût cognitif associé, condition nécessaire pour révéler ce que les métriques de surface occultent.

Pour répondre à ces deux lacunes, nous introduisons ARC (*Architectural Readiness for perceptual Convergence*), un cadre diagnostique de l'orchestration multimodale. Cet article en constitue le développement approfondi : il s'appuie sur une contribution préliminaire [75] qui avait introduit les cinq dimensions du cadre et conduit une première analyse exploratoire, et s'en distingue sur les points suivants. Il apporte quatre contributions principales : (1) un protocole de caractérisation systématique des architectures multimodales selon des dimensions codifiables et comparables, avec pondérations affinées sur la base d'une justification théorique explicitement articulée ; (2) l'introduction et l'opérationnalisation du construit théorique de *Rendement Cognitif Différentiel* (RCD / *Differential Cognitive Yield*, DCY), rendue possible par l'isolation rigoureuse de la performance rapportée comme variable externe au score architectural, éliminant tout biais de circularité ; (3) une caractérisation empirique de trois niveaux de maturité architecturale avec identification des dimensions différenciatrices ; (4) des recommandations de conception structurées sous forme de trajectoires d'amélioration actionnables.

2 Fondements théoriques et positionnement

2.1 Charge cognitive, multimodalité et critères ergonomiques

La théorie de la charge cognitive (CLT) de Sweller et al. [84] distingue trois composantes : la charge *intrinsèque* (liée à la complexité inhérente du contenu), la charge *extrinsèque* (imposée par la conception de l'interface) et la charge *essentielle* (dédiée à la construction de schémas cognitifs durables). Pour les interfaces multimodales pour l'accessibilité, l'enjeu central est de minimiser la charge extrinsèque afin de préserver les ressources cognitives pour la charge essentielle, tout en maintenant la richesse informationnelle requise par les contenus STEM. Une orchestration défaillante impose une double charge extrinsèque : l'utilisateur doit maintenir en mémoire de travail les informations partielles issues de chaque canal jusqu'à leur transmission complète, puis les intégrer manuellement [6]. Ce coût est aggravé pour les personnes aveugles ou malvoyantes, qui ne bénéficient pas du rôle intégrateur spatial naturel de la vision [31].

Le cadre ergonomique de Bastien et Scapin [8] propose deux critères directement opérationnalisables. Le premier, la *charge de travail*, vise à minimiser la charge perceptive, mnésique et attentionnelle. Une interface mal conçue ne respecte pas ce principe lorsqu'elle oblige l'utilisateur à maintenir des informations en mémoire de travail dans l'attente d'un second canal. Dans le contexte multimédia, Mayer [56] transpose la Cognitive Load Theory (CLT) au design interactif par le principe de *contiguïté temporelle*, qui consiste à synchroniser les flux d'information complémentaires, un enjeu particulièrement critique en l'absence de vision. Le second critère, l'*homogénéité et la cohérence*, exige une cohérence sémantique entre les différentes modalités : son absence contraint l'utilisateur à un effort cognitif supplémentaire pour établir la correspondance entre des informations indépendantes.

2.2 Compatibilité modale et intégration multisensorielle

Le modèle des ressources multiples de Wickens [97] structure les ressources cognitives selon plusieurs dimensions orthogonales : modalité sensorielle, code de représentation (spatial/verbal) et stade de traitement. Il fonde le principe de *compatibilité modale* : chaque type d'information doit être assigné à la modalité dont les caractéristiques épousent naturellement sa structure. Pour les interfaces pour l'accessibilité des STEM, cela signifie : le canal tactile pour les relations spatiales (exploration directe, isomorphisme topologique), la sonification pour les variations quantitatives continues (mapping paramétrique), et la synthèse vocale pour décrire des relations entre concepts (sémantique) et transmettre des informations textuelles (métadonnées). Enfreindre cette compatibilité contraint l'utilisateur à un recodage mental coûteux, saturant la mémoire de travail [47].

Les neurosciences cognitives établissent deux conditions nécessaires à l'intégration perceptive [26, 83] : la *coïncidence temporelle* et la *congruence sémantique*. La limite pour une intégration temporelle optimale est d'environ 100 ms pour les paires audio-visuelles [29, 92] : en deçà, les stimuli fusionnent automatiquement, avant toute allocation attentionnelle ; au-delà, l'utilisateur doit les lier de manière contrôlée. Ce seuil de 100 ms sert de référence commune dans la littérature. Pour les paires audio-tactiles, Machulla, Di Luca et Ernst [53] rapportent des seuils de détection plus bas : 56 ms en jugement de synchronie (81 ms pour l'audio-visuel). Notre barème (section 3) retient 100 ms pour le score maximal de la dimension de synchronisation temporelle, un choix délibérément plus large, privilégiant la sensibilité et la comparabilité inter-études plutôt qu'une stricte conservativité, et restant en deçà du consensus ($\geq$ 200 ms) sur la rupture de fusion perceptive [92]. La congruence sémantique s'appuie sur l'hypothèse d'unité de Welch et Warren [96] : les stimuli sont intégrés s'ils semblent décrire le même objet ou événement. Ces deux conditions définissent les prérequis architecturaux pour que la fusion perceptive devienne possible.

2.3 Taxonomies multimodales existantes et lacunes opérationnelles

Plusieurs taxonomies de référence structurent les interfaces multimodales. Nigay et Coutaz [64] proposent une taxonomie bidimensionnelle (temporalité, niveau d'abstraction). Coutaz et al. [17] développent le cadre CARE distinguant quatre relations entre modalités (Complémentarité, Assignation, Redondance, Équivalence). Une revue des approches de fusion est proposée par Turk [89]. Ces travaux partagent une limite commune : leur abstraction élevée résiste à l'opérationnalisation en protocoles de codage suffisamment précis pour garantir une fiabilité inter-évaluateurs satisfaisante. CARE, par exemple, fournit un vocabulaire conceptuel précieux mais ne propose ni métrique quantitative ni seuils diagnostiques actionnables. C'est cette lacune que notre cadre vise à combler : s'ancrer dans les construits théoriques exposés ci-dessus pour produire un protocole de codage quantifié, à fiabilité inter-évaluateurs vérifiée, et spécifiquement calibré pour l'orchestration multimodale dans le contexte de l'accessibilité des STEM. Le Tableau 1 situe ARC par rapport à ces outils ainsi qu'à des instruments génériques (SUS, NASA-TLX, WCAG/Section 508).

3 Le cadre ARC

3.1 Principes de conception du cadre

Nous avons conçu le cadre ARC (*Architectural Readiness for perceptual Convergence*) pour satisfaire quatre exigences complémentaires :

(1) le **fondement théorique** garantit que chaque dimension s'ancre dans des construits validés issus de l'ergonomie cognitive et des neurosciences de l'intégration multisensorielle, condition nécessaire à l'interprétabilité des scores ;
(2) l'**opérationnalisabilité** impose des critères de codage suffisamment précis pour que deux évaluateurs indépendants puissent atteindre une fiabilité inter-évaluateurs ICC $\geq$ 0,80 ; les scores reflètent ainsi des propriétés du système plutôt que des jugements idiosyncratiques ;
(3) le **pouvoir discriminant** exige que le cadre révèle des différences significatives de qualités architecturales entre paradigmes de conception ;
(4) l'**actionnabilité**, enfin, suppose que les résultats puissent être opérationnalisés sous forme de recommandations concrètes assorties de seuils empiriquement établis.

Les cinq dimensions du cadre (notées D_{sync}, D_{int}, D_{topo}, D_{modal}, D_{perf}, formant le score ARC_{arch}) ont été définies selon un processus en deux étapes. La première étape repose sur une revue systématique des cadres théoriques fondateurs de l'ergonomie cognitive et des neurosciences de l'intégration multisensorielle (théorie de la charge cognitive [84], critères ergonomiques de Bastien et Scapin [8], modèle des ressources multiples [97]) afin d'identifier les construits cognitifs les plus opérationnalisables en protocole de codage inter-évaluateurs, d'où les quatre dimensions architecturales. Le Tableau 2 synthétise l'ancrage théorique primaire de chaque dimension. La seconde étape consiste en une analyse pilote conduite sur 20 systèmes (30 % du corpus) pour tester la discrimination inter-niveaux et affiner les barèmes de notation. D_{perf} a été isolée *a priori* de cette procédure pour éviter toute circularité entre qualité architecturale et performance rapportée.

Une exigence de rigueur, non satisfaite dans la version préliminaire du cadre [75], structure la présente analyse : D_{perf} est exclue *par construction* du score ARC_{arch}. Cette séparation est essentielle pour éviter un raisonnement circulaire : inclure la performance dans le score architectural compromettrait la démonstration de l'indépendance entre qualité structurelle et résultats empiriques. En isolant D_{perf} comme variable externe *a priori*, le cadre remplit les conditions nécessaires pour tester, plutôt que présupposer, la relation entre architecture et performance. La robustesse de ce choix est vérifiée sous pondérations égales (section 5.4).

La Figure 1 illustre ce pipeline : les quatre phases séquentielles (sélection du corpus, codage, pondération, analyse) et les cinq dimensions de codage. Les quatre dimensions architecturales (bordures pleines) contribuent au score, tandis que D_{perf} (bordure pointillée) est traitée comme variable externe.

3.2 Dimensions architecturales

ARC évalue chaque système au moyen de cinq dimensions complémentaires, notées D_{sync} (cohérence temporelle), D_{int} (cohérence

Table 1: Positionnement d'ARC par rapport aux outils d'évaluation IHM existants.

Outil	Focus	Opérationnalisation	Portée	Base empirique
Critères B&S [8]	Ergonomie générale	Heuristiques qualitatives	Générique	Usage extensif
WCAG/508 [90, 99]	Conformité technique	Checkpoints binaires	Générique	Normative
SUS [10]	Satisfaction perçue	10 items subjectifs	Générique	Usage extensif
NASA-TLX [38]	Charge mentale ressentie	6 dimensions subjectives	Générique	Usage extensif
CARE [17]	Relations inter-modales	Taxonomie conceptuelle	Multimodal	Conceptuelle
ARC	**Orchestration multimodale**	**Grille codifiée**	**STEM accessible**	**voir sections 4 et 5**

Table 2: Ancrage théorique primaire des cinq dimensions du cadre ARC.

Dim.	Ancrage théorique primaire
D_{sync}	Coïncidence temporelle [83, 92] ; critère de charge de travail [8]
D_{int}	Hypothèse d'unité perceptive [96] ; critère d'homogénéité/ cohérence [8]
D_{topo}	Préservation des relations spatiales dans les représentations diagrammatiques [46]
D_{modal}	Modèle des ressources multiples et compatibilité modale [67, 97]
D_{perf}	Variable externe isolée *a priori* pour éviter toute circularité architecture–performance

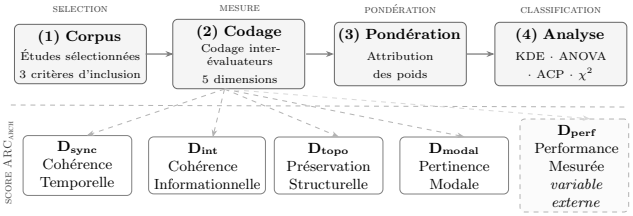


Figure 1: Pipeline analytique ARC. *Haut* : quatre phases séquentielles (SÉLECTION, MESURE, PONDÉRATION, CLASSIFICATION). *Bas* : les cinq dimensions de codage. $\mathbf{D_{perf}}$ (cadre pointillé) est une variable externe exclue du score.

informationnelle), D_{topo} (préservation structurelle), D_{modal} (pertinence modale) et D_{perf} (performance rapportée). La procédure de codage inter-évaluateurs est décrite en section 4. Le score architectural ARC_{arch} (maximum 16 points) repose sur les pondérations suivantes : D_{sync} = 5 points (31,2 %, barème brut /4 converti via ×5/4), D_{int} = 4 points (25,0 %), D_{modal} = 4 points (25,0 %, barème brut /3 converti via ×4/3), D_{topo} = 3 points (18,8 %).

Ces pondérations découlent de deux sources complémentaires : d'une part, une analyse exploratoire conduite sur un sous-ensemble du corpus dans un travail préliminaire [75] ; d'autre part, une hiérarchisation théorique issue de la littérature sur l'intégration multisensorielle et l'ergonomie cognitive. La synchronisation temporelle reçoit le poids le plus élevé car elle constitue une *condition préalable* à toute intégration perceptive automatique [83, 92] : en l'absence de coïncidence temporelle, aucune des autres dimensions ne peut produire une fusion perceptive, quelle que soit leur qualité propre. L'intégration informationnelle et la pertinence modale reçoivent un poids équivalent : elles déterminent conjointement la richesse sémantique de l'orchestration, conformément au principe de compatibilité modale [97] et à l'hypothèse d'unité perceptive [96]. La préservation structurelle, bien que fondamentale [46], est pondérée légèrement en deçà : son implémentation reste partiellement non résolue dans l'état de l'art, limitant sa variance discriminante dans le corpus. La robustesse de ces choix est vérifiée sous pondérations égales (section 5.4).

3.2.1 D_{sync} – Cohérence temporelle (0–4 pts brut, converti sur 5 pts après pondération). Cette dimension évalue le degré de synchronisation entre les canaux sensoriels. Elle opérationnalise le critère de charge de travail de Bastien et Scapin [8] et s'appuie sur le principe de coïncidence temporelle, condition nécessaire à l'intégration multisensorielle automatique. La littérature suggère une fenêtre d'intégration d'environ 100 ms : en deçà, les stimuli fusionnent automatiquement ; au-delà, l'utilisateur doit les lier manuellement, ce qui augmente la charge cognitive.

Le score de 0 point correspond à une présentation séquentielle contrainte dans laquelle les modalités sont diffusées l'une après l'autre, obligeant l'utilisateur à attendre la fin d'un canal avant d'accéder au suivant. Un score de 0,5 point est attribué dans le cas particulier où aucune synchronisation n'est explicitement rapportée, mais où la latence perçue est néanmoins documentée comme imperceptible. Un score de 1 point est attribué lorsque la synchronisation repose sur un déclenchement manuel : l'utilisateur doit activer explicitement la seconde modalité, par exemple via un bouton ou une commande vocale, ce qui fait porter l'intégration sur lui. Un score intermédiaire de 2,5 points correspond à une synchronisation déclarée avec latence perceptible, lorsque l'article mentionne une synchronisation mais qu'un délai reste perceptible. Le score de 3 points est attribué lorsque la synchronisation est déclarée avec une faible latence, sans mesure précise. Enfin, le score maximal de 4 points correspond à une synchronisation automatique avec latence imperceptible, lorsque la latence est mesurée et inférieure ou égale à 100 ms, permettant une fusion perceptive automatique. Le score brut (0–4) est converti vers sa contribution architecturale via la formule final = brut × 5/4, reflétant le poids de 5 points (31,2 %) de D_{sync} dans le score ARC_{arch}. Un score brut maximal de 4 correspond ainsi à une contribution de 5 points.

À titre d'illustration, Diagram writer [98], un système de création et d'édition autonome de diagrammes UML sur dispositifs

Table 3: Grille de notation des dimensions architecturales d'ARC.

Dimension	Opérationnalisation (critère ergonomique fondateur)	Max
$\mathbf{D_{sync}}$ Cohérence Temporelle	Synchrone + latence imperceptible ≤ 100 ms (4) ; synchrone, faible latence (3) ; synchrone, latence notable (2,5) ; déclenché utilisateur (1) ; absence de synchronisation déclarée mais latence rapportée comme imperceptible (0,5) ; séquentiel (0). *[Charge de travail, B&S]*	4†
$\mathbf{D_{int}}$ Cohérence Informationnelle	Complémentaire (2,0–3,0 selon documentation) ; supplémentaire (0,8–1,5) ; redondant/séquentiel (1) ; indépendant (0,3) ; +ajustements mineurs (jusqu'à +0,3/±0,2). Plafonné à 4. *[Homogénéité/cohérence, B&S]*	4
$\mathbf{D_{topo}}$ Préservation Structurelle	Métrique (1,6) ; topologique (1,2) ; mixte (1,0) ; hiérarchique (0,8) ; isolé (0,4) ; +bonus préservation (jusqu'à +1,0), navigation (jusqu'à +0,8) et ajustement dimensionnel (±0,2). *[Compatibilité, B&S]*	3
$\mathbf{D_{modal}}$ Pertinence Modale	Multimodal explicite (1,5) ; non-visuel riche (1) ; parole dominante (0,5) ; +bonus richesse (≥ 3 avec tactile+parole : +1,5 ; ≥ 3 distinctes : +1,0 ; 2 avec sonification ou tactile : +0,5) ; +bonus techniques secondaires (jusqu'à +0,85 cumulés). *[Charge de travail, B&S]*	3†
D_{perf} *Performance*	≥ 2 *indicateurs de preuve convergents (2) ; 1 indicateur solide, ou résultats mixtes + indicateur secondaire (1) ; aucune preuve probante (0)*	*2*

† D_{sync} et D_{modal} : barèmes bruts respectivement sur 4 et 3 pts, convertis ultérieurement sur 5 et 4 pts par pondération.

mobiles, atteint le score maximal ($D_{sync} = 4/4$) : la synchronisation entre retour tactile et retour vocal y est automatique, avec une latence rapportée comme imperceptible, condition nécessaire, selon notre barème, à une fusion perceptive automatique plutôt qu'à un traitement contrôlé et coûteux.

3.2.2 D_{int} – Cohérence informationnelle (0–4 pts). Cette dimension décrit la manière dont l'information est répartie entre les modalités. Elle opérationnalise le critère d'homogénéité/cohérence de Bastien et Scapin [8] et se fonde sur l'hypothèse d'unité perceptive de Welch et Warren [96], selon laquelle des stimuli sont intégrés lorsqu'ils semblent décrire le même objet ou événement.

Un score de 0,3 point correspond à des modalités indépendantes, dans lesquelles les canaux traitent de contenus distincts sans lien sémantique. Un score de 1 point est attribué en cas de redondance pure ou de présentation séquentielle des canaux. Un score de 0,8 à 1,5 point reflète une complémentarité supplémentaire, selon le potentiel d'intégration documenté. Le score de complémentarité proprement dite varie de 2,0 à 3,0 points selon ce même potentiel et la présence d'une justification explicite de la stratégie d'intégration par les auteurs. Un ajustement mineur (jusqu'à +0,3 point selon la fidélité de traduction sensorielle rapportée, et ±0,2 point selon la difficulté de correspondance inter-modale) complète le calcul. Le score total est plafonné à 4 points. L'objectif visé par cette dimension est la *complémentarité synergique*, où chaque canal apporte une information que l'autre ne peut transmettre efficacement, par exemple l'association d'un retour audio indiquant une alerte et d'un retour haptique localisé permettant d'identifier immédiatement la source de l'événement.

La plateforme d'enseignement des mathématiques accessibles *EuroMath*, telle que décrite dans sa présentation générale [27], illustre une intégration complémentaire de haut niveau ($D_{int} = 3{,}2/4$) : parole, braille et agrandissement visuel s'y répartissent l'information selon une logique de complémentarité documentée par les auteurs, chaque canal apportant une information que les autres ne peuvent transmettre aussi efficacement.

3.2.3 D_{topo} – Préservation structurelle (0–3 pts). Cette dimension évalue la fidélité avec laquelle les relations spatiales (distances, voisinage, hiérarchie) sont transmises. Larkin et Simon [46] ont montré que les représentations diagrammatiques sont efficaces car elles préservent les relations spatiales, permettant une inférence perceptive directe. La vision fournit cette propriété de manière implicite ; en l'absence de vision, elle doit être explicitement reconstruite par le dispositif interactif.

Le score de base dépend du niveau de relations spatiales encodées, sur une échelle à cinq paliers allant de la présentation d'éléments isolés (0,4) à des relations métriques précises telles que distances, proportions ou angles (1,6), en passant par les regroupements hiérarchiques (0,8), les encodages mixtes (1,0) et les relations topologiques qualitatives comme l'adjacence ou le voisinage (1,2).

À ce score de base s'ajoutent trois bonus cumulables, plafonnés à 3 points au total : un bonus de préservation de la structure spatiale globale (jusqu'à +1,0 point), un bonus lié à la présence de mécanismes d'orientation ou de navigation (jusqu'à +0,8 point), et un léger ajustement (±0,2 point) selon que l'écart dimensionnel rapporté entre représentation et contenu source est compensé ou constitue une gêne.

Pour les contenus non spatiaux comme les expressions mathématiques, la préservation structurelle concerne non pas des relations géométriques, mais la structure syntaxique elle-même : hiérarchie des parenthèses, distance syntaxique entre opérandes et priorités opératoires. Le moteur de conversion et de navigation d'EuroMath [58], conçu pour assister l'enseignement des mathématiques aux aveugles par des tuteurs voyants, en est un exemple : chaque formule y est représentée par un arbre syntaxique navigable, permettant d'explorer les relations parent-enfant entre sous-expressions. Son score $D_{topo} = 2{,}2/3$ traduit une préservation topologique explicite de cette hiérarchie, sans atteindre la précision métrique maximale.

3.2.4 D_{modal} – Pertinence modale (0–3 pts brut, converti sur 4 pts après pondération). Cette dimension examine l'adéquation entre les modalités choisies et la nature de l'information. Elle s'appuie sur le modèle des ressources multiples de Wickens [97] ainsi que sur le principe de compatibilité modale [67]. Selon ces travaux, certaines modalités sont particulièrement adaptées à certains types d'information : le canal tactile se prête à la transmission de structures spatiales, la sonification à la représentation de variations quantitatives continues, tandis que la parole est mieux adaptée à la communication de relations sémantiques.

Le score brut repose d'abord sur la modalité principale utilisée. Un score de 0,5 point correspond à une parole dominante, lorsque la synthèse vocale constitue le canal principal d'accès à l'information. Un score de 1 point est attribué lorsque la modalité primaire repose sur un canal non visuel riche, tel qu'un dispositif tactile ou une sonification structurée. Un score de 1,5 point correspond à une approche multimodale explicite, dans laquelle plusieurs modalités sont combinées de manière intentionnelle pour soutenir l'interaction.

À ce score de base s'ajoutent des bonus de richesse multimodale, cumulables dans la limite du score maximal. Un bonus de +1,5 point est attribué lorsqu'au moins trois modalités sont utilisées, incluant obligatoirement un canal tactile et la parole. Un bonus de +1,0 point est accordé dans le cas d'une tri-modalité générale impliquant au moins trois modalités distinctes. Un bonus de +0,5 point est attribué lorsqu'une bi-modalité inclut une sonification ou un canal tactile. Des bonus techniques mineurs et cumulables (jusqu'à +0,85 point au total) valorisent en outre certains choix d'implémentation documentés, tels que la dominance modale explicite ou le type de dispositif haptique employé.

Le score brut total (base + bonus) est plafonné à 3 points. Pour refléter son poids de 4 points dans le score architectural global, il est ensuite converti via la formule final = $\min(\text{brut} \times 4/3,\ 4)$. Ainsi, un score brut maximal de 3 correspond à un score pondéré de 4.

Le système *ChartA11y* [102], conçu pour l'exploration tactile de visualisations de données sur smartphone, combine quatre modalités (parole, sonification, retour haptique, description textuelle) avec un score $D_{\text{modal}} = 3{,}0/3$: la richesse modale y est maximale, chaque canal ciblant un type d'information pour lequel il est structurellement adapté, conformément au principe de compatibilité modale de Wickens [97].

3.2.5 D_{perf} – Performance rapportée (0–2 pts, variable externe). Cette dimension ne caractérise pas l'architecture du système mais les résultats empiriques publiés. Elle est donc exclue du score architectural et analysée séparément afin d'éviter toute circularité entre la qualité structurelle d'un système et ses performances rapportées.

Le score de 0 point correspond à l'absence de toute preuve empirique probante : aucune étude n'est rapportée, ou aucun résultat significatif n'est observé. Le score maximal de 2 points est attribué lorsqu'au moins deux indicateurs de preuve solide convergent, parmi : significativité statistique, mesure de charge cognitive standardisée, niveau de reporting inférentiel, avantage comparatif quantifié, et score d'utilisabilité (ce dernier ne comptant qu'en complément d'un autre indicateur). Le score intermédiaire de 1 point correspond aux cas partiels : un seul indicateur solide, ou des résultats mixtes soutenus par un indicateur secondaire (signification pratique, faible charge cognitive extrinsèque rapportée, avantage comparatif non quantifié).

Cette échelle, volontairement large, vise à permettre la comparaison entre études hétérogènes. Sa sensibilité limitée conduit à une estimation prudente des différences, renforçant l'interprétation du découplage éventuellement observé entre architecture et performance.

4 Corpus et méthode

Nous avons suivi un protocole pré-enregistré [76] pour la sélection des études. Conformément aux recommandations pour les revues systématiques [42] et à la méthode de développement de taxonomies de Nickerson et al. [63], nous avons constitué un corpus de 66 études empiriques évaluées par les pairs, publiées entre 2015 et 2025, portant sur des solutions logicielles multimodales destinées à l'accès des personnes aveugles ou malvoyantes aux contenus STEM. Les sources consultées incluent *ACM Digital Library*, *IEEE Xplore*, *OpenAlex*, *PubMed* et *Web of Science*.

La stratégie de recherche combine quatre facettes booléennes en conjonction : (A) population cible (personnes aveugles ou malvoyantes, ex. `"visually impaired"`, `BVI`, `"low vision"`), (B) contenu visuel STEM (ex. `equation`, `graph`, `diagram`, `STEM`), (C) technologies d'assistance (ex. `haptic`, `tactile`, `sonification`, `braille`, `screen reader`) et (D) outils numériques (ex. `software`, `machine learning`, `AI`). Un bloc d'exclusion (NOT) filtre les faux positifs thématiques récurrents : navigation spatiale et aides à la mobilité (canne blanche, chien guide), dispositifs tactiles physiques (impression 3D, thermoformage), réalité virtuelle/augmentée et jeux sérieux, ainsi que les usages homonymes de « blind » en traitement du signal (*blind source separation*, *blind deconvolution*). Le filtre temporel couvre 2015–2025. Les cinq requêtes complètes, adaptées à la syntaxe propre à chaque base, sont disponibles intégralement dans le protocole pré-enregistré [76].

Les critères d'inclusion, définis dans le protocole, portaient sur trois conditions cumulatives : (1) une solution multimodale non visuelle employant au moins deux modalités de sortie pour des contenus STEM authentiques ; (2) une évaluation empirique rapportée auprès de personnes aveugles ou malvoyantes ; (3) un niveau de description technique suffisant pour coder les cinq dimensions ARC. Le processus de sélection est détaillé Figure 2.

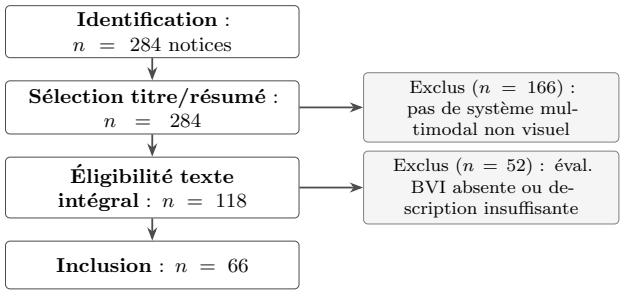


Figure 2: Diagramme de flux PRISMA documentant la sélection des études.

Le corpus couvre plusieurs types de contenus : mathématiques (42,4%), diagrammes 2D (33,3%), visualisations de données (16,7%) et modèles 3D (7,6%). Les combinaisons modales se répartissent entre audio+tactile (47,0%), audio+haptique (28,8%) et configurations intégrant trois modalités ou plus (24,2%). Enfin, les méthodologies d'évaluation comprennent des expériences contrôlées (57,6%), des études de terrain (27,3%) et des approches mixtes (15,2%).

Deux évaluateurs ont indépendamment codé chaque système selon les cinq dimensions. Les désaccords (moins de 12% des cas) ont été résolus par discussion consensuelle avec justification théorique explicite ; les cas ambigus ont été systématiquement assignés au niveau inférieur (approche conservative visant à prévenir l'inflation

des scores). Les coefficients de corrélation intra-classe (ICC) calculés sur l'ensemble du corpus sont les suivants [43] : D_{sync} = 0,91, D_{int} = 0,93, D_{topo} = 0,89, D_{modal} = 0,87, D_{perf} = 0,85, total = 0,92. Selon le critère de Koo et Li [43], un ICC supérieur à 0,90 indique une fiabilité excellente ; tous les ICC architecturaux le satisfont ou s'en approchent. La liste exhaustive des 66 études retenues, avec leurs scores ARC détaillés par dimension et leur niveau architectural, figure en Annexe A.

Toutes les analyses ont été conduites en Python 3.14.2 (α = 0,05), avec restitution systématique des tailles d'effet et des intervalles de confiance à 95%. Les analyses incluent : estimation de densité par noyau (KDE) pour identifier les structures distributionnelles, ANOVA univariée avec tests post-hoc de Tukey, régression logistique multinomiale, analyse en composantes principales (ACP), et tests de corrélation de Pearson.

5 Résultats : Analyse Descriptive du Corpus

5.1 Statut épistémique des analyses

Conformément à une démarche exploratoire-descriptive au sens de Tukey [88], les pondérations ont été fixées *a priori* sur la base d'une analyse pilote portant sur 20 systèmes (30 % du corpus), conduite dans un travail préliminaire [75], puis appliquées sans recalibration à l'ensemble des 66 systèmes. Cette procédure garantit que la détermination des seuils (section 5.3) est *indépendante* de la définition des pondérations : les discontinuités distributionnelles émergent des données et ne sont pas induites par les choix de pondération. L'ensemble des analyses qui suivent doit être lu comme une *caractérisation descriptive interne* : les seuils, effectifs et tailles d'effet sont des propriétés de ce corpus et ne constituent pas des inférences confirmatives généralisables. Cette limitation, inhérente à toute étude exploratoire de première génération, ne remet pas en cause la valeur diagnostique du cadre ; elle en définit le périmètre épistémique et motive explicitement les réplications indépendantes appelées en section 6.5.

5.2 Caractérisation des protocoles expérimentaux et de D_{perf} par niveau

Avant d'examiner la distribution des scores ARC, nous caractérisons ici les protocoles expérimentaux du corpus selon trois axes : la complexité des tâches, les métriques mesurées, et la distribution de D_{perf} par niveau ARC.

L'ensemble du corpus (100 %) rapporte au moins une métrique de performance brute (précision, temps de complétion, taux d'erreur), contre seulement 18,2 % (12/66) qui mesurent la charge cognitive, dont 12,1 % (8/66) via le NASA-TLX standardisé.

Le Tableau 4 croise la complexité de tâche rapportée avec le niveau ARC. On observe que les systèmes N_1 sont évalués sur des tâches proportionnellement plus simples (26,6 % de tâches faibles) que les systèmes N_3 (5,6 %), tandis que les systèmes N_2 occupent une position intermédiaire (11,1 %). Enfin, la distribution de D_{perf} par niveau (48,3 % du maximum en N_1, 33,3 % en N_2, 27,8 % en N_3) présente une trajectoire descriptive décroissante.

Table 4: Complexité des tâches et D_{perf} par niveau ARC.

Niveau	n	Tâches faibles	D_{perf} moyen	Charge cognitive
N_1 – Cumulatif	30	26,6 %	48,3 %	20,0 %
N_2 – Articulé	18	11,1 %	33,3 %	5,6 %
N_3 – Orchestré	18	5,6 %	27,8 %	5,6 %

5.3 Trois niveaux de maturité architecturale

La distribution des scores ARC_{arch} révèle une structure trimodale avec des discontinuités observées à 6,0 et 10,5 points, délimitant trois niveaux dont les intervalles de confiance à 95% sont non-chevauchants (Tableau 5, Figure 3). Ce nombre de niveaux n'a pas été fixé a priori : l'estimation de densité par noyau a fait émerger une structure naturelle à trois pics séparés par deux creux, confirmée par bootstrap (stabilité des seuils) et par l'ancrage à des seuils cognitifs préalablement documentés. Aucune autre partition (2, 4 ou 5 groupes) ne produisait simultanément des intervalles de confiance non chevauchants et une interprétation théorique cohérente.

Ces niveaux correspondent à des régimes architecturaux que nous nommons *Cumulatif* (N_1), *Articulé* (N_2) et *Orchestré* (N_3). Ces trois régimes prolongent et précisent les catégories *Additive*, *Augmentative* et *Integrative* identifiées dans [75]. Ce renommage reflète un déplacement conceptuel délibéré, de la description du nombre de modalités présentes vers la caractérisation de la *logique d'intégration* qui les gouverne, en cohérence avec l'approche centrée sur l'orchestration défendue dans cet article.

Trois systèmes du corpus illustrent ces logiques architecturales et le découplage architecture–performance qui les traverse.

N_1 – Cumulatif : SeeChart [3] (score ARC_{arch} = 3,27 ; D_{perf} = 2) exploite une interface conversationnelle en langage naturel pour décrire des visualisations de données à des utilisateurs aveugles. La modalité vocale y est quasi-exclusive, la synchronisation entre canaux est séquentielle et non automatique. Le système rapporte pourtant un temps de complétion et une précision significativement meilleurs qu'une baseline, cas paradigmatique de l'illusion additive : la performance mesurée ne reflète en rien l'absence d'orchestration architecturale.

N_2 – Articulé : Mathematical content browsing for print-disabled readers [45] (score ARC_{arch} = 7,80 ; D_{perf} = 1) combine parole, sonification et retour tactile pour l'exploration d'équations mathématiques. Sa pertinence modale est maximale, mais sa synchronisation temporelle est nulle : les canaux demeurent séquentiels. Ses résultats de précision sont mitigés, cohérents avec cette absence de coordination temporelle.

N_3 – Orchestré : Perceiving graphical and pictorial information via hearing and touch [80] (score ARC_{arch} = 14,2 ; D_{perf} = 2) synchronise sonification spatialisée et retour tactile avec une latence imperceptible pour l'exploration de formes géométriques 2D. L'intégration est automatique et complémentaire, et ses résultats (précision d'identification, temps de complétion) sont statistiquement significatifs.

Le contraste entre SeeChart et ce dernier système résume la thèse centrale : les deux rapportent une performance significative (D_{perf} = 2) pour un écart de près de 11 points sur le score architectural. Cette absence de correspondance entre sophistication structurelle et performance de surface est précisément ce que le Rendement Cognitif Différentiel (section 6.2) propose d'expliquer.

Les deux discontinuités s'ancrent dans des seuils cognitifs documentés. La première (6,0 points) sépare les systèmes à présentation séquentielle de ceux qui mettent en œuvre une coordination au moins partielle entre modalités : à partir de ce seuil, l'utilisateur n'est plus contraint d'attendre passivement la fin d'un canal avant d'accéder au suivant. La seconde (10,5 points) correspond au franchissement du seuil perceptif d'environ 100 ms [92] : la synchronisation en dessous 100 ms devient suffisamment fine pour permettre une fusion perceptive automatique, ce qui dans notre barème nécessite un score D_{sync} d'au moins 3 points.

L'ANOVA sur ARC_{arch} confirme une discrimination très marquée entre niveaux : $F(2, 63) = 326{,}10$, $p < 0{,}001$, $\eta^2 = 0{,}912$. Les comparaisons post-hoc (Tukey HSD) révèlent des tailles d'effet très grandes à chaque transition : N_1 vs. N_2 ($d = 3{,}77$, $p < 0{,}001$), N_2 vs. N_3 ($d = 3{,}37$, $p < 0{,}001$), N_1 vs. N_3 ($d = 8{,}35$, $p < 0{,}001$). Ces tailles d'effet reflètent la validité discriminante interne du cadre appliqué à ce corpus, et non une estimation de l'écart cognitif réel en conditions écologiques. La forte proportion de N_1 (45,5%) reflète l'état réel du corpus : l'exclusion de D_{perf} du score architectural empêche que des performances favorables compensent une orchestration structurellement défaillante, révélant sans atténuation la prévalence des architectures peu coordonnées dans la littérature.

Évolution temporelle. La répartition temporelle du corpus est inégale : la période 2023–2025 concentre 47 % des études ($n = 31$), tandis que les périodes antérieures comptent entre 6 et 13 études. En raison de ces faibles effectifs, toute inférence sur une tendance temporelle est fragile et les observations qui suivent sont purement descriptives. La proportion de systèmes N_3 atteint 67 % dans les années pionnières (2015–2016, $n = 6$), ce qui reflète probablement la spécificité de ces travaux fondateurs (souvent des prototypes de recherche très intégrés) plutôt qu'une tendance générale. Surtout, la proportion de systèmes N_1 ne diminue pas nettement dans la période récente (environ 45 % sur l'ensemble du corpus et une fraction comparable dans les années 2023–2025). Ce constat, bien que limité par les effectifs, suggère que le défi de l'orchestration architecturale reste persistant indépendamment des progrès technologiques.

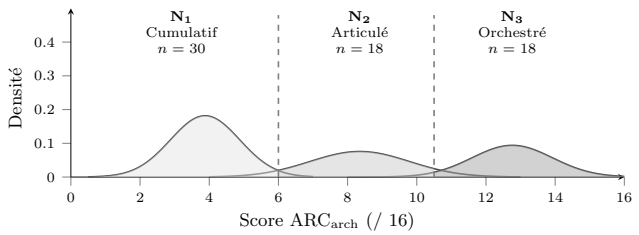


Figure 3: Distribution des scores ARC_{arch} par estimation de densité par noyau (KDE). Les lignes pointillées indiquent les seuils de partition à 6,0 et 10,5 points.

5.4 Le découplage architecture–performance

L'analyse dimensionnelle met en évidence une progression architecturale systématique de N_1 à N_3. D_{sync} en est le principal différenciateur. Il présente l'η^2 le plus élevé (0,739, $p < 0{,}001$), la plus forte corrélation point-bisériale avec le niveau architectural ($r = 0{,}857$, $p < 0{,}001$) et l'aire sous la courbe ROC (*Receiver Operating Characteristic*, une courbe représentant, pour différents seuils de décision, la capacité d'une dimension à distinguer correctement N_3 des autres niveaux), ou AUC (*Area Under the Curve* ; une valeur de 0,5 traduit un pouvoir discriminant nul, une valeur de 1 une discrimination parfaite), la plus haute pour identifier N_3 (0,92). La corrélation D_{sync}–D_{int} du présent corpus ($r = 0{,}43$) confirme que les deux dimensions mesurent des aspects distincts de l'orchestration, en cohérence avec les théories d'intégration multisensorielle [83, 92].

D_{modal} constitue le second différenciateur ($\eta^2 = 0{,}481$, AUC = 0,92), avec un pouvoir discriminant comparable à celui de D_{sync} pour l'identification de N_3. La progression modale de 34% à 86% du maximum (+52,2 pp) indique que les systèmes orchestrés combinent invariablement une synchronisation temporelle élevée et une sélection modale riche et intentionnelle. D_{modal} contribue indépendamment à l'articulation sémantique (voir section 5.5).

La structure corrélationnelle entre dimensions architecturales présente des corrélations modérées mais significatives ($r = 0{,}40$–$0{,}52$, $p < 0{,}001$, Tableau 6), à l'exception de la paire D_{int}–D_{modal} ($r = 0{,}40$, $p = 0{,}001$). Ce profil corrélationnel modéré confirme que les dimensions mesurent des aspects distincts de l'orchestration tout en partageant un facteur commun. Il importe de noter que D_{int} ne discrimine pas significativement N_2 de N_3 pris isolément (Mann-Whitney $U = 112$, $p = 0{,}109$) : la transition vers le régime orchestré requiert une progression conjointe sur plusieurs dimensions, et non une amélioration isolée de la cohérence informationnelle.

Le découplage architecture–performance. D_{perf} ne présente aucune variation significative entre niveaux : $F(2, 63) = 1{,}39$, $p = 0{,}257$, $\eta^2 = 0{,}042$. Au-delà de cette absence de significativité, la *direction* du résultat mérite attention : D_{perf} présente une trajectoire descriptive monotone décroissante, de 48,3 % du maximum en N_1 à 27,8 % en N_3 (−20,5 % ; voir Tableau 4). La matrice de corrélations (Tableau 6) confirme que D_{perf} est corrélée négativement (mais non significativement) avec toutes les dimensions architecturales. Ce résultat confirme empiriquement l'indépendance de D_{perf} vis-à-vis du score architectural validant *a posteriori* le choix de l'isoler comme variable strictement externe.

Cette tendance, purement descriptive, ne constitue pas une confirmation inférentielle d'un mécanisme sous-jacent. Sa robustesse directionnelle sous différentes pondérations en renforce néanmoins l'intérêt et motive l'interprétation théorique développée en section 6, ainsi qu'une validation expérimentale dédiée. L'échelle ordinale de D_{perf} (0–2) est volontairement conservative pour permettre la comparaison inter-études hétérogènes. Si une granularité plus fine pouvait révéler des nuances, un biais de mesure atténuant les différences irait à l'encontre du découplage observé. Le fait que cette inversion persiste, voire s'accentue, sous pondérations égales renforce l'hypothèse que les métriques conventionnelles manquent de sensibilité à la charge cognitive sous-jacente. À titre indicatif, l'analyse de puissance rétrospective indique que ce test dispose d'une puissance de $1 - \beta \approx 0{,}80$ pour détecter un effet de taille $\eta^2 \geq 0{,}133$ ($\alpha = 0{,}05$, $k = 3$, $n = 66$) ; pour l'effet observé ($\eta^2 = 0{,}042$), la puissance est de $1 - \beta = 0{,}30$. L'absence de significativité permet donc d'exclure des effets de taille modérée à grande ($\eta^2 \geq 0{,}133$). Elle ne permet pas d'exclure un petit effet résiduel de la taille observée ($\eta^2 = 0{,}042$, $1 - \beta = 0{,}30$) : ce résultat indique une absence d'effet détectable, non une preuve d'absence d'effet.

Table 5: Niveaux de maturité architecturale et profils dimensionnels. Les pourcentages indiquent l'utilisation relative du maximum.

	Vue d'ensemble			Profils dimensionnels (moyennes brutes ; % du maximum entre parenthèses)				
Niveau	N **(%)**	**Note /16**	**IC 95%**	$\mathbf{D_{sync}/4^{\ddagger}}$	$\mathbf{D_{int}/4}$	$\mathbf{D_{topo}/3}$	$\mathbf{D_{modal}/3}$	$\mathbf{D_{perf}/2^{\star}}$
N_1 Cumulatif	30 (45,5%)	3,88	[3,51 ; 4,26]	0,12 (3%)	1,01 (25%)	1,35 (45%)	1,03 (34%)	0,97 (48%)
N_2 Articulé	18 (27,3%)	8,35	[7,63 ; 9,07]	2,17 (54%)	2,04 (51%)	1,71 (57%)	1,42 (47%)	0,67 (33%)
N_3 Orchestré	18 (27,3%)	12,76	[12,19 ; 13,34]	3,67 (92%)	2,43 (61%)	2,29 (76%)	2,59 (86%)	0,56 (28%)
Progression $N_1 \rightarrow N_3$ (pp du max)				+88,7	+35,5	+31,2	+52,2	−20,5

* D_{perf} est externe au score architectural. ‡ Scores bruts ; D_{sync} est multiplié par 5/4 et D_{modal} par 4/3 pour le calcul de ARC_{arch}.

Table 6: Matrice de corrélations de Pearson entre les cinq dimensions ARC ($n = 66$).

	$\mathbf{D_{sync}}$	$\mathbf{D_{int}}$	$\mathbf{D_{topo}}$	$\mathbf{D_{modal}}$	$\mathbf{D_{perf}^{\star}}$
D_{sync}	1,00				
D_{int}	$0{,}43^{***}$	1,00			
D_{topo}	$0{,}48^{***}$	$0{,}44^{***}$	1,00		
D_{modal}	$0{,}44^{***}$	$0{,}40^{**}$	$0{,}52^{***}$	1,00	
D_{perf}	−0,17	−0,20	−0,05	−0,08	1,00

$^{***}p < 0{,}001$; $^{**}p < 0{,}01$.

5.5 Seuils critiques et efficacité des leviers

L'analyse logistique permet d'identifier les seuils dimensionnels et les contributions relatives de chaque dimension aux transitions architecturales. Pour la transition $N_1 \rightarrow N_2$, D_{sync} ($\beta = 1{,}68$) et D_{int} ($\beta = 1{,}71$) constituent les prédicteurs dominants à coefficients quasi-égaux, avec des seuils de Youden optimaux de $D_{sync} \geq 1{,}0$ ($J = 0{,}878$) et $D_{int} \geq 2{,}0$ ($J = 0{,}711$). Pour la transition $N_2 \rightarrow N_3$, la configuration se déplace vers D_{modal} ($\beta = 1{,}55$) et D_{sync} ($\beta = 1{,}34$), avec D_{topo} ($\beta = 0{,}99$) et D_{int} ($\beta = 0{,}92$) en appui. Les seuils de Youden pour cette transition sont $D_{sync} \geq 3{,}0$ ($J = 0{,}819$), $D_{modal} \geq 1{,}85$ ($J = 0{,}715$) et $D_{topo} \geq 2{,}0$ ($J = 0{,}632$). À titre d'indicateur interne de cohérence uniquement (les groupes et les données d'ajustement étant identiques, ces valeurs ne sauraient être interprétées comme des estimations de performance généralisable), le modèle logistique multinomial à quatre prédicteurs atteint une précision globale de 97,0% ($\kappa = 0{,}953$) sur le corpus d'entraînement. Une validation croisée ou une application sur corpus indépendant est nécessaire pour évaluer la généralisabilité de ces seuils. L'exigence asymétrique et élevée sur D_{sync} pour accéder à N_3 (75% du maximum, soit $\geq 3{,}0/4$) signale un saut qualitatif plutôt qu'une progression graduelle : la fenêtre de liaison temporelle de 100 ms constitue un seuil perceptif réel dont le franchissement modifie qualitativement le régime de traitement [92]. Les seuils de Youden obtenus ($D_{sync} \geq 3{,}0$, $D_{modal} \geq 1{,}85$) mettent en évidence le rôle de D_{modal} comme levier prépondérant de la transition $N_2 \rightarrow N_3$ ($\beta = 1{,}55$ vs $\beta_{sync} = 1{,}34$), résultat cohérent avec son AUC = 0,920 pour la détection de N_3.

La régression multiple de D_{int} sur D_{sync} et D_{modal} confirme leur contribution conjointe ($R^2 = 0{,}238$, $F(2, 63) = 9{,}83$, $p < 0{,}001$; $\beta_{std,sync} = 0{,}32$, $\beta_{std,modal} = 0{,}25$, tous deux $p < 0{,}001$) : la synchronisation temporelle et la sélection modale créent les conditions favorables à l'articulation sémantique, établissant un *prérequis temporel et modal* à l'orchestration complète.

5.6 Structure factorielle

L'analyse en composantes principales (ACP) sur les quatre dimensions architecturales fait apparaître deux facteurs principaux qui expliquent 74,4 % de la variance totale. Le test de sphéricité de Bartlett est significatif ($\chi^2(6) = 60{,}63$, $p < 0{,}001$) et l'indice KMO vaut 0,77, ce qui confirme l'adéquation de la matrice de corrélation à une analyse factorielle.

Le premier facteur (58,9 % de la variance) représente une *maturité architecturale globale* : les quatre dimensions y contribuent de façon équilibrée, indiquant que synchronisation, intégration sémantique, préservation structurelle et pertinence modale progressent ensemble. Le second facteur (15,6 %) oppose la cohérence informationnelle (D_{int}) à la richesse des canaux non verbaux (D_{topo} et D_{modal}). La dimension de performance (D_{perf}) n'est liée à aucun de ces deux facteurs, confirmant son indépendance. Enfin, les trois niveaux architecturaux (N1, N2, N3) occupent des régions bien séparées dans cet espace (ellipses de confiance à 95 % sans chevauchement).

6 Discussion

6.1 Logiques architecturales des trois niveaux

Les niveaux définis par ARC renvoient à des logiques d'orchestration fondamentalement distinctes. L'ampleur des écarts qui les séparent, mise en regard des régimes de traitement du modèle SRK [73], suggère l'existence d'une rupture qualitative plutôt que d'une simple gradation quantitative.

N_1 – Cumulatif (45,5 %) représente une logique d'accumulation sans intégration, que Norman nomme le *featurism* [65]. Cette logique illustre l'*illusion additive* introduite en section 1 : la coexistence de canaux est confondue avec leur orchestration. La quasi-absence de synchronisation ($D_{sync} = 0{,}12/4$, soit 3 % du maximum) signifie que les modalités coexistent dans le système sans coordination temporelle intentionnelle. Chaque canal impose ses propres exigences de traitement sans contribuer à une synthèse globale. Confronté à ce régime d'accumulation non coordonné, l'utilisateur est contraint d'opérer au niveau *connaissance* du modèle SRK (délibéré, contrôlé, coûteux en ressources), même pour des opérations qui devraient être automatisées. La persistance de ce régime dans 45,5 % du corpus ne traduit pas une contrainte technologique infranchissable, les solutions de synchronisation à faible latence étant disponibles, mais l'absence de cadres diagnostiques permettant aux concepteurs de mesurer et de cibler la qualité de l'orchestration.

N_2 – Articulé (27,3 %) reconnaît les besoins de coordination sans les satisfaire pleinement (D_{sync} = 2,17/4, soit 54 % du maximum). Des systèmes combinant des maquettes tactiles imprimées en 3D avec des messages vocaux déclenchés au toucher [62, 74] illustrent ce niveau intermédiaire : ils atteignent une coordination partielle qui réduit la charge extrinsèque par rapport à N_1, mais ils requièrent encore un pont cognitif entre modalités, maintenant l'utilisateur dans un fonctionnement au niveau *règle* du modèle SRK (semi-automatique, basé sur des heuristiques acquises) plutôt qu'au niveau *compétence* (automatique, pré-attentionnel).

N_3 – Orchestré (27,3 %) incarne l'ingénierie d'intégration perceptive : synchronisation temporelle quasi-maximale (D_{sync} = 92% du maximum) et richesse modale pleinement déployée (D_{modal} = 86% du maximum). Les résultats de l'ACP (section 5.6) montrent que l'orchestration n'est pas la somme d'optimisations indépendantes par dimension, mais un état systémique cohérent où synchronisation, intégration sémantique, préservation structurelle et pertinence modale progressent conjointement. Ce résultat suggère que l'orchestration est une propriété émergente du système, plutôt qu'un ensemble de paramètres ajustables indépendamment.

6.2 Le Rendement Cognitif Différentiel

Le découplage rapporté en section 5.4 — absence de variation significative de D_{perf} entre niveaux architecturaux, avec une trajectoire descriptive décroissante de N_1 à N_3 — appelle une interprétation théorique. Nous formalisons cette interprétation sous l'hypothèse du **Rendement Cognitif Différentiel** (RCD) : des systèmes architecturalement distincts produiraient des performances observables équivalentes tout en imposant des coûts cognitifs fondamentalement différents, ces coûts n'étant pas capturés par les métriques de performance conventionnelles. Il s'agit d'un *construit théorique* proposé pour expliquer un résultat empirique, non d'une mesure directe : sa validation requiert des protocoles expérimentaux dédiés (NASA-TLX, double-tâche, pupillométrie).

Le RCD ne relève pas d'une affirmation *ad hoc* : il s'ancre dans quatre mécanismes non mutuellement exclusifs, chacun documenté par des caractéristiques identifiables du corpus.

H1 – Insensibilité des mesures conventionnelles. Seulement 18,2 % (12/66) des études du corpus mesurent la charge cognitive de manière globale (incluant les échelles subjectives de type SUS ou évaluation d'effort) ; parmi celles-ci, 12,1 % (8/66) le font via le NASA-TLX standardisé, qui constitue la mesure la plus reproductible. La majorité des études s'appuie donc sur des méthodes subjectives plutôt que comportementales ou physiologiques. Des utilisateurs peuvent atteindre une précision identique avec un système N_3 et avec un système N_1. Dans le premier cas, les ressources cognitives préservées sont disponibles pour un traitement inférentiel élaboré ; dans le second, toutes les ressources sont mobilisées pour maintenir une coordination manuelle entre modalités. C'est une distinction fondamentale que les protocoles actuels ne peuvent pas détecter [84].

H2 – Effet plafond des tâches expérimentales. 71,2 % (47/66) des protocoles du corpus utilisent des tâches de complexité faible à modérée, avec un taux de réussite médian de 87 %. Ces tâches favorisent *structurellement* les systèmes N_1 : leur architecture simple génère des gains mesurables sur des tâches réduites, sans exposer le coût cognitif du maintien en mémoire de travail imposé par l'absence de synchronisation. Comme le montrent Gray et Boehm-Davis [34], optimiser les micro-performances sur des tâches simples masque les macro-inefficiences sur des tâches authentiques.

H3 – Biais de publication et conditions d'évaluation. 89,4 % des études du corpus rapportent des résultats globalement positifs. Les évaluations en conditions optimales – formation médiane de 2,5 heures, environnements contrôlés, participants hautement motivés – permettent aux participants de développer des stratégies compensatoires [73] qui occultent les défaillances d'orchestration. Les systèmes N_1 sont davantage présents dans des études évaluées dans ces conditions optimales et rapportant des gains nets sur des métriques simples.

H4 – Multidimensionnalité non capturée de l'efficience cognitive. Les systèmes N_3 pourraient exceller précisément sur les dimensions les moins souvent mesurées : seulement 13,6 % (9/66) des études mentionnent le transfert d'apprentissage, et 7,6 % (5/66) la rétention à plus de 24 heures. L'efficience cognitive – le rapport entre le bénéfice informationnel et le coût cognitif du traitement – ne se résume pas à la performance immédiate et n'est pas capturée par des métriques de complétion de tâche isolées.

6.3 Compromis coût–efficacité des architectures

Les recommandations G1–G5 exposées dans la section suivante impliquent des coûts d'ingénierie très différents selon le niveau visé ; le Tableau 7 synthétise, à partir des profils d'implémentation observés dans le corpus, les technologies typiques, coûts relatifs et compromis par niveau architectural. La transition $N_1 \rightarrow N_2$ offre un premier gain qualitatif pour un surcoût modéré ; $N_2 \rightarrow N_3$ promet des bénéfices cognitifs (hypothèse RCD) au prix d'un effort d'ingénierie non toujours justifié pour des contextes à faibles ressources. Les recommandations G1–G5 proposent ainsi des paliers progressifs selon les objectifs et ressources des concepteurs.

6.4 Principes de conception et évaluation

Les résultats empiriques et les hypothèses qui précèdent conduisent à cinq recommandations hiérarchisées, ordonnées selon leur efficacité discriminante (AUC et η^2). Ces cinq principes sont présentés dans l'ordre de priorité suggéré par les analyses (AUC et η^2) ; leur implémentation conjointe reste néanmoins préférable. Ils traduisent les seuils de transition quantifiés en prescriptions actionnables. Les hypothèses H2 (effet plafond des tâches) et H3 (biais de publication) expliquent pourquoi les protocoles actuels récompensent structurellement les architectures additives, ce qui motive en particulier la recommandation G5. Contrairement aux checkpoints binaires des normes WCAG ou Section 508, ces principes ne visent pas la conformité technique mais la qualité de l'orchestration perceptive, complétant ainsi les normes par une couche d'évaluation ergonomique centrée sur l'intégration temporelle et sémantique.

G1 – Primauté de la cohérence temporelle. D_{sync} est le différenciateur architectural primaire (η^2 = 0,739, AUC = 0,92, corrélation point-bisériale r = 0,857). Les systèmes N_1 n'atteignent en moyenne que 3 % du maximum de D_{sync}, contre 92 % pour N_3 (soit +88,7 points de pourcentage). La transition vers N_2 nécessite

Table 7: Coûts d'implémentation et compromis pour les trois niveaux architecturaux.

Niveau	Technologies typiques	Coût d'implémentation	Principaux compromis
N_1 (Cumulatif)	Synthèse vocale séquentielle, sorties audio uniquement, ou tactile statique (papier imprimé)	Très faible (logiciel standard, peu ou pas de matériel spécifique)	Aucune coordination temporelle ; charge cognitive élevée, mais déploiement immédiat et universel
N_2 (Articulé)	Bus OSC, WebAudio, API tactiles standard (vibrotactile), maquettes 3D avec étiquettes vocales	Faible à modéré (logiciels open source, matériel grand public)	Coordination partielle, charge cognitive significative, mais rapport coût/bénéfice favorable pour le prototypage
N_3 (Orchestré)	Dispositifs haptiques à retour de force, surfaces tactiles à haute résolution, audio spatialisé 3D, matériel sur mesure	Élevé (matériel coûteux, développement spécifique, parfois propriétaire)	Intégration perceptive maximale, mais investissement initial et courbe d'apprentissage techniques peuvent freiner l'adoption

de cibler $D_{sync} \geq 1{,}0$ et $D_{int} \geq 2{,}0$. En pratique, mettre en œuvre la synchronisation via une architecture événementielle à bus de messages unique (protocole OSC, API WebAudio avec ordonnancement précis), mesurer et documenter les latences inter-modales dès les premières itérations, et ne jamais supposer qu'une synchronisation apparente en laboratoire résistera à la charge réelle constituent des solutions typiques du niveau N_2, dont le rapport coût/bénéfice est discuté dans le Tableau 7.

G2 – Sélection des modalités par compatibilité cognitive. $_{modal}$ est le second levier ($\eta^2 = 0{,}481$, AUC = 0,92). Les systèmes N_1 n'exploitent que 34 % du maximum de D_{modal}, contre 86 % pour N_3 (soit +52,2 %). La prescription est de combiner des modalités de nature différente – canal auditif verbal et canal tactile spatial – conformément au modèle des ressources multiples [97]. Le recours massif à la synthèse vocale pour des contenus spatiaux constitue un défaut ergonomique caractéristique : le canal verbal-temporel séquentiel est inadapté aux relations spatiales simultanées, et son usage massif force l'utilisateur à des transformations mentales que l'interface devrait assumer. La sonification paramétrique est une alternative plus compatible, permettant un traitement parallèle à la parole [91]. G1 et G2 entretiennent une relation de conditionnement mutuel : synchronisation temporelle et richesse modale progressent conjointement dans le corpus ($r = 0{,}44$, $p < 0{,}001$).

G3 – Préservation explicite de la structure informationnelle. D_{topo} présente l'AUC la plus élevée après G1 et G2 (AUC = 0,89). Même les systèmes N_3 n'atteignent que 76 % du maximum de D_{topo} : c'est la dimension avec la plus grande marge de progression, et donc une frontière de recherche active. La prescription est d'identifier, avant l'implémentation, les relations structurelles critiques (ordre, hiérarchie, proximité, symétrie) et de choisir les modalités les plus aptes à les préserver – surfaces tactiles multi-points pour la topologie 2D, audio spatialisé pour les relations directionnelles [46]. La transition vers N_3 requiert une préservation topologique explicite et documentée.

G4 – Viser la cohérence informationnelle synergique. D_{int} présente le quatrième AUC (AUC = 0,84) ; la transition $N_2 \rightarrow N_3$ requiert $D_{int} \geq 3{,}0$, correspondant à une intégration synergique explicitement documentée. Il est recommandé de documenter la stratégie d'intégration *avant* l'implémentation (plutôt que a posteriori), en explicitant pourquoi chaque modalité véhicule l'information assignée et non ce que l'autre canal transmet déjà. Il faut éviter la redondance totale (même information dans deux canaux) qui double la charge perceptive sans enrichissement [56], et viser une distribution complémentaire intentionnelle.

G5 – Refonte des protocoles d'évaluation. Les protocoles d'évaluation actuels tendent à favoriser structurellement les architectures les moins sophistiquées, en raison de deux biais cumulatifs. Le premier est un biais de tâche : 71,2 % des protocoles utilisent des tâches de complexité faible à modérée (dont 47,0 % explicitement codées comme faible), avec un taux de réussite médian de 87 %. Le second est un biais de condition : les évaluations se déroulent en conditions optimales, avec une formation médiane de 2,5 heures et dans des environnements contrôlés. Ces limitations suggèrent la nécessité d'une refonte des protocoles selon quatre axes prioritaires.

Le premier axe, la triangulation méthodologique, consiste à combiner des mesures subjectives (NASA-TLX), comportementales (double-tâche) et physiologiques (pupillométrie, variabilité de la fréquence cardiaque) afin de mieux capturer la charge cognitive réelle. Le deuxième axe, la complexité échelonnée, recommande l'inclusion de tâches authentiques telles que l'analyse de graphes réalistes, la comparaison multi-critères ou la navigation hiérarchique, capables de saturer la mémoire de travail. Le troisième axe concerne l'évaluation du transfert et de la rétention, en mesurant l'apprentissage transféré, la rétention à moyen terme ainsi que la fatigue cognitive cumulée dans des contextes écologiques et longitudinaux. Enfin, le quatrième axe, la standardisation progressive, vise à établir un ensemble minimal de mesures recommandées pour assurer la comparabilité et faciliter l'accumulation de connaissances entre études. Le Tableau 8 synthétise, pour chaque niveau de maturité, les priorités d'action et les cibles dimensionnelles à atteindre pour guider le progrès méthodologique.

6.5 Limites et perspectives

Cette étude présente plusieurs limites méthodologiques qu'il convient de prendre en compte pour interpréter les résultats et qui dessinent un agenda de recherche. La première concerne la circularité et l'absence de validation externe : les pondérations ont été définies sur un sous-ensemble de 20 systèmes et l'analyse descriptive réalisée sur 66, sans corpus indépendant. Les effectifs, seuils (6,0 ; 10,5) et tailles d'effet (η^2, d de Cohen) reflètent ainsi des propriétés internes de ce corpus et ne peuvent être généralisés à l'ensemble des systèmes multimodaux. Cette circularité, assumée dans une approche descriptive, interdit toute conclusion confirmatoire. Une validation indépendante, appliquant ARC sans modification des pondérations sur un nouveau corpus de systèmes d'accessibilité des STEM et documentant les ICC inter-évaluateurs obtenus, est nécessaire pour évaluer la réplicabilité des seuils (6,0 et 10,5 points)

Table 8: Trajectoires d'amélioration par niveau : priorités d'action, cibles dimensionnelles et seuils de transition.

Niveau	Priorités d'action	Cibles et transitions
$\mathbf{N_1}$	1. G1 : synchronisation automatique dès le déclenchement coordonné	**Cibles de transition ($\mathbf{N_2}$)** :
< 6 pts	2. G2 : diversifier au-delà de la parole dominante	$D_{sync} \geq 1{,}0$
	3. Mesurer les latences inter-modales dès maintenant	$D_{int} \geq 2{,}0$
$\mathbf{N_2}$	1. G1 : atteindre la latence imperceptible ($\leq$ 100 ms mesurés)	**Cibles de transition ($\mathbf{N_3}$)** :
6–10,5	2. G2 : richesse modale complète (tactile + son + parole)	$D_{sync} \geq 3{,}0$
	3. G3 : préservation topologique explicite	$D_{modal} \geq 1{,}85$
	4. G4 : documenter la stratégie d'intégration avant implémentation	$D_{topo} \geq 2{,}0$
$\mathbf{N_3}$	G5 : investir dans l'évaluation cognitive approfondie	NASA-TLX + double-tâche + transfert
$\geq 10{,}5$		structurel + rétention : valider le RCD

et la stabilité des recommandations G1–G5 issues de ce corpus. Les analyses de robustesse avec pondérations égales suggèrent que le découplage architecture-performance n'est pas un artefact, mais ne remplacent pas une validation externe.

La deuxième limite concerne l'inférence causale : la nature rétrospective du codage ne permet que des relations associatives entre propriétés architecturales et performances mesurées, sans déterminer de direction causale. La validation expérimentale du *Rendement Cognitif Différentiel* constitue une priorité, afin de tester si des systèmes architecturés différemment imposent des coûts cognitifs distincts, indépendamment de leur performance brute. Des tâches de complexité croissante combinant mesures de performance et de charge cognitive (NASA-TLX, double-tâche, pupillométrie) fournissent un cadre approprié.

Troisièmement, des effets de halo et des biais de codage peuvent influencer les corrélations modérées observées entre dimensions et affecter légèrement les estimations de fidélité inter-codeurs. L'extension du protocole à d'autres domaines d'accessibilité avec des équipes de codeurs indépendantes permettrait d'évaluer la robustesse de la grille au-delà du corpus STEM. La règle conservative de codage (assignation des cas ambigus au niveau inférieur) peut systématiquement déflater les scores absolus et influencer les seuils de transition, mais elle préserve la validité des comparaisons relatives et renforce la robustesse des recommandations.

Quatrièmement, l'analyse temporelle est limitée par la répartition inégale des publications dans le temps. La validité externe est également restreinte par la composition du corpus (publications anglophones évaluées par les pairs, excluant la littérature grise et les travaux non anglophones) et par un biais de publication en faveur de résultats positifs. Le déséquilibre de contenu du corpus (mathématiques largement majoritaires par rapport aux modèles 3D) soulève par ailleurs la question de la sensibilité des pondérations au type de contenu : D_{topo}, actuellement la dimension la moins pondérée (3 points, 18,8 %), pourrait sous-estimer son importance relative pour des contenus intrinsèquement spatiaux (modèles 3D, diagrammes complexes) par rapport à des contenus symboliques comme les formules mathématiques, où sa contribution reste structurellement plus limitée. Une pondération différenciée par type de contenu (par exemple un poids accru pour D_{topo} sur des corpus à dominante 3D) constitue une piste de raffinement à explorer, sans remettre en cause la validité des pondérations uniformes comme référence générale assurant la comparabilité inter-études. Des études longitudinales en contexte réel et l'application du cadre à des corpus variés permettraient d'évaluer la généralisabilité d'ARC et de documenter la fatigue cognitive cumulée.

Enfin, l'application d'une ACP à des données ordinales constitue une approximation ; une ACP polychorique serait plus strictement appropriée. Néanmoins, les structures corrélationnelles observées sont cohérentes avec la matrice de corrélations ordinales (Tableau 6), renforçant leur robustesse interprétative. Un agenda méthodologique complémentaire consisterait à développer des versions du cadre adaptées à des métriques continues.

6.6 Perspectives de recherche

Les limites identifiées dessinent un programme de recherche structuré autour de trois priorités complémentaires. La première consiste en la validation expérimentale du Rendement Cognitif Différentiel (RCD), visant à déterminer si des systèmes architecturalement distincts génèrent des coûts cognitifs différents indépendamment de leur performance brute, en utilisant des tâches de complexité croissante combinant mesures de performance, évaluation de la charge cognitive (NASA-TLX, double-tâche, pupillométrie) et tests de transfert. La deuxième priorité porte sur le développement de protocoles multi-métriques standardisés, définissant un ensemble minimal de mesures (performance, charge cognitive, transfert, rétention) afin de favoriser la comparabilité et l'accumulation de connaissances entre études, en s'appuyant sur des cadres méthodologiques partagés. Enfin, la troisième priorité vise l'extension longitudinale et inter-domaines : appliquer le cadre ARC à d'autres champs de l'accessibilité, tels que la mobilité, et mener des études en contexte réel pour documenter la fatigue cognitive cumulée et tester la généralisabilité des seuils de transition. En résumé, ces perspectives ne remettent pas en cause la pertinence descriptive d'ARC mais appellent à un effort coordonné pour valider expérimentalement le RCD, standardiser les mesures multi-métriques, et étendre le cadre de manière longitudinale et à l'inter-domaines - afin d'éprouver la robustesse et la généralisabilité des seuils et recommandations.

7 Conclusion

Cet article est parti d'un paradoxe persistant : en accessibilité STEM non visuelle, l'accumulation de modalités n'améliore pas

mécaniquement l'accessibilité cognitive. Le cadre ARC met en évidence un *découplage* systématique entre sophistication architecturale et performance mesurée. Ce résultat donne une base cohérente à l'hypothèse du *Rendement Cognitif Différentiel* (RCD) : les protocoles d'évaluation actuels, centrés sur la complétion de tâche, restent structurellement aveugles à l'efficience cognitive réelle.

ARC apporte trois contributions concrètes et articulées. Il fournit d'abord un protocole de diagnostic reproductible (ICC > 0,85) pour caractériser objectivement la maturité multimodale. Il identifie ensuite trois régimes architecturaux distincts — Cumulatif, Articulé, Orchestré — et révèle leurs seuils de transition qualitatifs, offrant ainsi une trajectoire de conception hiérarchisée et actionnable. Enfin, en isolant la performance comme variable externe, il invite à une refonte nécessaire des pratiques évaluatives, intégrant des mesures de charge cognitive, de transfert et de rétention.

Ces résultats, descriptifs, appellent une validation expérimentale et longitudinale du RCD en conditions écologiques. ARC ne plaide pas seulement pour de meilleures interfaces, mais pour une métrique plus honnête de leur qualité : non pas « est-ce que cela fonctionne ? », mais « à quel coût cognitif cela fonctionne-t-il ? ».

8 Utilisation de l'IA générative

Des outils d'IA générative (Claude et Gemini) ont été utilisés pour reformuler certains passages du manuscrit afin d'en améliorer la clarté, ainsi que pour identifier et corriger des erreurs dans les scripts d'analyse. Les auteurs ont relu et vérifié toutes les suggestions produites, et restent pleinement responsables du contenu de l'article (idées, analyses, interprétations, méthodes et résultats).

Acknowledgements

Ce travail s'inscrit dans le projet COOBRA (Coopération entre voyants et déficients visuels braillistes pour apprendre et travailler ensemble), financé par l'Agence Nationale de la Recherche (ANR) au titre du programme Science avec et pour la Société – Recherches participatives 2 (SAPS-RA-RP2), sous la référence ANR-24-SARP-0006. Les auteurs remercient le LABEX ASLAN (ANR-10-LABX-0081) de l'Université de Lyon pour son soutien financier dans le cadre du programme français "Investissements d'Avenir" géré par l'Agence Nationale de la Recherche.

References

[1] R. Agustina, N. Farida, and M. Irfan. 2024. Learning mathematics outcomes using android for blind students based on newman's theory. *Journal of education and learning (edulearn)* 18, 3 (2024), 1056–1065. doi:10.11591/edulearn.v18i3.21454

[2] D. Ahmetovic, V. Alampi, C. Bernareggi, A. Gerino, and S. Mascetti. 2017. Math melodies: supporting visually impaired primary school students in learning math. In *Proceedings of the web for all conference (w4a '17)*. ACM, Perth, Australia, 1–2. doi:10.1145/3058555.3058583

[3] M. Z. I. Alam, S. Islam, and E. Hoque. 2023. Seechart: enabling accessible visualizations through interactive natural language interface for people with visual impairments. In *28th international conference on intelligent user interfaces (iui '23)*. ACM, New York, NY, USA, 46–64. doi:10.1145/3581641.3584099

[4] K. Anderer, K. Müller, L. Strobel, M. Wölfel, J. Niehues, and K. Gerling. 2025. Making lecture videos accessible for students who are blind or have low vision through ai-assisted navigation and visual question answering. In *The 27th international acm sigaccess conference on computers and accessibility (assets '25)*. ACM, New York, NY, USA, 1–15. doi:10.1145/3663547.3746349

[5] Safa Arooj, Shaban Zulfiqar, Muhammad Qasim Hunain, Suleman Shahid, and Asim Karim. 2020. Web-alap: a web-based latex editor for blind individuals. In *Assets '20: the 22nd international acm sigaccess conference on computers and accessibility*. ACM, New York, NY, USA, 1–6. doi:10.1145/3373625.3417009

[6] Alan D. Baddeley. 2000. The Episodic Buffer: A New Component of Working Memory? *Trends in Cognitive Sciences* 4, 11 (2000), 417–423. doi:10.1016/S1364-6613(00)01538-2

[7] P. F. Balestrucci, E. Di Nuovo, M. Sanguinetti, L. Anselma, C. Bernareggi, and A. Mazzei. 2024. An educational dialogue system for visually impaired people. *Ieee access* 12 (2024), 150502–150519. doi:10.1109/ACCESS.2024.3479883

[8] J. M. Christian Bastien and Dominique L. Scapin. 1997. Ergonomic Criteria for Evaluating the Ergonomic Quality of Interactive Systems. *Behaviour & Information Technology* 16, 4-5 (1997), 220–231. doi:10.1080/014492997119806

[9] C. R. Beal and L. P. Rosenblum. 2018. Evaluation of the effectiveness of a tablet computer application (app) in helping students with visual impairments solve mathematics problems. *Journal of visual impairment & blindness* 112, 1 (2018), 5–19. doi:10.1177/0145482X1811200102

[10] John Brooke. 1996. SUS: A 'Quick and Dirty' Usability Scale. In *Usability Evaluation in Industry*, Patrick W. Jordan, Bruce Thomas, Ian L. McClelland, and Bernard Weerdmeester (Eds.). CRC Press, London, 4–7. doi:10.1201/9781498710411-35

[11] J. R. Brown, S. A. Doore, J. K. Dimmel, N. Giudice, and N. A. Giudice. 2023. Comparing natural language and vibro-audio modalities for inclusive stem learning with blind and low vision users. In *The 25th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS '23)*. ACM, New York, NY, USA, Article 12, 17 pages. doi:10.1145/3597638.3608429

[12] Emeline Brulé, Brianna J. Tomlinson, Oussama Metatla, Christophe Jouffrais, and Marcos Serrano. 2020. Review of Quantitative Empirical Evaluations of Technology for People with Visual Impairments. In *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems (CHI '20)*. ACM, New York, NY, USA, Article 290, 13 pages. doi:10.1145/3313831.3376749

[13] Matthew Butler, Leona M. Holloway, Samuel Reinders, Cağatay Goncu, and Kim Marriott. 2021. Technology Developments in Touch-Based Accessible Graphics: A Systematic Review of Research 2010–2020. In *Proceedings of the CHI Conference on Human Factors in Computing Systems (CHI '21)*. ACM, New York, NY, USA, Article 278, 15 pages. doi:10.1145/3411764.3445207

[14] W. Chinthaka and P. Abeygunawardhana. 2018. Cbeyond: mathematical learning tool for primary level visual impaired students. In *2018 13th International Conference on Computer Science & Education (ICCSE)*. IEEE, Colombo, Sri Lanka, 1–5. doi:10.1109/ICCSE.2018.8468805

[15] Kiroong Choe and Jinwook Seo. 2019. Compatible 2d table navigation system for visually impaired users. In *Proceedings of the 2019 ACM International Conference on Interactive Surfaces and Spaces (ISS '19)*. ACM, New York, NY, USA, 347–350. doi:10.1145/3343055.3360749

[16] J. Choi, S. Jung, D. G. Park, J. Choo, and N. Elmqvist. 2019. Visualizing for the non-visual: enabling the visually impaired to use visualization. *Computer Graphics Forum* 38, 3 (2019), 249–260. doi:10.1111/cgf.13686

[17] Joëlle Coutaz, Laurence Nigay, Daniel Salber, Ann Blandford, Jon May, and Richard M. Young. 1995. Four Easy Pieces for Assessing the Usability of Multimodal Interaction: The CARE Properties. In *Human–Computer Interaction: INTERACT '95*. Springer, Boston, MA, 115–120. doi:10.1007/978-1-5041-2896-4_19

[18] Luiz Felipe da Paixão Silva, Antônio Armando de O. Barbosa, Evelise Roman Corbalan Góis Freire, Paula Christina Figueira Cardoso, Rafael Serapilha Durelli, and André Pimenta Freire. 2018. Content-Based Navigation Within Mathematical Formulae on the Web for Blind Users and Its Impact on Expected User Effort. In *Proceedings of the 8th International Conference on Software Development and Technologies for Enhancing Accessibility and Fighting Info-exclusion*. ACM, New York, NY, USA, 23–32. doi:10.1145/3218585.3218596

[19] P. Damsma. 2025. Hearing a circle: an exploratory study of accessible sonification for young children with blindness and low vision. *British journal of visual impairment* 43, 3 (2025), 597–616. doi:10.1177/02646196241253534

[20] Alex Santos de Oliveira, Bruno Merlin, Heleno Fülber, João Elias Vidueira Ferreira, and Tatiana Nazaré de Carvalho Artur Barros. 2017. Quimivox mobile: assistive tool to teach mendeleev table. In *Universal Access in Human–Computer Interaction. Human and Technological Environments (Lecture Notes in Computer Science, Vol. 10279)*. Springer, Cham, 188–197. doi:10.1007/978-3-319-58700-4_16

[21] Cynthya Letícia Teles de Oliveira, Alan Trindade De Almeida Silva, Jefferson Magalhães de Morais, and Marcelle Pereira Mota. 2023. Accessible bar charts through textual description templates. *Journal of the brazilian computer society* 29, 1 (2023), 1–18. doi:10.5753/jbcs.2023.2301

[22] Stacy A. Doore, Justin Dimmel, Toni M. Kaplan, Benjamin A. Guenther, and Nicholas A. Giudice. 2023. Multimodality as Universality: Designing Inclusive Accessibility to Graphical Information. *Frontiers in Education* 8 (2023), 1071759. doi:10.3389/feduc.2023.1071759

[23] K. Dumkasem, P. Srisingchai, and P. Rattanatamrong. 2019. Eyemath: increasing accessibility of mathematics to visually impaired readers. In *2019 23rd International Computer Science and Engineering Conference (ICSEC)*. IEEE, Phuket, Thailand, 197–202. doi:10.1109/ICSEC47112.2019.8974682

[24] Ewa Dzierzgowska, Michał Maćkowski, Mateusz Kawulok, Piotr Brzoza, Sylwia Maćkowska, and Dominik Spinczyk. 2025. Alternative audio-graphic method for presenting structural information in mathematical graphs designed for low-vision users. *Scientific reports* 15 (2025), 21972. doi:10.1038/s41598-025-07710-2

[25] C. Engel, N. Konrad, and G. Weber. 2020. Touchpen: rich interaction technique for audio-tactile charts by means of digital pens. In *International conference on computers helping people with special needs*, Vol. 12376. Springer, Cham, 446–455. doi:10.1007/978-3-030-58796-3_52

[26] Marc O. Ernst and Martin S. Banks. 2002. Humans Integrate Visual and Haptic Information in a Statistically Optimal Fashion. *Nature* 415 (2002), 429–433. doi:10.1038/415429a

[27] D. Fitzpatrick, A. Nazemi, and G. Terlikowski. 2020. Euromath: a web-based platform for teaching of accessible mathematics. In *International Conference on Computers Helping People with Special Needs (ICCHP) (Lecture Notes in Computer Science, Vol. 12376)*. Springer, Cham, 385–392. doi:10.1007/978-3-030-58796-3_45

[28] G. Foran, J. Cooke, and J. Hannam. 2022. The power of listening to your data: opening doors and enhancing discovery using sonification. *Revista Mexicana de Astronomía y Astrofísica Serie de Conferencias* 54 (2022), 1–8. doi:10.22201/ia.14052059p.2022.54.01

[29] Waka Fujisaki, Shinsuke Shimojo, Makio Kashino, and Shin'ya Nishida. 2004. Recalibration of Audiovisual Simultaneity. *Nature Neuroscience* 7, 7 (2004), 773–778. doi:10.1038/nn1268

[30] Salvatore Gatto, Ombretta Gaggi, Luca Grosset, and Lucrezia Guiotto Nai Fovino. 2024. Accessible mathematics: representation of functions through sound and touch. *IEEE Access* 12 (2024), 121552–121569. doi:10.1109/access.2024.3448509

[31] Nicholas A. Giudice. 2018. Navigating without Vision: Principles of Blind Spatial Cognition. In *Handbook of Behavioral and Cognitive Geography*, Daniel R. Montello (Ed.). Edward Elgar Publishing, Cheltenham, UK, Chapter 15, 260–288. doi:10.4337/9781784717544.00024

[32] C. Goncu and K. Marriott. 2015. Gracalc: an accessible graphing calculator. In *Proceedings of the 17th International ACM SIGACCESS Conference on Computers & Accessibility (ASSETS '15)*. ACM, New York, NY, USA, 311–312. doi:10.1145/2700648.2811353

[33] J. Gorniak, D. Wei, Y. Kim, and N.W. Kim. 2024. Vizability: enhancing chart accessibility with llm-based conversational interaction. In *The 37th annual acm symposium on user interface software and technology (uist '24)*. ACM, New York, NY, USA, 1–19. doi:10.1145/3654777.3676414

[34] Wayne D. Gray and Deborah A. Boehm-Davis. 2000. Milliseconds Matter: An Introduction to Microstrategies and to Their Use in Describing and Predicting Interactive Behavior. *Journal of Experimental Psychology: Applied* 6, 4 (2000), 322–335. doi:10.1037/1076-898X.6.4.322

[35] William Grussenmeyer and Eelke Folmer. 2016. Audiodraw: user preferences in non-visual diagram drawing for touchscreens. In *Proceedings of the 13th International Web for All Conference (W4A '16)*. ACM, New York, NY, USA, Article 22, 8 pages. doi:10.1145/2899475.2899483

[36] L. Guiotto Nai Fovino, A. Zanella, L. Di Mascolo, M. Ginolfi, N. Carpita, F. Trovato Manuncola, and M. Grassi. 2024. Evaluating the effectiveness of sonification in science education using edukoi. *Personal and ubiquitous computing* 28, 5 (2024), 693–711. doi:10.1007/s00779-024-01809-5

[37] C. Gunnarsson, J. Hammenberg, K. Bornemalm, and K. Rassmus-Gröhn. 2018. Automation of audio descriptions of large bar charts for persons with visual impairment: prototyping and proof of concept. *Technology and disability* 30, 1-2 (2018), 53–62. doi:10.3233/tad-170181

[38] Sandra G. Hart and Lowell E. Staveland. 1988. Development of NASA-TLX (Task Load Index): Results of Empirical and Theoretical Research. In *Human Mental Workload*, Peter A. Hancock and Najmedin Meshkati (Eds.). Advances in Psychology, Vol. 52. North-Holland, Amsterdam, 139–183. doi:10.1016/S0166-4115(08)62386-9

[39] Md Naimul Hoque, Md Ehtesham-Ul-Haque, Niklas Elmqvist, and Syed Masum Billah. 2023. Accessible data representation with natural sound. In *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems (CHI '23)*. ACM, New York, NY, USA, Article 826, 19 pages. doi:10.1145/3544548.3581087

[40] C. Jung, S. Mehta, A. Kulkarni, Y. Zhao, and Y.-S. Kim. 2022. Communicating visualizations without visuals: investigation of visualization alternative text for people with visual impairments. *Ieee transactions on visualization and computer graphics (tvcg)* 28, 1 (2022), 1095–1105. doi:10.1109/TVCG.2021.3114846

[41] E. Kim, C. Onweller, and K. F. Mccoy. 2021. Information graphic summarization using a collection of multimodal deep neural networks. In *Proceedings of the 25th International Conference on Pattern Recognition (ICPR)*. IEEE, Milan, Italy, 10188–10195. doi:10.1109/ICPR48806.2021.9412146

[42] Barbara Kitchenham. 2004. *Procedures for Performing Systematic Reviews*. Technical Report TR/SE-0401. Keele University.

[43] Terry K. Koo and Mae Y. Li. 2016. A Guideline of Selecting and Reporting Intraclass Correlation Coefficients for Reliability Research. *Journal of Chiropractic Medicine* 15, 2 (2016), 155–163. doi:10.1016/j.jcm.2016.02.012

[44] R. Kruger, F. De Wet, and T. Niesler. 2020. Interactive image exploration for visually impaired readers using audio-augmented touch gestures. In *2020 24th international conference information visualisation (iv)*. IEEE, Melbourne, Australia, 544–549. doi:10.1109/IV51561.2020.00093

[45] R. Kruger, F. De Wet, and T. Niesler. 2023. Mathematical content browsing for print-disabled readers based on virtual-world exploration and audio-visual sensory substitution. *Acm transactions on accessible computing* 16, 2 (2023), 1–27. doi:10.1145/3584365

[46] Jill H. Larkin and Herbert A. Simon. 1987. Why a Diagram Is (Sometimes) Worth Ten Thousand Words. *Cognitive Science* 11, 1 (1987), 65–100. doi:10.1111/j.1551-6708.1987.tb00863.x

[47] Nilli Lavie. 2010. Attention, Distraction, and Cognitive Control Under Load. *Current Directions in Psychological Science* 19, 3 (2010), 143–148. doi:10.1177/0963721410370295

[48] Jonathan Lazar, Daniel F. Goldstein, and Anne Taylor. 2015. *Ensuring Digital Accessibility through Process and Policy*. Morgan Kaufmann, Waltham, MA. doi:10.1016/C2013-0-13367-3

[49] H.-N. Lee and V. Ashok. 2022. Customizable tabular access to web data records for convenient low-vision screen magnifier interaction. *Acm transactions on accessible computing* 15, 2, Article 14 (2022), 22 pages. doi:10.1145/3517044

[50] Seonghee Lee, Maho Kohga, Steve Landau, Sile O'Modhrain, and Hari Subramonyam. 2024. Altcanvas: a tile-based editor for visual content creation with generative ai for blind or visually impaired people. In *The 26th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS '24)*. ACM, New York, NY, USA, 1–22. doi:10.1145/3663548.3675600

[51] C. Loitsch, K. Muller, S. Seifermann, J. Henß, S. Krach, G. Jaworek, and R. Stiefelhagen. 2018. Uml4all syntax – a textual notation for uml diagrams. In *International conference on computers helping people with special needs (icchp) (Lecture Notes in Computer Science, Vol. 10896)*. Springer, Cham, 598–605. doi:10.1007/978-3-319-94277-3_93

[52] Julia Loitzenbauer and Mandy Keck. 2024. A screen reader and sonification approach for non-sighted users to explore data visualizations on the internet. In *2024 1st IEEE Workshop on Accessible Data Visualization (AccessViz)*. IEEE, Tampa, FL, USA, 19–23. doi:10.1109/AccessViz64636.2024.00009

[53] Tonja-Katrin Machulla, Massimiliano Di Luca, and Marc O. Ernst. 2016. The consistency of crossmodal synchrony perception across the visual, auditory, and tactile senses. *Journal of Experimental Psychology: Human Perception and Performance* 42, 7 (2016), 1026–1038. doi:10.1037/xhp0000191

[54] S. Mascetti, A. Gerino, C. Bernareggi, and L. Picinali. 2017. On the evaluation of novel sonification techniques for non-visual shape exploration. *Acm transactions on accessible computing* 9, 4, Article 13 (2017), 28 pages. doi:10.1145/3046789

[55] J. Matousek, Z. Krňoul, M. Campr, Z. Zajic, Z. Hanzlíček, M. Grüber, and M. Kocurová. 2020. Speech and web-based technology to enhance education for pupils with visual impairment. *Journal on multimodal user interfaces* 14 (2020), 219–230. doi:10.1007/s12193-020-00323-1

[56] Richard E. Mayer. 2020. *Multimedia Learning* (3rd ed.). Cambridge University Press, Cambridge. doi:10.1017/9781316941355

[57] Catherine Mei, Josh Pollock, Daniel Hajas, Jonathan Zong, and Arvind Satyanarayan. 2025. Benthic: perceptually congruent structures for accessible charts and diagrams. In *Proceedings of the 27th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS '25)*. ACM, New York, NY, USA, 1–17. doi:10.1145/3663547.3746342

[58] Dariusz Mikulowski. 2022. Support for teaching mathematics of the blind by sighted tutors through multisensual access to formulas with braille converters and speech. In *30th acm international conference on multimedia (mm '22)*. ACM, New York, NY, USA, 1552–1560. doi:10.1145/3503161.3548425

[59] P. Mishra, S. Kumar, M.K. Chaube, and U. Shrawankar. 2022. Chartvi: charts summarizer for visually impaired. *Journal of computer languages* 69 (2022), 101107. doi:10.1016/j.cola.2022.101107

[60] Ye Mo, Gang Huang, Liangcheng Li, Dazhen Deng, Zhi Yu, Yilun Xu, Kai Ye, Sheng Zhou, and Jiajun Bu. 2025. Tablenarrator: making image tables accessible to blind and low vision people. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems (CHI '25)*. ACM, New York, NY, USA, 1–17. doi:10.1145/3706598.3714329

[61] M. R. Morris, J. Johnson, C. L. Bennett, and E. Cutrell. 2018. Rich representations of visual content for screen reader users. In *2018 chi conference on human factors in computing systems*. ACM, New York, NY, USA, 1–11. doi:10.1145/3173574.3173633

[62] Ruth Galan Nagassa, Andre Ky Pham, Matthew Butler, Leona Holloway, Kalin Stefanov, Skye de Vent, and Kim Marriott. 2025. Enhancing Tactile Learning: A Co-Designed System for Supporting Speech Interaction with Multi-Part 3D Printed Models by Students who are Blind. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems (CHI '25)*. ACM, New York, NY, USA, Article 294, 18 pages. doi:10.1145/3706598.3713706

[63] Robert C. Nickerson, Upkar Varshney, and Jan Muntermann. 2013. A Method for Taxonomy Development and Its Application in Information Systems. *European Journal of Information Systems* 22, 3 (2013), 336–359. doi:10.1057/ejis.2012.26

[64] Laurence Nigay and Joëlle Coutaz. 1993. A Design Space for Multimodal Systems: Concurrent Processing and Data Fusion. In *Proceedings of the INTERACT and CHI Conference*. ACM, New York, NY, USA, 172–178. doi:10.1145/169059.169143

[65] Donald A. Norman. 2013. *The Design of Everyday Things* (revised and expanded edition ed.). Basic Books, New York.

[66] J. Onishi, T. Sakai, M. Sakajiri, A. Ogata, T. Miura, T. Handa, T. Shimizu, and T. Ono. 2016. Auto-assisting figure presentation system for inclusion education. In *2016 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*.

IEEE, Budapest, Hungary, 176–181. doi:10.1109/SMC.2016.7844238
[67] Sharon Oviatt. 1999. Ten Myths of Multimodal Interaction. *Commun. ACM* 42, 11 (1999), 74–81. doi:10.1145/319382.319398
[68] G. Pedemonte, M. Leotta, and M. Ribaudo. 2025. Improving web accessibility with an llm-based tool: a preliminary evaluation for stem images. *Ieee access* 13 (2025), 107566–107582. doi:10.1109/ACCESS.2025.3577519
[69] Emma C. Pender and John J. Healy. 2022. Accessible circuit diagrams. In *2022 33rd Irish Signals and Systems Conference (ISSC)*. IEEE, Cork, Ireland, 1–6. doi:10.1109/issc55427.2022.9826152
[70] Z. P. Putra and D. Setiawan. 2024. Representation of negative numbers: point estimation tasks using multi-reference sonification mappings. *Peerj computer science* 10 (2024), e2275. doi:10.7717/peerj-cs.2275
[71] Z. P. Putra, D. Setiawan, B. Priambodo, Y. Jumaryadi, and M. D. Anasanti. 2020. Multi-touch gesture of mobile auditory device for visually impaired users. In *2020 2nd International Conference on Broadband Communications, Wireless Sensors and Powering (BCWSP)*. IEEE, Yogyakarta, Indonesia, 90–95. doi:10.1109/BCWSP50066.2020.9249457
[72] A. Radecki, M. Bujacz, P. Skulimowski, and P. Strumillo. 2020. Interactive sonification of images in serious games as an education aid for visually impaired children. *British journal of educational technology* 51, 2 (2020), 473–497. doi:10.1111/bjet.12852
[73] Jens Rasmussen. 1983. Skills, Rules, and Knowledge; Signals, Signs, and Symbols, and Other Distinctions in Human Performance Models. *IEEE Transactions on Systems, Man, and Cybernetics* 13, 3 (1983), 257–266. doi:10.1109/TSMC.1983.6313160
[74] Samuel Reinders, Matthew Butler, and Kim Marriott. 2025. "It Brought the Model to Life": Exploring the Embodiment of Multimodal I3Ms for People who are Blind or have Low Vision. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems (CHI '25)*. ACM, New York, NY, USA, Article 367, 19 pages. doi:10.1145/3706598.3713158
[75] Madjid Sadallah and Benoît Encelle. 2026. Beyond Additive Design: An Empirical Taxonomy of Multimodal STEM Accessibility Systems. In *Proceedings of the Extended Abstracts of the 2026 CHI Conference on Human Factors in Computing Systems (CHI EA '26)*. Association for Computing Machinery, New York, NY, USA, Article 119, 6 pages. doi:10.1145/3772363.3799343
[76] Madjid Sadallah and Benoît Encelle. 2026. Systematic Review Protocol: Interactive Digital Technologies for Non-Visual Access to 2D STEM Content by Blind and Low-Vision Individuals. doi:10.5281/zenodo.21137716
[77] J. Seo, S. S. Kamath, A. Zeidieh, S. Venkatesh, and S. Mccurry. 2024. Maidr meets ai: exploring multimodal llm-based data visualization interpretation by and with blind and low-vision users. In *The 26th international acm sigaccess conference on computers and accessibility (assets '24)*. ACM, New York, NY, USA, 1–31. doi:10.1145/3663548.3675660
[78] Deni Setiawan, Bagus Priambodo, Mila Desi Anasanti, Al Hamidy Hazidar, Emil Naf'an, Mardhiah Masril, Inge Handriani, Asama Kudr Nseaf, and Zico Pratama Putra. 2019. Designing a Multimodal Graph System to Support Non-Visual Interpretation of Graphical Information. *Journal of Physics: Conference Series* 1339 (2019), 012059. doi:10.1088/1742-6596/1339/1/012059
[79] Yixian Shen, Hang Zhang, Yanxin Shen, Lun Wang, Chuanqi Shi, Shaoshuai Du, and Yiyi Tao. 2025. AltGen: AI-Driven Alt Text Generation for Enhancing EPUB Accessibility. In *Proceedings of the 2025 International Conference on Artificial Intelligence and Computational Intelligence*. ACM, New York, NY, USA, 78–83. doi:10.1145/3730436.3730449
[80] P. M. Silva, T. N. Pappas, J. Atkins, and J. E. West. 2016. Perceiving graphical and pictorial information via hearing and touch. *Ieee transactions on multimedia* 18, 12 (2016), 2432–2445. doi:10.1109/tmm.2016.2601029
[81] Thomas C. Smits, Sehi L'Yi, Andrew P. Mar, and Nils Gehlenborg. 2024. AltGosling: automatic generation of text descriptions for accessible genomics data visualization. *Bioinformatics* 40, 12 (2024), btae670. doi:10.1093/bioinformatics/btae670
[82] Arjun Srinivasan, Tim Harshbarger, Darrell Hilliker, and Jennifer Mankoff. 2023. Azimuth: designing accessible dashboards for screen reader users. In *The 25th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS '23)*. ACM, New York, NY, USA, 1–16. doi:10.1145/3597638.3608405
[83] Barry E. Stein and M. Alex Meredith. 1993. *The Merging of the Senses*. MIT Press, Cambridge, MA.
[84] John Sweller, Paul Ayres, and Slava Kalyuga. 2011. *Cognitive Load Theory*. Springer, New York. doi:10.1007/978-1-4419-8126-4
[85] Joe Tekli, Youssef Bou Issa, and Richard Chbeir. 2018. Evaluating touchscreen vibration modality for blind users to access simple shapes and graphics. *International Journal of Human-Computer Studies* 110 (2018), 115–133. doi:10.1016/j.ijhcs.2017.10.009
[86] John R. Thompson, Jesse J. Martinez, Alper Sarikaya, Edward Cutrell, and Bongshin Lee. 2023. Chart reader: accessible visualization experiences designed with screen reader users. In *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems (CHI '23)*. ACM, New York, NY, USA, Article 802, 18 pages. doi:10.1145/3544548.3581186
[87] B. J. Tomlinson, J. Batterman, Y. C. Chew, A. Henry, and B. N. Walker. 2016. Exploring auditory graphing software in the classroom: the effect of auditory graphs on the classroom environment. *Acm transactions on accessible computing* 9, 1, Article 3 (2016), 27 pages. doi:10.1145/2994606
[88] John W. Tukey. 1977. *Exploratory Data Analysis*. Addison-Wesley, Reading, MA.
[89] Matthew Turk. 2014. Multimodal Interaction: A Review. *Pattern Recognition Letters* 36 (2014), 189–195. doi:10.1016/j.patrec.2013.07.003
[90] United States Access Board. 2017. Section 508 Standards for Electronic and Information Technology. https://www.access-board.gov/ict/. Rehabilitation Act, 29 U.S.C. § 794d.
[91] Bruce N. Walker and Michael A. Nees. 2011. Theory of Sonification. In *The Sonification Handbook*, Thomas Hermann, Andy Hunt, and John G. Neuhoff (Eds.). Logos Verlag, Berlin, 9–39.
[92] Mark T. Wallace and Ryan A. Stevenson. 2014. The Construct of the Multisensory Temporal Binding Window and Its Dysregulation in Developmental Disabilities. *Neuropsychologia* 64 (2014), 105–123. doi:10.1016/j.neuropsychologia.2014.08.005
[93] Yanan Wang, Arjun Srinivasan, and Yea-Seul Kim. 2024. Enabling tabular data exploration for blind and low-vision users. In *Proceedings of the 2024 ACM Designing Interactive Systems Conference (DIS '24)*. ACM, New York, NY, USA, 1218–1233. doi:10.1145/3643834.3661609
[94] T. Watanabe, K. Araki, T. Yamaguchi, and K. Minatani. 2016. Development of tactile graph generation web application using r statistics software environment. *Ieice transactions on information and systems* E99.D, 8 (2016), 2151–2160. doi:10.1587/transinf.2015EDP7405
[95] S. E. Wegwerth, G. J. Manchester, and J. E. Winter. 2023. A feasibility study of the kasi learning system to support independent use of stem diagrams by students with visual impairments. *Journal of visual impairment & blindness* 117, 2 (2023), 162–174. doi:10.1177/0145482X231169713
[96] Robert B. Welch. 1999. Meaning, Attention, and the "Unity Assumption" in the Intersensory Bias of Spatial and Temporal Perceptions. In *Cognitive Contributions to the Perception of Spatial and Temporal Events*, Gisa Aschersleben, Talis Bachmann, and Jochen Müsseler (Eds.). Advances in Psychology, Vol. 129. Elsevier, Amsterdam, 371–387. doi:10.1016/S0166-4115(99)80036-3
[97] Christopher D. Wickens. 2002. Multiple Resources and Performance Prediction. *Theoretical Issues in Ergonomics Science* 3, 2 (2002), 159–177. doi:10.1080/14639220210123806
[98] F. Wildhaber, N. Salloum, M. Gygli, and A. Kennel. 2020. Self-directed creation and editing of uml class diagrams on mobile devices for visually impaired people. In *2020 ieee/acm 2nd international workshop on model-driven requirements engineering (modre)*. IEEE, Zurich, Switzerland, 49–57. doi:10.1109/modre51215.2020.00012
[99] World Wide Web Consortium (W3C). 2018. *Web Content Accessibility Guidelines (WCAG) 2.1*. Technical Report. W3C. https://www.w3.org/TR/WCAG21/ W3C Recommendation.
[100] A. M. Zambrano, D. I. Pilacuán, M. N. Salvador, F. Grijalva, Nathaly Orozco Garzón, and H. Carvajal Mora. 2023. Irismath: a blind-friendly web-based computer algebra system. *Ieee access* 11 (2023), 71766–71776. doi:10.1109/access.2023.3281761
[101] A. M. Zambrano, M. N. Salvador, F. Grijalva, H. Carvajal Mora, and N. Orozco Garzón. 2024. Math for everybody: a sonification module for computer algebra systems aimed at visually impaired people. *Technologies* 12, 8 (2024), 133. doi:10.3390/technologies12080133
[102] Zhuohao (Jerry) Zhang, John R. Thompson, Aditi Shah, Manish Agrawal, Alper Sarikaya, Jacob O. Wobbrock, Edward Cutrell, and Bongshin Lee. 2024. Charta11y: designing accessible touch experiences of visualizations with blind smartphone users. In *The 26th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS '24)*. ACM, New York, NY, USA, Article 55, 15 pages. doi:10.1145/3663548.3675611
[103] Zhuohao (Jerry) Zhang and Jacob O. Wobbrock. 2023. A11yboard: making digital artboards accessible to blind and low-vision users. In *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems (CHI '23)*. ACM, New York, NY, USA, 1–17. doi:10.1145/3544548.3580655
[104] Y. Zhao. 2025. Miui: make interaction usable on information visualization for people with visual impairments. In *28th international conference on computer supported cooperative work in design (cscwd)*. IEEE, Compiegne, France, 104–109. doi:10.1109/cscwd64889.2025.11033608
[105] J. Zong, C. Lee, A. Lundgard, J. Jang, D. Hajas, and A. Satyanarayan. 2022. Rich screen reader experiences for accessible data visualization. *Computer graphics forum* 41, 3 (2022), 15–27. doi:10.1111/cgf.14519

A Corpus complet des 66 études

Le tableau 9 liste les 66 études du corpus, avec leurs scores ARC par dimension (D_{sync}, D_{int}, D_{topo}, D_{modal}), le score architectural total (ARC_{arch}) et le niveau de maturité (N_1–N_3).

Table 9: Corpus complet des 66 études et scores ARC par dimension.

Identification de l'étude	D_{sync}	D_{int}	D_{topo}	D_{modal}	ARC_{arch}(Niv.)
Kasi learning system [95]	5.00	3.00	1.60	2.27	11.87 (N3)
Exploreur de visualisations par lecteur d'écran et sonification [52]	0.00	3.00	1.50	2.27	6.77 (N2)
A11yBoard [103]	5.00	2.20	2.80	3.87	13.87 (N3)
ChartVision [21]	3.12	0.80	0.80	1.67	6.39 (N2)
Accessible circuit diagrams [69]	0.00	0.30	0.80	2.67	3.77 (N1)
Susurrus [39]	1.25	1.00	1.40	2.27	5.92 (N1)
GraficiAccessibili [30]	3.75	3.00	2.00	3.93	12.68 (N3)
AltCanvas [50]	3.75	2.50	2.40	2.53	11.18 (N3)
Plateforme audio-graphique pour fonctions mathématiques [24]	1.25	2.00	2.30	0.93	6.48 (N2)
AltGen (alt-text génératif) [79]	0.00	2.10	0.80	0.67	3.57 (N1)
AltGosling (génomique) [81]	5.00	1.50	2.20	2.67	11.37 (N3)
NoVAGraphs Dialogue System (NoVABot) [7]	0.00	1.00	1.80	0.67	3.47 (N1)
AudioDraw [35]	0.00	1.10	1.60	0.67	3.37 (N1)
Système de présentation tactile et haptique [66]	5.00	2.20	2.30	4.00	13.50 (N3)
Audio descriptions, bar charts [37]	0.00	0.90	1.10	0.67	2.67 (N1)
Azimuth (dashboards) [82]	5.00	1.50	1.90	2.00	10.40 (N2)
Benthic (structures congruentes) [57]	0.00	1.00	1.80	0.67	3.47 (N1)
CBeyond (maths primaire) [14]	0.00	0.80	1.00	0.67	2.47 (N1)
Chart Reader [86]	1.25	3.00	1.50	2.27	8.02 (N2)
ChartA11y [102]	5.00	2.50	1.70	4.00	13.20 (N3)
ChartVI [59]	3.75	1.00	1.00	0.67	6.42 (N2)
Alt-text de visualisations [40]	0.00	1.60	1.20	0.67	3.47 (N1)
MDS (Multimodal Diagram System) [11]	5.00	2.00	2.30	3.27	12.57 (N3)
Système de navigation tabulaire 2D [15]	1.25	3.00	1.10	1.60	6.95 (N2)
Web data records, magnifier [49]	0.00	2.10	2.30	0.27	4.67 (N1)
Graphes multimodaux [78]	5.00	2.00	1.70	4.00	12.70 (N3)
Graphiques tactiles via R [94]	0.00	0.80	1.90	2.93	5.63 (N1)
Exploration de tableaux [93]	0.00	1.10	1.10	0.67	2.87 (N1)
Plateforme EuroMath [27]	1.25	3.20	2.60	4.00	11.05 (N3)
Edukoi (sonification) [36]	0.00	1.10	0.70	1.60	3.40 (N1)
Vibration tactile, formes simples [85]	0.00	0.30	2.40	1.67	4.37 (N1)
Tablette, résolution de problèmes [9]	1.25	2.00	2.00	4.00	9.25 (N2)
Auditory graphing software [87]	5.00	3.00	2.00	2.93	12.93 (N3)
EyeMath [23]	0.00	0.80	1.10	0.67	2.57 (N1)
GraCALC [32]	5.00	2.00	2.90	4.00	13.90 (N3)
CosmoBally on Sonoplanet [19]	5.00	1.00	2.40	2.93	11.33 (N3)
Outil LLM, images STEM [68]	0.00	1.80	0.90	0.67	3.37 (N1)
Multimodal DNN Summarizer [41]	0.00	1.00	0.70	0.67	2.37 (N1)
Explorateur tactile auditif d'images [44]	0.00	0.10	1.90	2.47	4.47 (N1)
Sonification interactive, jeux sérieux [72]	1.25	3.00	3.00	2.93	10.18 (N2)
IrisMath (CAS web) [100]	3.12	2.00	2.00	0.67	7.79 (N2)
Maths sur Android [1]	0.00	0.30	0.70	1.33	2.33 (N1)
MAIDR + LLM multimodal [77]	0.00	1.50	2.20	0.67	4.37 (N1)
LectureAssistant [4]	0.00	0.60	1.40	2.67	4.67 (N1)
Math for Everybody (Math4e) [101]	5.00	2.00	1.10	2.27	10.37 (N2)
Math Melodies [2]	5.00	2.70	2.50	3.60	13.80 (N3)
Navigateur non visuel d'équations [45]	0.00	1.80	2.00	4.00	7.80 (N2)
MIUI (interaction usable) [104]	3.12	0.60	1.30	0.67	5.69 (N1)
Mobile Auditory Graph (MAG), gestes multi-touch [71]	0.00	1.00	0.50	2.27	3.77 (N1)
Sonification, exploration de formes [54]	0.00	0.80	1.30	2.73	4.83 (N1)
Perceiving via hearing and touch [80]	5.00	2.80	2.60	3.80	14.20 (N3)
Quimivox Mobile (table de Mendeleïev) [20]	3.12	2.00	1.50	1.00	7.62 (N2)
Mobile Auditory Graph (MAG), sonification multi-référence [70]	0.00	0.30	1.50	2.27	4.07 (N1)
Contenu visuel riche, lecteurs d'écran [61]	5.00	0.80	1.90	2.27	9.97 (N2)
Prototypes de navigation non visuelle dans des visualisations [105]	5.00	0.80	1.60	0.67	8.07 (N2)
SeeChart [3]	0.00	1.50	1.10	0.67	3.27 (N1)
Diagram writer [98]	5.00	3.20	2.80	4.00	15.00 (N3)
ARET (Automatic Reading of Educational Texts) [55]	5.00	2.00	2.00	0.67	9.67 (N2)
Moteur de conversion EuroMath [58]	3.75	3.00	2.20	4.00	12.95 (N3)
TableNarrator [60]	0.00	1.80	1.40	0.67	3.87 (N1)
Sonification, découverte de données [28]	5.00	2.00	2.20	2.47	11.67 (N3)
TouchPen [25]	1.25	3.00	1.80	3.60	9.65 (N2)
UML4ALL (notation textuelle) [51]	0.00	0.30	2.20	2.67	5.17 (N1)
Pipeline d'extraction automatique de graphiques [16]	0.00	1.30	1.00	2.67	4.97 (N1)
VizAbility [33]	3.12	3.00	1.70	0.67	8.49 (N2)
Web-Alap [5]	0.00	1.50	1.50	0.67	3.67 (N1)