Designing for Epistemic Agency: The Verification Paradox and Control Affordances in AI Accessibility Systems

Concevoir pour l'agentivité épistémique : paradoxe de vérification et affordances de contrôle dans les systèmes d'accessibilité IA

Madjid Sadallah
Université Claude Bernard Lyon 1, CNRS, INSA Lyon, LIRIS, UMR5205
69622 Villeurbann, France
madjid.sadallah@liris.cnrs.fr

Benoît Encelle
Universite Claude Bernard Lyon 1, CNRS, INSA Lyon, LIRIS, UMR5205
69622 Villeurbanne, France
benoit.encelle@liris.cnrs.fr

Abstract

AI-powered accessibility systems have shifted from *transcription* (rendering visual content as-is) to *interpretation* (generating selective, conversational narratives). While this evolution enriches user experience, it also introduces a **verification paradox**: blind and low-vision users, who rely most heavily on AI descriptions, are the very people who lack the independent perceptual access needed to detect consequential errors—hallucinations, misclassifications, or semantic drift. This asymmetry is inherent whenever AI acts as an epistemic intermediary, shaping information while simultaneously removing the means to verify it. Through a systematic review with comparative analysis of 17 empirically evaluated systems, we introduce the **Verification-Cognition Balance Index (VCBI)**. This composite metric quantifies the equilibrium between two enablers of verification (validation rigor and user agency) and two sources of epistemic burden (architectural complexity and documented risk density). Our findings reveal that transformer-based architectures exhibit substantially higher documented risk than classical computer-vision pipelines, yet they offer no corresponding improvement in verification balance. Specialized hybrid systems point toward a more promising, though presently rare, alternative. Most critically, current evaluations emphasize system accuracy while overlooking whether users can detect AI errors. Grounded in epistemic agency theory, we argue for a necessary shift from *system accuracy* to *user verifiability* and distill three actionable design patterns—provenance transparency, non-visual uncertainty signaling, and contestation interactions—that make this principle concrete for blind and low-vision users.

Résumé

Les systèmes d'accessibilité fondés sur l'IA sont passés de la transcription (restituer tel quel le contenu visuel) à l'interprétation (descriptions sélectives, souvent conversationnelles). Ce changement, tout en enrichissant l'expérience, fait émerger un **paradoxe de vérification** : les déficients visuels (aveugles ou malvoyants), qui dépendent le plus des descriptions de l'IA, n'ont plus d'accès perceptuel pour détecter des erreurs critiques (hallucinations, erreurs de classification, dérive sémantique). Cette asymétrie est consubstantielle au rôle d'*intermédiaire épistémique* de l'IA, qui façonne l'information tout en supprimant les moyens de la vérifier. À travers une revue systématique évaluant de manière comparative 17 systèmes, nous introduisons le **Verification-Cognition Balance Index (VCBI)**. Cette métrique composite évalue l'équilibre entre deux leviers de vérifiabilité que sont la rigueur de validation du système et l'agentivité épistémique (capacité des utilisateurs à détecter les erreurs du système), et deux sources de charge cognitive liée à la vérification : la complexité architecturale du système et la densité de risque documenté. Nos résultats montrent entre autres que les architectures basées sur les transformeurs présentent un risque documenté nettement supérieur à celui des pipelines de vision classique, sans amélioration correspondante de l'équilibre vérification-cognition, et que les systèmes hybrides spécialisés, bien que rare, offrent une voie plus prometteuse. Surtout, les évaluations actuelles privilégient la mesure de la précision système au détriment de l'agentivité épistémique. Ancrés dans la théorie de l'agentivité épistémique, nous plaidons pour un recentrage de l'évaluation - de la précision système vers la *vérifiabilité par l'utilisateur*, et proposons trois schémas de conception actionnables—*transparence de provenance*, *signalement non visuel de l'incertitude*, et *interactions de contestation*—qui opérationnalisent ce principe pour les utilisateurs aveugles et malvoyants.

CCS Concepts

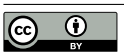
• **Human-centered computing** → **Accessibility**; *HCI theory, concepts and models*; *Empirical studies in accessibility*; • **Computing methodologies** → Artificial intelligence.

Keywords

Accessibility, Blind and Low Vision, Artificial Intelligence, Verification, Epistemic Agency, Verification Affordances, Design Patterns

Mots clés

Accessibilité, Aveugles et malvoyants, Intelligence artificielle, Vérification, Agentivité épistémique, Affordances de vérification, Schémas de conception



This work is licensed under a Creative Commons Attribution 4.0 International License.
IHM '26, Villeneuve-d'Ascq, France
© 2026 Copyright held by the owner/author(s).
ACM ISBN 979-8-4007-2965-2/2026/10
https://doi.org/10.1145/3845948.3845954

ACM Reference Format:
Madjid Sadallah and Benoît Encelle. 2026. Designing for Epistemic Agency: The Verification Paradox and Control Affordances in AI Accessibility Systems: Concevoir pour l'agentivité épistémique : paradoxe de vérification et affordances de contrôle dans les systèmes d'accessibilité IA. In *Proceedings of the 37th Conference on l'Interaction Humain-Machine (IHM '26), October 19–23, 2026, Villeneuve-d'Ascq, France.* ACM, New York, NY, USA, 14 pages. https://doi.org/10.1145/3845948.3845954

1 Introduction

Les technologies d'assistance, systèmes destinées aux utilisateurs déficients visuels (aveugles et malvoyants), ont longtemps reposé sur un *paradigme de transcription* : la reconnaissance optique de caractères convertit des matrices de pixels en flux de caractères [22], les lecteurs d'écran linéarisent les hiérarchies de composants graphiques constituant les interfaces en sorties auditives séquentielles [24], et les graphiques tactiles encodent les relations spatiales sous forme de représentations embossées [37]. Dans cette perspective, ces systèmes agissent principalement comme des transducteurs sensoriels, rendant l'information visuelle accessible sans en expliciter la structure ni en soutenir l'interprétation sémantique, laissée à la charge de l'utilisateur.

L'intégration de l'apprentissage profond et de l'IA générative a profondément transformé cette répartition du travail en substituant au paradigme de transcription un *paradigme d'interprétation.* Les systèmes contemporains produisent désormais des récits en langage naturel à partir de visualisations statistiques (VizAbility [16]), résument des données tabulaires (TableNarrator [30]), génèrent des descriptions contextuellement enrichies de contenus visuels pour l'accès aux images issues des STEM (Edukoi [17]), ou transforment des diagrammes scientifiques en matériel pédagogique accessible (LectureAssistant [2]). Ce faisant, les technologies d'assistance cessent d'être de simples conduits neutres pour devenir des *intermédiaires épistémiques* : cette transition modifie en profondeur les capacités de vérification de l'utilisateur sur les sorties d'un système.

Pour l'utilisateur voyant, les interprétations générées par l'IA coexistent avec un accès perceptuel direct à l'information source, permettant une validation croisée immédiate. Pour les utilisateurs aveugles et malvoyants, en revanche, l'IA constitue souvent la source d'information primaire, parfois exclusive. Cette asymétrie se révèle particulièrement problématique au regard des types de défaillance documentés des modèles vision-langage : hallucinations, dérive sémantique, erreurs de classification, inexactitudes contextuelles [19, 20]. Lorsqu'une IA rapporte à tort une tendance, crée de toutes pièces une donnée ou introduit des inexactitudes factuelles, les utilisateurs aveugles et malvoyants se trouvent privés de la redondance perceptuelle dont dispose leurs homologues voyants pour détecter l'erreur.

C'est là que réside le *paradoxe de vérification* : ceux qui ont le plus besoin de l'interprétation IA sont précisément les moins en mesure de la vérifier. Pour l'illustrer, considérons un analyste de données aveugle consultant un graphique à barres comparant les ventes trimestrielles dans cinq régions. Le système lui narre : *« Les ventes ont culminé au trimestre 3 dans toutes les régions, avec le Nord-Est affichant la plus forte croissance à 47% »*. L'interprétation semble fluide et fiable. Pourtant, si l'IA a inventé la valeur de 47 %, mal lu l'axe des ordonnées ou confondu deux séries de données, l'analyste n'a aucun moyen de s'en apercevoir par lui-même. Les travaux empiriques récents confirment cette vulnérabilité : dans des conditions contrôlées, les utilisateurs aveugles et malvoyants ne détectent qu'environ 50% des erreurs de reconnaissance [18]. Ce taux, établi pour des erreurs de reconnaissance visuelle classique, constitue vraisemblablement une *borne supérieure* pour les hallucinations de modèles génératifs. Ces dernières sont structurellement plus difficiles à identifier : précisément parce qu'elles sont sémantiquement plausibles et énoncées clairement, elles résistent à la détection en l'absence d'accès à l'information source, au « terrain de vérité » [20].

Les approches traditionnelles pour estimer et mettre à l'épreuve l'IA, notamment les scores de confiance, les demandes d'explications et les propositions d'hypothèses alternatives, présupposent que les utilisateurs conservent un accès épistémique indépendant ou des canaux de vérification auxiliaires [5, 43]. Cette hypothèse ne tient pas dans les contextes d'accessibilité, où les mécanismes de vérification doivent opérer sous les mêmes contraintes sensorielles et cognitives qui avaient initialement rendu nécessaire la médiation par l'IA. Malgré ces enjeux accrus, les affordances de vérification (capacités de pouvoir détecter/contester les erreurs de l'IA tout en minimisant l'effort cognitif, données aux utilisateurs d'un système) dans les technologies d'assistance basées sur l'IA n'ont fait l'objet d'aucune analyse systématique : les pratiques d'évaluation restent axées sur la *précision de l'IA* plutôt que sur la *vérifiabilité utilisateur.*

1.1 Questions de recherche

Cet article s'inscrit dans la continuité d'un programme de recherche dont une première publication [36] a posé les fondements. Il aborde trois questions de recherche à travers une revue systématique avec analyse comparative :

- **QR1 (Profils)** : Quels profils de vérification-cognition émergent de l'analyse conjointe de la rigueur de validation scientifique, de l'agentivité épistémique conférée à l'utilisateur, de la complexité architecturale et du risque d'erreurs dans les systèmes d'accessibilité fondés sur l'IA ?
- **QR2 (Architecture)** : Dans quelle mesure l'équilibre entre vérification et cognition varie-t-il selon les paradigmes IA (vision classique, transformeurs, systèmes hybrides), et quelles propriétés architecturales soutiennent le mieux les affordances de vérification ?
- **QR3 (Conception)** : Quels schémas de conception caractérisent les systèmes dotés des affordances de vérification les plus robustes ?

Dans les situations à fort enjeu, la question déterminante n'est pas « l'IA peut-elle accomplir la tâche ? » mais « les utilisateurs peuvent-ils exercer un contrôle épistémique sur les interprétations que l'IA leur transmet ? ». Notre travail montre que ces deux objectifs sont souvent contradictoires et que, sans une conception délibérément orientée vers la vérifiabilité, l'innovation en IA risque d'éroder l'autonomie des utilisateurs plutôt que de la renforcer [28].

1.2 Relation à nos travaux antérieurs

Cet article s'appuie sur le corpus de 17 systèmes et le protocole de sélection et d'analyse associé (revue de portée PRISMA-ScR, Section 3.1), sur le schéma de codage multidimensionnel, ainsi

que sur la formule du *Verification-Cognition Balance Index* (VCBI, Section 3.2.3), introduits dans [36]. Les scores bruts par système qui en résultent sont rapportés en annexe (Tableau 5).

À partir de ce socle empirique, l'article développe une théorisation de l'agentivité épistémique appliquée à l'accessibilité IA (Section 2.3) : nous y introduisons l'*injustice vérificationnelle* comme troisième forme d'injustice épistémique au sens de Fricker [14], et distinguons l'autonomie de *contenu* de l'autonomie de *processus* au sens d'Anderson [3]. Ce cadre théorique fonde à son tour un ensemble de contributions destinées à la communauté IHM : un cadre opérationnel de conception (Section 5.3), articulant anti-patrons, priorisation par détectabilité des erreurs et référentiels réglementaires (WCAG 2.2, European Accessibility Act, RGAA) ; des protocoles d'évaluation centrés sur la vérifiabilité, assortis de cibles chiffrées testables (Section 5.4) ; et une analyse comparative de l'adoption des schémas de conception par paradigme architectural (Section 4.3.3), qui révèle le paradoxe d'une adoption universelle chez les systèmes transformeurs (100 %) sans amélioration correspondante du VCBI.

Les sections de résultats (Section 4 et suivantes) réutilisent les données quantitatives du corpus, mais les ré-analysent sous l'angle de l'agentivité épistémique : une mise en garde porte sur le poids disproportionné des deux systèmes hybrides dans le R^2 architectural (Section 4.1.1), et un commentaire sur le système de dialogue éducatif précise que son VCBI élevé s'explique par une rigueur de validation exceptionnelle plutôt que par son agentivité. L'articulation avec les référentiels réglementaires (WCAG 2.2, EAA, RGAA), notamment européens et français, constitue par ailleurs un apport distinct pour la communauté IHM francophone, absent de [36].

2 Travaux connexes

2.1 Architectures IA et implications pour la vérification

Les systèmes d'accessibilité IA pour les utilisateurs aveugles et malvoyants se répartissent en trois paradigmes architecturaux impactant distinctement les capacités de vérification. Les *systèmes basés sur des règles et la vision par ordinateur classique* reposent sur des algorithmes déterministes ou des réseaux de neurones convolutifs de première génération. Leurs sorties, souvent structurées, produisent des défaillances généralement détectables [25]. Ainsi, un système OCR qui confond le chiffre « 8 » avec la lettre « B » génère une sortie syntaxiquement invalide, aisément repérable par de simples vérifications de cohérence. À l'inverse, les *systèmes génératifs basés sur les transformeurs* produisent des interprétations sémantiquement riches, mais sont susceptibles de générer des hallucinations, c'est-à-dire des sorties plausibles mais fausses, indistinguables des productions valides en l'absence d'accès à un terrain de vérité [10, 20]. Ces systèmes reposent sur de grands modèles de langue (LLM) ou des modèles vision-langage qui génèrent du texte en prédisant la suite la plus probable, sans mécanisme de vérification interne. Entre ces deux approches, les *architectures hybrides spécialisées* cantonnent l'IA à des sous-tâches bien délimitées au sein de flux de travail structurés, ménageant ainsi un équilibre entre capacité et vérifiabilité grâce à la supervision humaine et au contrôle modulaire, c'est-à-dire la possibilité d'inspecter et de corriger chaque sous-composant indépendamment [40].

Les travaux sur la collaboration humain-IA montrent que les utilisateurs peinent à proportionner leur confiance en l'absence de canaux de vérification indépendants [5, 23]. Ces cadres supposent toutefois que les utilisateurs disposent de *sources d'information alternatives*, hypothèse invalide dans les contextes d'accessibilité où l'IA constitue le canal perceptuel primaire, voire unique.

2.2 Explicabilité, agentivité et interfaces explicables

Les techniques d'explicabilité telles que les cartes de saillance restent largement inaccessibles aux utilisateurs aveugles et malvoyants en raison de leur nature visuelle [32]. La quantification de l'incertitude pourrait contribuer à la calibration de la confiance [15], mais ces métriques sont rarement exposées dans les modèles commerciaux et supposent une médiation non visuelle encore peu standardisée.

Le cadre de l'IA centrée sur l'humain de Shneiderman [40] invite à dépasser la consommation passive pour aller vers une supervision accrue et une agentivité renforcée. Le mouvement émergent des interfaces utilisateur explicables (XUI) cherche à rendre les systèmes d'IA transparents et compréhensibles [32]. Ces travaux demeurent toutefois centrés sur l'explicabilité *post-hoc*, qui consiste à expliquer pourquoi une décision a été prise, plutôt que sur l'explicabilité *vérifiable*, qui permet de détecter une décision erronée. Pour l'accessibilité des utilisateurs aveugles et malvoyants, cette distinction est cruciale : une explication parfaitement claire d'une hallucination reste une hallucination. Notre travail élargit la portée du champ XUI en proposant que la vérifiabilité constitue une dimension fondamentale de l'explicabilité lorsque la validation indépendante est structurellement contrainte.

Si les fonctions de forçage cognitif et les explications bien conçues favorisent une confiance appropriée [5], elles n'en supposent pas moins que les utilisateurs peuvent évaluer les limites du système. Cette évaluation requiert des canaux de vérification indépendants, souvent absents pour les personnes aveugles ou malvoyantes. Les évaluations actuelles privilégient les métriques de *précision système* au détriment de la *capacité de détection d'erreurs par l'utilisateur*. À mesure que les systèmes évoluent vers des modèles génératifs, les modes de défaillance deviennent plus subtils et plus difficiles à contester, sans que les méthodologies d'évaluation n'évoluent en conséquence. C'est précisément à cette lacune que le présent travail entend remédier.

2.3 Agentivité épistémique et déficit structurel

La notion d'*agentivité épistémique* constitue le fondement théorique du paradoxe de vérification. Nous en proposons une conceptualisation adaptée aux contextes d'accessibilité IA, articulée autour de trois niveaux d'analyse complémentaires.

Injustice épistémique. Fricker [14] distingue deux formes d'injustice épistémique : l'injustice testimoniale (dévaluation du témoignage d'un agent en raison de son identité sociale) et l'injustice herméneutique (déficit des ressources conceptuelles collectives pour comprendre une expérience). Le paradoxe de vérification relève d'une troisième forme, que nous proposons d'appeler *injustice vérificationnelle* : les personnes aveugles et malvoyantes sont structurellement empêchées de *vérifier* les informations qui leur sont

fournies, non par dévaluation sociale, mais par inaccessibilité des mécanismes de validation. Par exemple, une personne aveugle consultant une description d'image générée par IA ne peut pas, comme le ferait une personne voyante, jeter un coup d'œil à l'original pour confirmer qu'aucun objet n'a été inventé. Ce déficit est *constitutif* du paradigme d'interprétation IA : c'est parce que le système interprète *pour* l'utilisateur que celui-ci ne peut plus exercer son agentivité épistémique directement sur la source.

Autonomie cognitive et dépendance technologique. Les travaux sur l'autonomie cognitive [3] distinguent l'autonomie de *contenu* (contrôle sur ce que l'on croit) de l'autonomie de *processus* (contrôle sur la manière dont on forme ses croyances). Les systèmes d'accessibilité fondés sur l'IA affectent les deux : en substituant leur interprétation à l'accès perceptuel direct, ils contraignent le contenu des croyances ; en rendant la vérification difficile, ils entravent le processus de formation de ces croyances. Cette distinction a une conséquence pratique importante : un système peut fournir des informations globalement exactes (autonomie de contenu) tout en empêchant l'utilisateur de vérifier chaque élément individuel (autonomie de processus). Or, c'est précisément cette seconde dimension que les métriques de précision système ignorent. La réponse appropriée à cette vulnérabilité n'est pas la perfection algorithmique, mais la mise en place d'affordances de vérification.

Implications pour l'évaluation des systèmes. Cette distinction entre autonomie de contenu et autonomie de processus a des conséquences directes pour l'analyse des systèmes d'accessibilité fondés sur l'IA. Elle implique qu'une évaluation complète de la vérifiabilité ne peut se réduire ni à la seule précision des sorties, ni à la seule richesse des interactions, mais doit considérer conjointement la fiabilité du contenu et les moyens offerts à l'utilisateur pour exercer un contrôle épistémique. C'est précisément cette double exigence qui motive la construction du *Verification-Cognition Balance Index* (VCBI), une métrique composite qui vise à capturer l'équilibre entre ces deux dimensions. L'analyse de la Section 4.3.1 illustrera empiriquement les conséquences d'une déficience dans l'une ou l'autre de ces facettes.

3 Méthodologie

3.1 Construction du corpus

Afin d'identifier les systèmes d'accessibilité basés sur l'IA et de réaliser leurs évaluations, nous avons conduit une revue systématique de littérature selon les directives *PRISMA-ScR* [41] et un protocole préenregistré [35]. Cinq bases de données (ACM Digital Library, IEEE Xplore, SpringerLink, PubMed et OpenAlex) ont été interrogées au moyen de requêtes combinant des termes relatifs à la déficience visuelle, aux technologies d'assistance, à l'accès au contenu visuel et à l'évaluation empirique. Les études retenues devaient satisfaire quatre critères : (1) évaluation empirique avec des participants aveugles ou malvoyants ; (2) centrage sur l'accès aux contenus STEM ; (3) IA ou apprentissage automatique comme composant fonctionnel central ; (4) publication sous forme d'article complet révisé par les pairs entre 2015 et 2025. Ce filtrage a abouti à un corpus final de 17 systèmes, couvrant la période 2019–2025.

Quatre systèmes ont fait l'objet d'une reclassification à l'issue de la résolution des désaccords inter-juges, sur la base d'un consensus concernant la fonction opérationnelle de leur composant IA. L'application Android d'apprentissage des mathématiques [1], le générateur de résumés de graphiques (Multimodal DNN Summarizer) [21] et le système de dialogue NoVAGraphs [4] ont été reclassés en *Vision classique*, tandis que KASI [42], initialement codé « CNN », a été reclassé en *Architecture hybride spécialisée*. Ces 17 systèmes se répartissent comme suit :

- **Vision classique et systèmes à base de règles (n=7).** Exemples : EyeMath [12], ChartVi [29], Edukoi [17].
- **Systèmes basés sur les transformeurs (n=8).** Exemples : AltCanvas [27], VizAbility [16], TableNarrator [30].
- **Architectures hybrides spécialisées (n=2).** Exemples : KASI [42], TableView+ [26].

Les scores détaillés attribués à chaque système sur les différentes métriques, ainsi que les justifications de codage associées, sont documentés dans le Tableau 5 en annexe.

3.2 Extraction des données et codage

3.2.1 Codage. Un schéma de codage multidimensionnel a été appliqué à chaque article, couvrant les caractéristiques techniques (IA, topologie — entendue ici comme la complexité architecturale du système, opérationnalisée en Section 3.2.2), les risques documentés, la méthodologie d'évaluation, l'agentivité utilisateur, et la qualité des études. Un second codeur indépendant a traité 20% du corpus ; l'accord inter-juges atteint un κ de Cohen de 0,83 pour les items catégoriels. Les désaccords ont été résolus par discussion et consensus.

3.2.2 Métriques dérivées.

Complexité topologique (échelle ordinale 1–4). Cette métrique évalue la sophistication structurelle du traitement de l'information. Pour les utilisateurs aveugles et malvoyants, un niveau topologique plus élevé corrèle avec une charge cognitivo-épistémique accrue lors de la vérification. Lorsque l'architecture d'un système couvre deux niveaux, des valeurs intermédiaires (ex. : 2,4 ; 2,5) ont été assignées pour refléter un recouvrement partiel du niveau supérieur. Les quatre niveaux sont définis comme suit :

- Niveau 1 (Discret) : une fonction unique, par exemple un classifieur qui associe directement une étiquette à une image sans traitement intermédiaire.
- Niveau 2 (Hiérarchique) : un pipeline séquentiel, tel qu'une chaîne de traitement où l'OCR précède la synthèse vocale.
- Niveau 3 (Réseau) : une logique de branchement ou de fusion multimodale, comme un système qui combine reconnaissance d'objets et OCR avant de générer une description.
- Niveau 4 (Écosystème) : plusieurs sous-systèmes interagissant avec rétroaction, par exemple un assistant qui adapte ses descriptions en fonction des corrections antérieures de l'utilisateur.

Agentivité utilisateur (échelle ordinale 1–4). Adaptée du cadre de l'IA centrée sur l'humain de Shneiderman [40], cette échelle distingue quatre modes d'engagement, où l'agentivité ne se limite pas à la navigation mais inclut la capacité épistémique de contester

les interprétations de l'IA. Le Niveau 1 (consommation passive) correspond à la réception de sorties fixes sans possibilité d'interaction. Le Niveau 2 (exploration guidée) autorise une navigation au sein d'options ou de paramètres prédéfinis. Le Niveau 3 (collaboration pilotée) introduit une interaction portant sur le contenu même de l'interprétation, permettant d'interroger le système, de contester ses sorties ou d'obtenir un retour contextuel. Enfin, le Niveau 4 (contrôle épistémique complet) donne accès aux données sous-jacentes et aux estimations d'incertitude, avec la possibilité de surpasser les décisions du système.

Rigueur de validation (VR) (échelle 0–10). Cette métrique synthétise la robustesse méthodologique à travers cinq sous-composantes :

- *Conception d'étude* (max 3,0) : méthodes mixtes ou intra-sujets = 3,0 ; inter-sujets avec groupes contrôle = 2,0 ; qualitatif seul = 1,0 ; pilote = 0,5.
- *Complétude statistique* (max 2,0) : tests inférentiels + tailles d'effet + IC = 2,0 ; inférentiel partiel = 1,0 ; descriptif seulement = 0,5.
- *Adéquation de l'échantillon d'utilisateurs aveugles et malvoyants* (max 2,0) : $n \geq 15$ = 2,0 ; $10 \leq n < 15$ = 1,5 ; $n < 10$ = 1,0 ; inclusion symbolique = 0,5.
- *Reproductibilité du protocole* (max 2,0) : spécification complète avec matériaux disponibles = 2,0 ; partielle = 1,0 ; minimale = 0,5.
- *Framework qualitatif* (max 1,0) : checklist validée (MMAT, SUS) = 1,0 ; grille informelle = 0,5.

Le score évalue la *qualité* méthodologique plutôt que la seule présence d'une étude utilisateur. Ainsi, si par exemple TableNarrator [30] inclut bien une étude avec des participants aveugles et malvoyants, il n'obtient que 2,0/10 en raison d'une analyse uniquement descriptive (0,5/2,0), d'une reproductibilité insuffisante (0,0/2,0) et de l'absence de checklist validée (0,0/1,0), soit un total de 2,0 (= 1,0 + 0,5 + 0,5 + 0,0 + 0,0).

La supériorité accordée aux méthodes mixtes ou intra-sujets sur les designs inter-sujets avec groupes contrôle s'explique par un facteur méthodologique propre au contexte étudié. Les études impliquant des participants aveugles et malvoyants présentent une variabilité inter-individuelle particulièrement élevée, liée à la diversité des profils de compensation sensorielle (qui dépendent de l'âge d'apparition de la déficience, d'usage concurrent d'aides techniques, de stratégies cognitives individuelles). Les designs intra-sujets, où chaque participant est comparé à lui-même à travers les conditions testées, contrôlent statistiquement cette source de variance de façon plus efficace qu'un design inter-sujets à effectif comparable, ce qui justifie leur score - le plus élevé dans notre rubrique. Ce choix ne préjuge cependant pas de leur supériorité en toute circonstance : dans les contextes d'accessibilité, les designs intra-sujets exposent aussi les participants à un risque accru de fatigue, particulièrement sensible pour des tâches perceptuelles ou d'écoute prolongées, et à des effets de transfert, où l'usage d'une première technologie modifie la stratégie cognitive employée pour la suivante. Aucune des études de notre corpus ne rapporte de contrôle explicite de ces deux facteurs, ce qui constitue une limite reconnue plutôt qu'un écueil résolu par notre rubrique de notation.

Densité de risque (RD) (échelle 0–10). Quantifiant les risques documentés par sommation pondérée, cette métrique distingue : risques critiques (sécurité, biais, confidentialité) = 2,0 par instance ; risques élevés (hallucinations sémantiques indétectables) = 1,5 ; défaillances techniques détectables = 1,0 ; barrières d'adoption = 0,5. Le score est plafonné à 10.

Schémas de conception pour la vérifiabilité. Au-delà des métriques quantitatives, nous avons relevé pour chaque système la présence de trois schémas de conception susceptibles de soutenir la vérifiabilité par l'utilisateur : la transparence de provenance (accès à la source évidentielle, à l'information source), le signalement d'incertitude (encodage non visuel de la confiance), et les interactions de contestation (possibilité de questionner ou corriger l'IA). Ces schémas sont opérationnalisés à partir des descriptions fournies dans les articles et feront l'objet d'une analyse comparative dans la Section 4.3.

3.2.3 Le Verification-Cognition Balance Index (VCBI). L'index VCBI, initialement introduit dans [36], est un *instrument analytique exploratoire* qui capture l'équilibre entre les affordances de vérification et la charge cognitivo-épistémique dans les systèmes d'accessibilité IA. Ce statut mérite d'être précisé : le VCBI n'est pas une métrique généralisable dont la validité aurait été établie sur un corpus externe, mais un outil de comparaison interne au corpus étudié, destiné à faire émerger des profils contrastés et à guider l'interprétation qualitative plutôt qu'à produire une mesure de précision absolue. Toute lecture du VCBI comme un score certifié de « qualité » d'un système irait au-delà de ce que nos données permettent d'établir. Les affordances de vérification (rigueur de validation et agentivité) désignent la capacité d'un système à soutenir la détection et la contestation des erreurs de l'IA. La charge cognitivo-épistémique (complexité et risques documentés) représente l'effort mental requis pour vérifier les sorties et la probabilité d'y rencontrer des défaillances.

Définition et interprétation du VCBI. Le *Verification-Cognition Balance Index* (VCBI) est défini par la formule suivante :

$$\mathrm{VCBI}(V, A, C, R) = \frac{V^{0.85} \times A^{0.85}}{1 + (C + 1.5R)^{0.65}} + B,$$

où $V, A, C, R \in [0, 1]$ désignent respectivement la rigueur de validation, l'agentivité utilisateur, la complexité topologique et la densité de risque, normalisées selon : $V = \mathrm{VR}/10$, $A = (\text{agentivité} - 1)/3$, $C = (\text{topologie} - 1)/3$, $R = \mathrm{RD}/10$. Le terme B est un bonus de résilience fixé à 0,08 lorsque $V \geq 0{,}7$ et $R \geq 0{,}6$, et à 0 sinon. Ce bonus récompense les systèmes qui maintiennent une validation rigoureuse en dépit d'un risque documenté élevé.

Cette formulation repose sur trois principes clés qui en guident l'interprétation.

(1) La vérification exige validation ET agentivité. La structure multiplicative du numérateur interdit qu'une déficience dans l'une ou l'autre dimension soit compensée par l'autre. Une propriété mathématique critique en découle directement : lorsque l'agentivité = 1, A=0, le numérateur s'annule, donnant VCBI = 0,000 quelle que soit la valeur de V. Quantitativement, un système obtenant 0,9 en validation mais seulement 0,3 en agentivité produit un numérateur de $0{,}9^{0.85} \times 0{,}3^{0.85} = 0{,}33$, inférieur au produit de scores modérés équilibrés $0{,}6^{0.85} \times 0{,}6^{0.85} = 0{,}42$.

(2) La charge cognitive est comprimée relativement aux affordances. L'exposant sous-linéaire au dénominateur favorise les gains sur les affordances plutôt que la réduction de charge.

(3) Le risque est pénalisé davantage que la complexité. Le coefficient 1,5 appliqué à la densité de risque reflète que les erreurs potentielles imposent une charge de vérification plus lourde que la sophistication architecturale.

Aucun système du corpus n'a satisfait simultanément les deux conditions du bonus ($V \geq 0{,}7$ et $R \geq 0{,}6$) : ce terme joue donc un rôle prospectif, définissant un niveau de résilience cible que les pratiques actuelles n'atteignent pas.

Analyse de sensibilité. Les trois coefficients libres de la formule — l'exposant partagé du numérateur (valeur retenue : 0,85), l'exposant du dénominateur (0,65) et le coefficient de pondération du risque (1,5) — ont été calibrés par tests itératifs. Pour évaluer la robustesse de ce calibrage, nous avons recalculé le VCBI des 17 systèmes du corpus en faisant varier chaque paramètre indépendamment sur quatre valeurs alternatives couvrant sa plage plausible, les deux autres paramètres étant maintenus à leur valeur de référence : exposant du numérateur $\in \{0{,}75\,;\ 0{,}80\,;\ 0{,}90\,;\ 0{,}95\}$ (plage 0,75–0,95), exposant du dénominateur $\in \{0{,}55\,;\ 0{,}60\,;\ 0{,}70\,;\ 0{,}75\}$ (plage 0,55–0,75), et coefficient de risque $\in \{1{,}0\,;\ 1{,}25\,;\ 1{,}75\,;\ 2{,}0\}$ (plage 1,0–2,0), soit douze configurations au total. Le Tableau 1 résume, pour chaque paramètre, le déplacement de rang maximal observé sur les 17 systèmes ainsi que le comportement des deux cas extrêmes du corpus.

Table 1: Analyse de sensibilité du VCBI sur douze configurations (quatre valeurs par paramètre, deux paramètres fixés à leur valeur de référence).

Paramètre	Plage testée	Déplacement de rang max.	Rang 1 (TableView+)
Exposant numérateur	0,75–0,95	1 rang	rang 1 (4/4)
Exposant dénominateur	0,55–0,75	1 rang	rang 1 (4/4)
Coefficient de risque	1,0–2,0	2 rangs	rang 1 (4/4)

Multimodal DNN Summarizer : VCBI = 0,000 dans les 12/12 configurations (propriété structurelle, numérateur nul lorsque l'agentivité vaut 1).

Sur les deux exposants, le déplacement de rang reste nul ou marginal (au plus un rang) dans les huit configurations testées, et TableView+ occupe systématiquement le rang 1. Sur le coefficient de risque, le déplacement atteint deux rangs dans trois configurations sur quatre (1,00 ; 1,25 ; 2,00) et un seul rang à 1,75 ; TableView+ reste néanmoins en tête dans les douze configurations, sans exception. Multimodal DNN Summarizer conserve un VCBI de 0,000 dans toutes les configurations : il s'agit d'une propriété mathématique de la formule (numérateur nul lorsque l'agentivité vaut 1), indépendante des coefficients testés. L'affectation aux quatre clusters (Section 4.1.1) reste elle aussi inchangée, mais ce résultat découle directement de la méthode : le clustering hiérarchique opère sur les composantes normalisées (V, A, C, R) prises séparément, et non sur le VCBI lui-même, ce qui le rend mathématiquement indépendant des coefficients de la formule. Cette robustesse structurelle, suffisante pour un outil exploratoire, ne constitue pas une validation externe : elle atteste que le classement relatif des systèmes étudiés n'est pas un artefact du choix précis des coefficients, sans pour autant garantir que la formule se généraliserait à d'autres corpus.

3.3 Analyse statistique

Les statistiques descriptives (moyennes, écarts-types, IC à 95 %) ont été calculées pour chaque catégorie. Une analyse de clusters (méthode de Ward, distance euclidienne) et des corrélations de rangs de Spearman (ρ) entre composantes indépendantes ont été examinées, les variables ordinales (agentivité, topologie) requérant un test non paramétrique. Afin de contrôler l'inflation de l'erreur de Type I liée aux comparaisons multiples, la correction de Benjamini-Hochberg (FDR, m=6) a été appliquée à toutes les corrélations pairées entre composantes indépendantes. Les corrélations avec le VCBI ont été délibérément évitées en raison de la circularité mathématique qu'elles introduiraient.

Compte tenu de la taille réduite de l'échantillon (N=17), les analyses privilégient les configurations descriptives, les tailles d'effet (d de Cohen) et l'extraction qualitative, plutôt que les tests de significativité. Lorsque des valeurs-p sont rapportées, elles servent d'indicateurs complémentaires de la force d'un patron et non de tests confirmatoires ; la puissance statistique est insuffisante pour détecter des effets inférieurs à $d \approx 0{,}9$. Les résultats non significatifs sont interprétés comme une *absence d'évidence d'association dans cet échantillon*, et non comme une preuve d'indépendance.

4 Résultats

4.1 QR1 : Profils de vérification-cognition

Le Tableau 2 présente les statistiques descriptives des métriques primaires sur les 17 systèmes.

Table 2: Statistiques descriptives pour les métriques primaires (N=17)

Métrique	Moy.	ET	IC 95%	Étendue
VCBI (0–1)	0,163	0,071	[0,127; 0,199]	0,000–0,287
Agentivité (1–4)	2,59	0,62	[2,28; 2,90]	1,0–3,0
Valid. rigueur (0–10)	5,54	1,51	[4,77; 6,31]	2,0–8,0
Densité risque (0–10)	5,71	2,30	[4,53; 6,89]	1,8–10,0
Complex. topo. (1–4)	1,89	0,70	[1,55; 2,24]	1,0–3,0

L'analyse révèle trois constats principaux. Premièrement, la complexité topologique se concentre aux niveaux inférieurs : Niveau 1 pour 7 systèmes (41,2%), Niveau 2 pour 8 systèmes (47,1%), Niveau 3 pour 2 systèmes (11,8%), et aucun au Niveau 4. Deuxièmement, l'agentivité se répartit comme suit : 11 systèmes (64,7 %) atteignent le Niveau 3 (collaboration pilotée), 5 systèmes (29,4 %) se situent au Niveau 2 (exploration guidée) et un seul système (5,9 %) reste au Niveau 1 (consommation passive). Aucun système n'atteint le contrôle épistémique complet (Niveau 4). Troisièmement, le VCBI moyen s'établit à 0,163 (IC 95% [0,127; 0,199]), ce qui traduit un équilibre vérification-cognition globalement insuffisant au regard des exigences de vérifiabilité identifiées. Parallèlement, la densité de risque moyenne atteint 5,71/10, témoignant d'une documentation généralisée des défaillances potentielles.

La médiane du VCBI s'établit à 0,173 (IQR = [0,113; 0,214]), mais cette valeur centrale masque une dispersion considérable : les scores

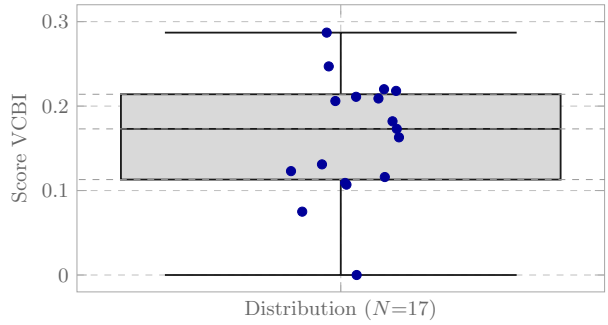


Figure 1: Distribution du VCBI pour les 17 systèmes d'accessibilité IA (2019–2025). La boîte à moustaches indique la médiane et l'intervalle interquartile ; les points correspondent aux scores individuels.

s'étendent de 0,000 (Multimodal DNN Summarizer [21], agentivité = 1) à 0,287 (TableView+ [26], architecture hybride). La Figure 1 synthétise cette distribution, en faisant apparaître à la fois médiane, intervales interquartiles et scores individuels. La majorité des systèmes (n=13, 76,5%) se situe dans un intervalle d'un écart-type autour de la moyenne (0,094–0,232), ce qui reflète une certaine homogénéité des pratiques actuelles. Deux systèmes (11,8 %) affichent des scores inférieurs à 0,08, révélant des échecs fondamentaux d'équilibre. Leurs causes sont cependant de nature radicalement différente, comme nous le détaillons dans l'analyse contrastive (cf. Section 4.3.1) : l'un souffre d'un déficit d'agentivité malgré une validation correcte, l'autre d'une validation insuffisante malgré une agentivité satisfaisante. À l'autre extrémité, sept systèmes (41,2%) dépassent VCBI = 0,20 : TableView+ (0,287), NoVAGraphs Dialogue System [4] (0,247), AltCanvas (0,220), VizAbility (0,218), KASI (0,211), LectureAssistant (0,209) et Edukoi (0,206). Bien que la formule du VCBI admette un maximum théorique de 1,0, le score le plus élevé observé dans notre corpus n'atteint que 0,287. Cet écart considérable suggère que les pratiques actuelles de conception et d'évaluation des systèmes d'accessibilité fondés sur l'IA sont encore loin de réunir les conditions d'un équilibre vérification-cognition optimal. Autrement dit, il existe des obstacles structurels qui limitent aujourd'hui la capacité des systèmes à offrir simultanément une validation rigoureuse, une agentivité élevée et une maîtrise des risques documentés.

Signalons un résultat transversal important : plus un système repose sur une IA sophistiquée (modèles génératifs, architectures transformeurs), plus il tend à documenter un profil de risque élevé. Ce couplage capacité-risque impose un plafond structurel à la vérifiabilité : au-delà d'un certain seuil de sophistication générative, chaque gain de capacité s'accompagne de modes de défaillance plus difficiles à détecter en l'absence d'accès perceptuel direct.

4.1.1 Profils empiriques issus du clustering hiérarchique. Une analyse de classification hiérarchique (méthode de Ward) des composantes normalisées du VCBI (V, A, C, R) suggère une partition en quatre groupes (pseudo-F=4,2), expliquant 68% de la variance totale. Compte tenu de la taille de l'échantillon au regard de l'espace à quatre dimensions, ces groupes sont considérés comme des archétypes exploratoires. Le Tableau 3 synthétise les quatre profils empiriques obtenus.

Les sept systèmes à vision classique se répartissent entre les clusters 1 (trois systèmes), 2 (trois systèmes) et 3 (un système). Les huit systèmes transformeurs présentent une variance plus marquée : six appartiennent au cluster 1, un au cluster 2 et un au cluster 3. Les deux systèmes hybrides se situent dans les clusters les plus performants (KASI en cluster 1, TableView+ en cluster 4). Ce résultat, qui repose sur seulement deux systèmes, est cohérent avec l'hypothèse que les architectures spécialisées favorisent de meilleures affordances de vérification.

Le paradigme architectural explique R^2=0,178 de la variance du VCBI, contre seulement $R^2 \approx$0,07 pour l'année de publication. Toutefois, la différence de VCBI entre systèmes à vision classique et à base de transformeurs n'est pas significative (U=24,0, p=0,643, d=0,31). Le R^2 provient quasi exclusivement des deux systèmes hybrides, dont le poids statistique est disproportionné en raison du faible effectif (n=2). C'est donc le profil de risque, et non l'équilibre vérification-cognition global, qui constitue le principal différenciateur entre paradigmes majoritaires.

4.1.2 Relations entre composantes indépendantes. Les corrélations de Spearman entre les composantes indépendantes, après correction de Benjamini–Hochberg (m=6), mettent en évidence deux associations significatives. L'agentivité et la topologie présentent une association positive forte (ρ=0,669, p_{adj}=0,0018) : les systèmes plus complexes tendent à offrir un contrôle utilisateur accru, à condition d'être intentionnellement conçus dans ce but. L'agentivité et le risque présentent une corrélation positive modérée (ρ=0,503, p_{adj}=0,0144) : les systèmes dotés d'une plus forte agentivité documentent davantage leurs modes de défaillance. Les quatre autres paires ne montrent pas d'association significative après correction : la rigueur de validation opère de manière largement indépendante des autres dimensions, confirmant que le VCBI capture des facettes distinctes de l'équilibre vérification-cognition. Cette indépendance a une implication directe pour la conception : la qualité méthodologique ne saurait être considérée comme une conséquence naturelle des choix architecturaux ; elle doit faire l'objet d'une attention intentionnelle et explicite.

4.2 QR2 : L'architecture comme déterminant des affordances de vérification

Pour examiner l'influence du paradigme architectural sur l'équilibre vérification-cognition, nous comparons les trois groupes identifiés dans le corpus. Le Tableau 4 présente les scores moyens du VCBI.

Couplage capacité-risque sans amélioration de la validation. Les systèmes fondés sur des transformeurs présentent une densité de risque supérieure de 80% à celle des systèmes de vision classique (7,64 contre 4,24 ; d=2,43, effet très large), avec des préoccupations d'hallucination rapportées dans 7 des 8 systèmes transformeurs contre 1 seul parmi les systèmes de vision classique. Pourtant, ce bond de capacité ne s'accompagne d'aucune amélioration de la validation : les systèmes de vision classique maintiennent une rigueur marginalement supérieure (5,81 vs 5,05, d=0,52), et l'écart VCBI global reste négligeable et non significatif (0,162 vs 0,141, p=0,643).

Table 3: Profils empiriques de conception issus du clustering hiérarchique (Méthode de Ward, N=17)

Cluster (%)	n	Systèmes et caractéristiques
Cluster 1 : Courant dominant (58,8%)	10	*KASI, AltCanvas, Edukoi, MAIDR AI, LectureAssistant, NoVAGraphs Dialogue System [4], VizAbility, AlternAtIve, Android Math. App. [1], MIUI [44].* VCBI moyen = 0,194 [0,109–0,247] ; validation équilibrée (5,59) et agentivité élevée (2,90). Ces systèmes représentent les pratiques courantes les plus abouties.
Cluster 2 : Agentivité contrainte (23,5%)	4	*AltGen [39], ChartVi [29], EyeMath, pipeline graphiques.* VCBI moy. = 0,119 [0,107–0,130] ; faible agentivité (2,00) malgré une validation modérée (5,47) ; densité de risque (5,40) sans mécanisme compensatoire. Trois systèmes sur quatre utilisent des architectures de vision classique, signalant des pratiques héritées privilégiant l'automatisation sur l'autonomisation.
Cluster 3 : Déséquilibre critique (11,8%)	2	*Multimodal DNN Summarizer [21], TableNarrator.* VCBI moy. = 0,037 [0,000–0,075] ; modes de défaillance orthogonaux : déficit d'agentivité (VCBI = 0,000, agentivité = 1) d'un côté, insuffisance de validation (VCBI = 0,075, VR = 2,0) de l'autre.
Cluster 4 : Haute performance (5,9%)	1	*TableView+.* VCBI = 0,287 ; excellence en validation (8,0), agentivité modérée (3,0), complexité contrôlée (2,4). Seul système atteignant l'équilibre fort.

Table 4: Équilibre vérification-cognition par paradigme architectural

Métrique	Vision cl. (n=7)	Transformeur (n=8)	Hybride (n=2)
Affordances de vérification			
VCBI (moy.)	0,14	0,16[a]	**0,25**
VCBI [min–max]	[0,00; 0,25]	[0,08; 0,22]	[0,21; 0,29]
Validation rigueur (moy.)	5,81	5,05	6,55
Agentivité (moy.)	2,14	2,88	3,00
Niveau 4 atteint	0/7	0/8	0/2
Profil de risque			
Densité risque (moy.)	4,24	7,64[b]	3,15
Densité risque [min–max]	[1,80; 5,50]	[4,60; 10,0]	[2,30; 4,00]
Hallucination documentée	1/7 (14,3%)	7/8 (87,5%)	0/2 (0%)
Profil méthodologique			
Complex. topologique (moy.)	1,57	2,04	2,45
Adoption schémas vérification	3/7 (42,9%)	8/8 (100%)	1/2 (50%)

[a] Écart VCBI vs Vision cl. : d=0,31 (petit, non significatif, U=24,0, p=0,643). [b] Écart risque vs Vision cl. : d=2,43 (très large, U=3,0, p=0,004). Tailles d'effet pour Hybride non calculées (n=2, instable).

Les systèmes de vision classique obtiennent un VCBI faible principalement en raison de leur agentivité limitée (moy. 2,14/4), et non de leurs risques : les deux paradigmes échouent différemment.

Progression de l'agentivité qui bute sur un plafond. L'agentivité progresse de façon monotone avec la sophistication architecturale (vision classique : 2,14 → transformeurs : 2,88 → hybrides : 3,00), ce qui représente une amélioration de 40 % entre les extrêmes. Cependant, aucun système n'atteint le Niveau 4, y compris parmi les transformeurs où les interfaces conversationnelles pourraient théoriquement offrir une interrogation sans restriction. La différence d'agentivité entre ces deux groupes est marginalement significative ($p \approx 0{,}05$) mais doit être interprétée avec prudence étant donné la petite taille des échantillons. Certains systèmes (MAIDR AI, VizAbility) implémentent une interaction par requêtes (Niveau 3) mais n'exposent pas d'estimations de confiance, de traces de raisonnement ni d'accès aux données brutes, capacités que leurs architectures pourraient aisément supporter. Ce plafond relève d'un choix de conception délibéré : les systèmes privilégient l'efficacité de la tâche sur l'examen critique.

Les hybrides spécialisés, cas d'implémentation prometteurs. Les deux systèmes hybrides affichent le meilleur équilibre observé (VCBI moy. = 0,249), la densité de risque la plus faible (3,15) et zéro hallucination documentée. Ces systèmes partagent deux propriétés : (1) l'IA y est cantonnée à des sous-tâches sémantiques étroites (reconnaissance de pièces tactiles pour KASI, extraction sémantique de tableaux pour TableView+), ce qui réduit l'espace d'erreur et rend les défaillances généralement détectables ; (2) leur évaluation est exceptionnellement rigoureuse (scores MMAT ≥ 85, $n_{\text{utilisateurs aveugles et malvoyants}} \geq 10$, protocoles à méthodes mixtes). Ces systèmes partagent également des caractéristiques confondues, notamment des domaines bien délimités et une publication en 2022–2023, avant la généralisation des LLM, rendant délicate l'attribution de l'avantage observé à l'architecture seule. Ils constituent des cas de référence pour l'excellence de l'implémentation plutôt qu'une confirmation statistique de la supériorité du paradigme hybride. La Figure 2 synthétise visuellement ces tendances en présentant les scores normalisés des quatre dimensions constitutives du VCBI.

4.3 QR3 : Schémas de conception pour une vérifiabilité accrue

4.3.1 Analyse contrastive : systèmes à VCBI élevé vs. faible. Deux cas extrêmes illustrent la propriété fondamentale du cadre VCBI. Multimodal DNN Summarizer [21] (VCBI = 0,000) bénéficie d'une validation raisonnable (VR = 6,4) mais son agentivité est réduite au niveau minimal (1,0/4, consommation passive), ce qui annule entièrement le numérateur multiplicatif du VCBI. L'absence de tout mécanisme d'interaction réduit à zéro le numérateur multiplicatif de la formule : une IA potentiellement fiable peut ainsi demeurer épistémiquement inerte. TableNarrator (VCBI = 0,075) présente le profil inverse : une agentivité substantielle (3,0/4) s'exerce sur des contenus dont la fiabilité est insuffisante (VR = 2,0), conférant à l'utilisateur un contrôle sur le processus sans garantie sur le contenu. Ces deux exemples confirment que la vérifiabilité ne se réduit ni à la fiabilité intrinsèque du système, ni à l'agentivité offerte à l'utilisateur, mais résulte de leur conjonction. Un déficit dans l'une

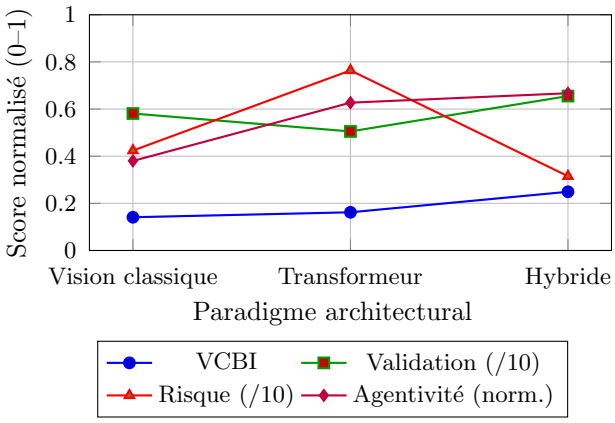


Figure 2: Équilibre vérification-cognition par paradigme architectural. Toutes les métriques sont normalisées entre 0 et 1 (VCBI est intrinsèquement dans cet intervalle ; Validation et Risque sont divisés par 10 ; Agentivité est transformée par (valeur − 1)/3).

ou l'autre dimension suffit à compromettre la sécurité épistémique. À l'opposé, TableView+ (VCBI = 0,287) atteint l'équilibre le plus robuste par une compensation délibérée. Il associe une rigueur de validation élevée (8,0/10), fruit d'une évaluation rigoureuse par méthodes mixtes, à une architecture en pipeline qui circonscrit les erreurs de l'IA, le tout complété par des affordances d'interaction personnalisables mais encadrées.

4.3.2 Trois schémas de conception pour la vérifiabilité. L'examen des systèmes du corpus, en particulier ceux qui se distinguent par un VCBI élevé, fait émerger trois schémas de conception récurrents qui soutiennent concrètement la vérifiabilité des interprétations produites par l'IA.

Schéma 1 : Transparence de provenance. La transparence de provenance, notion issue des travaux de Russell et al. [34] sur la boucle de *sensemaking*, désigne la capacité d'un utilisateur à remonter d'une interprétation produite par l'IA jusqu'à sa source. Un seul système du corpus (5,9%) a mis en œuvre une provenance complète ; 76,5% n'en proposaient aucune forme. Les implémentations efficaces adaptent l'accès à la source à la modalité de l'utilisateur : *navigation hiérarchique* (TableView+ [26]), permettant de passer d'un résumé aux données individuelles via clavier ou gestes ; *sonification* (Chart Pipeline [9]), encodant la valeur numérique dans la hauteur tonale ; *interrogation directe* (MAIDR AI [38], VizAbility [16]), par laquelle une question en langage naturel renvoie une preuve spécifique. Ces approches partagent le principe de *divulgation progressive* [31] : résumé de confiance par défaut, avec des chemins explicites vers les preuves à la demande.

Schéma 2 : Signalement d'incertitude. Aucun système du corpus (0/17) n'expose d'estimation de confiance à l'utilisateur, alors même que quatre d'entre eux calculent de telles métriques en interne sans les rendre accessibles. Le signalement d'incertitude étend aux modalités non visuelles les travaux sur la communication de la confiance [43], avec une contrainte fondamentale : l'incertitude doit être *passivement perceptible*, sans alourdir le coût d'interaction. Des implémentations non intrusives incluent : la *modulation prosodique* [6] (rythme ralenti, intonation montante pour signaler l'hésitation), les *qualificateurs sémantiques* préposés (« il semble que », « probablement »), et les *earcons différenciés* [7] associant un son distinct à chaque niveau de confiance.

Schéma 3 : Interactions de contestation. Ce schéma opérationnalise le niveau « Collaborer » de Shneiderman [40] pour l'exercice d'un contrôle épistémique, en conférant à l'utilisateur la capacité de questionner, de contester et d'exiger des interprétations alternatives. Deux systèmes seulement (11,8%) ont pleinement mis en œuvre une interrogation ouverte ; 64,7% ne proposaient aucun mécanisme de contestation. Les implémentations observées incluent l'*interrogation ouverte* (MAIDR AI [38], VizAbility [16]) via un dialogue LLM ; et les *alternatives structurées* (ChartVi [29]). Sans contrôles de contestation effectifs, les LLM se révèlent structurellement enclins à produire des descriptions inconsistantes [4], signe que le problème est architectural autant qu'interactionnel.

4.3.3 Adoption des schémas de vérifiabilité selon le paradigme architectural. Nous avons examiné, pour chaque système du corpus, s'il implémentait au moins l'un des trois schémas de conception décrits précédemment (transparence de provenance, signalement d'incertitude, interactions de contestation). L'adoption varie fortement selon le paradigme architectural. Les huit systèmes transformeurs intègrent tous au moins un schéma de vérifiabilité, soit un taux d'adoption de 100 %. À l'inverse, seuls trois des sept systèmes à vision classique (42,9 %) présentent de tels mécanismes, tandis que le groupe hybride affiche une adoption partielle avec un système sur deux concerné (50 %).

L'adoption universelle chez les transformeurs témoigne d'une réelle sensibilisation de la communauté aux risques spécifiques de ces architectures. Cette prise de conscience ne se traduit pourtant pas par une amélioration substantielle de l'équilibre vérification-cognition : l'écart de VCBI avec les systèmes à vision classique reste faible et non significatif ($d = 0{,}31$, $p = 0{,}643$). Dans le même temps, la densité de risque des transformeurs excède de 80 % celle des systèmes de vision classique ($d = 2{,}43$, $p = 0{,}004$). Ce décalage met en évidence une limite importante : les schémas de vérification tels qu'ils sont actuellement implémentés ne suffisent pas à compenser l'explosion des risques inhérente aux modèles génératifs. Ajouter des mécanismes de vérification *a posteriori* ne neutralise donc pas les modes de défaillance intrinsèques d'une architecture générative. Les implications pour la conception sont approfondies dans la Section 5.3.

5 Discussion

5.1 Architecture, risque et validation : trois dynamiques dissociées

L'architecture de l'IA détermine principalement les affordances de vérification disponibles (R^2=0,178 contre R^2≈0,07 pour l'année de publication). Cette influence s'exerce toutefois de manière différenciée sur les trois dimensions du VCBI, et l'examen détaillé des cas révèle des logiques distinctes.

Systèmes à vision classique : agentivité limitée mais risques maîtrisés. Le système Multimodal DNN Summarizer illustre les limites d'une approche centrée sur la seule précision : malgré

une validation méthodologique acceptable, l'absence de mécanisme d'interaction le rend épistémiquement inerte pour l'utilisateur. Le VCBI nul traduit ici non une défaillance technique, mais l'absence d'affordance de vérification. À l'inverse, le NoVAGraphs Dialogue System, bien que fondé sur une architecture à base de règles, atteint l'un des meilleurs équilibres du corpus grâce à une validation d'une rigueur exceptionnelle. Ce contraste montre que la qualité méthodologique, lorsqu'elle est délibérément recherchée, peut compenser certaines limitations architecturales en matière d'agentivité.

Systèmes transformeurs : une progression de l'agentivité neutralisée par l'accroissement des risques. Les systèmes fondés sur les transformeurs présentent une agentivité significativement supérieure à celle des systèmes de vision classique. Cette progression est toutefois contrebalancée par une exposition aux risques nettement plus élevée, sans amélioration concomitante de la rigueur de validation. L'écart de VCBI global reste non significatif. Surtout, la grande majorité de ces systèmes présente des risques d'hallucination sans offrir à l'utilisateur de mécanisme permettant de les détecter. Ces risques sont ainsi appréhendés comme des problèmes de précision algorithmique relevant du seul domaine de l'ingénierie, plutôt que comme des défis de vérification pouvant être pris en charge par la conception de l'interaction. Pour les concepteurs, cela signifie que l'ajout de mécanismes de vérification *a posteriori* à une architecture générative ne suffit pas à neutraliser ses modes de défaillance intrinsèques.

Systèmes hybrides : une piste prometteuse mais à confirmer. Les deux systèmes hybrides du corpus présentent le meilleur équilibre vérification-cognition observé. Ils partagent la caractéristique de cantonner l'IA à des sous-tâches sémantiques étroites, ce qui réduit l'espace d'erreur et rend les défaillances plus facilement détectables. Toutefois, la présence de facteurs confondus (domaines bien délimités, rigueur méthodologique des auteurs, publication antérieure à la généralisation des LLM) interdit d'attribuer cet avantage à la seule architecture. Ces systèmes constituent des cas de référence pour l'excellence de l'implémentation plutôt qu'une preuve statistique de la supériorité du paradigme hybride. Ils montrent néanmoins qu'une spécialisation structurelle de l'IA rend la vérifiabilité plus accessible, en réduisant la dépendance à des palliatifs interactionnels.

5.2 Le déficit d'agentivité : une opportunité sous-exploitée

Mathématiquement, l'agentivité et la rigueur de validation ont un poids symétrique dans la formule du VCBI. Il est dès lors important de constater que l'agentivité reste systématiquement sous-développée : aucun système n'atteint le Niveau 4, et la moyenne de 2,59/4,0 reflète un plafonnement collectif que les pratiques actuelles ne semblent pas chercher à dépasser. Ce plafond relève d'un choix de conception délibéré plutôt que d'une contrainte architecturale : les interfaces conversationnelles des systèmes transformeurs pourraient techniquement soutenir un examen critique sans restriction, mais elles privilégient l'efficacité de la tâche sur le contrôle épistémique de l'utilisateur. L'amélioration de l'agentivité représenterait ainsi une voie d'optimisation accessible pour les équipes de conception, à condition de la cibler explicitement vers la *vérification* plutôt que vers la tâche.

Aucun système n'a atteint le seuil du bonus de résilience du VCBI ($V \geq 0{,}7 \wedge R \geq 0{,}6$) : maintenir une validation élevée *face à* des risques élevés, plutôt qu'en leur absence, reste un objectif que le corpus actuel n'atteint pas.

5.3 Cadre opérationnel : des schémas aux contraintes de conception

Les trois schémas identifiés en QR3 constituent des *objectifs de conception*. Nous les développons ici en cadre prescriptif : anti-patrons à éviter, guide de priorisation, et articulation avec les référentiels réglementaires.

5.3.1 Anti-patrons et pièges d'implémentation. En conception logicielle et en IHM, un *anti-patron* désigne une solution fréquente mais contre-productive à un problème récurrent, contrairement à un patron de conception, qui constitue une bonne pratique. Chacun des trois schémas de conception identifiés précédemment peut être compromis par un anti-patron spécifique, que nous décrivons ci-dessous afin d'en prévenir l'apparition.

Transparence de provenance : le piège de la surcharge informationnelle. L'anti-patron dominant est la *provenance non filtrée* : exposer d'emblée l'intégralité des données sources peut imposer une charge cognitive excessive. La divulgation progressive [31] doit s'organiser en trois niveaux : (1) un résumé de confiance par défaut, (2) l'accès aux données agrégées à la demande, et (3) l'accès aux données brutes en option avancée. Un système qui expose directement les données brutes sans résumé de confiance relève de l'anti-patron *provenance sans médiation* : l'utilisateur dispose de l'information nécessaire à la vérification, mais pas des ressources cognitives pour l'exploiter.

Signalement d'incertitude : le piège de l'interruption active. L'anti-patron est le *signalement par interrogation requise* : obliger l'utilisateur à demander « quel est votre niveau de confiance ? » pour chaque sortie rend la vérification exceptionnelle plutôt que routinière. L'incertitude doit être encodée dans la modalité d'une sortie sans action supplémentaire requise, par exemple par la modulation prosodique [6], les qualificateurs sémantiques préposés et les earcons différenciés [7], qui constituent des implémentations non intrusives et préservent le flux de l'interaction.

Interactions de contestation : le piège de la contestation rhétorique. Un système peut autoriser la contestation, entendue comme la possibilité pour l'utilisateur de remettre en cause une réponse, sans que celle-ci modifie substantiellement le contenu épistémique : l'utilisateur conteste, tandis que le système se borne à reformuler sa réponse. Cette *contestation rhétorique* confère une agentivité d'interface sans agentivité épistémique, conformément à la distinction établie en Section 2.3. Les auteurs du *NoVAGraphs Dialogue System* [4] soulignent que, sans contraintes de conception explicites, les LLM sont structurellement sujets à cette dérive.

5.3.2 Guide de priorisation et articulation normative. Pour guider les concepteurs, une règle simple se résume à la question : *les erreurs produites par le système sont-elles facilement détectables par l'utilisateur en l'absence d'aide extérieure ?* Lorsque les erreurs sont

détectables, par exemple dans les systèmes à base de vision classique produisant des sorties structurées, la priorité va aux *interactions de contestation* et à la *transparence de provenance,* qui permettent à l'utilisateur de confronter l'interprétation de l'IA à ses connaissances ou à d'autres données. À l'inverse, si les erreurs sont *indétectables* (cas des systèmes génératifs sujets aux hallucinations sémantiques), la priorité absolue devient le *signalement d'incertitude*. Rendre l'incertitude passivement perceptible, sans nécessiter d'interrogation explicite, est le préalable à toute contestation utile. L'objectif à long terme reste le Niveau 4 d'agentivité (contrôle épistémique complet), encore inatteint dans le corpus. Ces recommandations s'articulent avec les référentiels réglementaires, dont il convient toutefois de ne pas surinterpréter la portée actuelle. Nous distinguons deux niveaux : d'une part, ce que les référentiels actuels *exigent d'ores et déjà* : les critères *WCAG 2.2* [8] imposent la restitution non visuelle de tout contenu informatif (critère 1.3.1, *Info and Relationships*) et l'opérabilité clavier de toute fonction interactive (critère 2.1.1, *Keyboard*), deux exigences générales qui, appliquées aux systèmes étudiés ici, couvrent de fait le signalement d'incertitude et les interactions de contestation, sans toutefois avoir été formulées spécifiquement pour l'IA. L'*European Accessibility Act* [13] relève du même registre : il impose un cadre général d'accessibilité des produits et services numériques, sans énoncer d'obligation propre à la vérifiabilité des sorties d'IA. Pour le contexte français, le *Référentiel Général d'Amélioration de l'Accessibilité* (RGAA) [11], qui décline WCAG 2.2 en critères de contrôle opérationnels, relève de la même limite : il ne prévoit à ce jour aucun critère spécifique aux indicateurs de confiance ou aux mécanismes de contestation propres aux systèmes d'IA. D'autre part, ce que nous *proposons comme extension* de ces cadres au contexte de l'IA accessible : que les indicateurs de confiance générés par l'IA soient eux-mêmes soumis à l'exigence de restitution non visuelle (par analogie avec le critère 1.3.1), et que les interactions de contestation soient explicitement reconnues comme des fonctions de contrôle devant satisfaire le critère 2.1.1. Cette extension normative constitue une piste de plaidoyer pour de futures révisions de ces référentiels, et non une lecture de leur texte actuel.

5.3.3 De l'adoption partielle à la contrainte architecturale. L'analyse des taux d'adoption présentée en QR3 révèle un paradoxe : les systèmes transformeurs intègrent systématiquement les schémas de vérification (100%) sans pour autant améliorer leur VCBI. Ce constat a une implication directe pour la conception : ajouter des mécanismes de vérification *a posteriori* dans une architecture générative ne compense pas les modes de défaillance intrinsèques à cette architecture. La vérifiabilité doit donc être traitée comme une contrainte de premier ordre dès les premières étapes de conception. Pour les systèmes génératifs, cela implique de restreindre explicitement le périmètre sémantique de l'IA plutôt que de superposer des correctifs. Les deux systèmes hybrides du corpus illustrent cette approche : aucun cas d'hallucination documenté, densité de risque minimale (3,15) et VCBI le plus élevé. Ils constituent ainsi des cas de référence non pas comme preuve de supériorité d'un paradigme architectural, mais comme démonstration qu'une spécialisation structurelle de l'IA rend la vérifiabilité intrinsèquement accessible, plutôt que dépendante de palliatifs interactionnels.

5.4 Vers une évaluation centrée sur la vérifiabilité

Aucun des 17 systèmes du corpus n'évalue la capacité des utilisateurs à détecter les erreurs, tandis que 82,4% rapportent des mesures de précision. Cette asymétrie souligne que l'évaluation reste principalement centrée sur la technologie. Nous proposons trois critères initiaux, offrant des objectifs testables et aisément ajustables.

Détection d'erreur. Ce critère mesure la capacité des utilisateurs à identifier des erreurs injectées sans validation externe. Le protocole consiste à concevoir des stimuli appariés : pour chaque contenu visuel de test, une interprétation correcte et une interprétation erronée d'un type connu (hallucination numérique, attribution incorrecte) ; les deux versions sont présentées en ordre aléatoire, les participants ayant pour consigne de signaler toute erreur suspectée. Au moins trois types d'erreurs et dix stimuli par type sont recommandés, avec un double aveugle sur le statut correct/erroné. La cible de 70% de détection est provisoire, calibrée par analogie avec les travaux sur la détection d'erreur en collaboration humain-IA [5] ; tout type d'erreur atteignant moins de 30% de détection constitue un signal d'échec critique.

Coût de vérification. Ce deuxième critère mesure le nombre minimal d'actions atomiques, telles que le contact tactile, le clic, la commande clavier ou l'énoncé vocal, nécessaires pour accéder à la base évidentielle d'une interprétation IA. Cinq tâches de vérification types sont réalisées par un évaluateur expert en parcours minimal ; nous proposons une médiane cible inférieure à cinq actions, à titre indicatif et sujette à ajustement selon le contexte applicatif. Ce critère est réalisable par inspection experte sans recrutement de participants, le rendant économiquement accessible aux projets à ressources limitées.

Efficacité de la contestation. Ce troisième critère mesure la proportion de contestations suscitant une réponse substantive, c'est-à-dire apportant une information nouvelle ou modifiant effectivement l'interprétation, plutôt que rhétorique. Dix contestations types sont soumises au système et évaluées par deux juges indépendants (κ cible >0,70). La cible de 50% de réponses substantives marque le seuil en deçà duquel le mécanisme est cosmétique : il offre une agentivité d'interface sans agentivité épistémique, au sens de la distinction de la Section 2.3.

5.5 Limites et perspectives

La taille réduite de notre corpus ($N = 17$) limite la puissance statistique des analyses, empêchant de détecter des corrélations $|\rho| \lesssim 0{,}48$ et rendant le clustering hiérarchique sur quatre dimensions susceptible de sur-segmentation. La classification architecturale des systèmes hybrides a nécessité des jugements interprétatifs, validés par consensus mais introduisant une part de subjectivité. Notre métrique d'agentivité confond le contrôle épistémique et le contrôle d'interface, tandis que la concentration géographique du corpus restreint la généralisation des résultats. Enfin, notre cadre mesure la *disponibilité* des affordances de vérification, c'est-à-dire leur présence ou absence dans l'architecture du système, et non leur *coût d'activation effectif* pour l'utilisateur : un schéma techniquement présent peut rester sous-utilisé si la charge cognitive qu'il engendre est trop importante : un second niveau que le VCBI, dans sa forme actuelle, ne capture pas.

Pour consolider nos conclusions, il convient de valider les protocoles sur des systèmes génératifs en conditions réelles, de développer des métriques d'agentivité distinguant contrôle épistémique et contrôle de tâche, et d'élargir le corpus à plus de cinquante systèmes avec une diversité géographique accrue. Des études causales permettraient d'isoler les effets des choix de conception, tandis que des travaux longitudinaux pourraient observer la dynamique temporelle de l'agentivité épistémique.

Deux pistes complémentaires se dégagent de ces constats. La première concerne le *score de consensus inter-IA* : en l'absence de mesures de confiance directement exposées par les systèmes commerciaux, la divergence entre les sorties de plusieurs modèles interrogés sur un même contenu pourrait constituer un signal palliatif d'incertitude, accessible sans modification des systèmes évalués. Cette approche reste cependant limitée par deux facteurs : son coût computationnel, qui croît linéairement avec le nombre de modèles interrogés, et le risque de *convergence trompeuse*, notamment lorsque plusieurs modèles partagent les mêmes biais d'entraînement ou les mêmes données sources : un consensus élevé peut refléter une erreur partagée plutôt qu'une confirmation fiable, amplifiant ainsi l'illusion de fiabilité plutôt que de la dissiper. La seconde piste répond à la limite identifiée ci-dessus : l'évaluation de la charge cognitive effective liée à l'usage des schémas de vérification constitue une direction de recherche à part entière, qui viendrait compléter la disponibilité structurelle mesurée par le VCBI. Le protocole d'efficacité de la contestation (Section 5.4) offre un point d'entrée opérationnel pour cette évaluation : mesurer, au-delà de la simple présence d'un mécanisme de contestation, l'effort perçu par l'utilisateur pour l'activer et en tirer parti.

6 Conclusion

Ce travail met en évidence une tension centrale dans les systèmes d'accessibilité contemporains : à mesure que l'IA gagne en sophistication interprétative, elle réduit la capacité des utilisateurs à vérifier ses résultats. Ce paradoxe découle directement du passage de la simple transcription à l'interprétation. Pour y répondre, nous plaidons pour un changement de perspective évaluative, déplaçant l'attention de la seule précision algorithmique vers la *vérifiabilité* effective des interprétations par les déficients visuels. Le *Verification-Cognition Balance Index* (VCBI) fournit un premier outil quantitatif pour analyser les équilibres et les déséquilibres entre validation scientifique, agentivité épistémique, complexité et exposition au risque. Son application aux 17 systèmes du corpus révèle des profils architecturaux contrastés et un plafond collectif d'agentivité que nul système ne franchit. Ces résultats ne constituent pas une fin en soi, mais invitent à repenser la place de l'utilisateur dans la boucle interprétative.

L'enjeu dépasse les performances techniques : lorsque l'IA devient le médiateur obligé de l'accès à l'information pour des publics privés de redondance perceptuelle, la capacité à douter, questionner et contester devient une condition de l'autonomie cognitive. Concevoir pour la vérifiabilité signifie reconnaître que l'agentivité épistémique des utilisateurs n'est pas une option d'interface, mais une exigence éthique et un socle de confiance dans les systèmes d'IA accessibles.

7 Utilisation de l'IA générative

Des outils d'IA générative (Claude et Gemini) ont été utilisés pour reformuler certains passages du manuscrit afin d'en améliorer la clarté, ainsi que pour identifier et corriger des erreurs dans les scripts d'analyse. Les auteurs ont relu et vérifié toutes les suggestions produites, et restent pleinement responsables du contenu de l'article (idées, analyses, interprétations, méthodes et résultats).

Acknowledgements

Ce travail s'inscrit dans le projet COOBRA (Coopération entre voyants et déficients visuels braillistes pour apprendre et travailler ensemble), financé par l'Agence Nationale de la Recherche (ANR) au titre du programme Science avec et pour la Société – Recherches participatives 2 (SAPS-RA-RP2), sous la référence ANR-24-SARP-0006. Les auteurs remercient le LABEX ASLAN (ANR-10-LABX-0081) de l'Université de Lyon pour son soutien financier dans le cadre du programme français "Investissements d'Avenir" géré par l'Agence Nationale de la Recherche.

References

[1] Rina Agustina, Nurul Farida, and Muhammad Irfan. 2024. Learning Mathematics Outcomes Using Android for Blind Students Based on Newman's Theory. *Journal of Education and Learning (EduLearn)* 18, 3 (2024), 1056–1065. doi:10.11591/edulearn.v18i3.21454

[2] Katharina Anderer, Karin Müller, Lukas Strobel, Matthias Wölfel, Jan Niehues, and Kathrin Gerling. 2025. Making Lecture Videos Accessible for Students who are Blind or have Low Vision through AI-Assisted Navigation and Visual Question Answering. In *Proceedings of the 27th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS '25)*. ACM, New York, NY, USA, 1–15. doi:10.1145/3663547.3746349

[3] Joel Anderson and Axel Honneth. 2005. Autonomy, Vulnerability, Recognition, and Justice. In *Autonomy and the Challenges to Liberalism*, John Christman and Joel Anderson (Eds.). Cambridge University Press, Cambridge, UK, 127–149.

[4] P. F. Balestrucci, E. Di Nuovo, M. Sanguinetti, L. Anselma, C. Bernareggi, and A. Mazzei. 2024. An educational dialogue system for visually impaired people. *IEEE Access* 12 (2024), 150502–150519. doi:10.1109/ACCESS.2024.3479883

[5] Gagan Bansal, Besmira Nushi, Ece Kamar, Walter S. Lasecki, Daniel S. Weld, and Eric Horvitz. 2019. Beyond Accuracy: The Role of Mental Models in Human-AI Team Performance. In *Proceedings of the AAAI Conference on Human Computation and Crowdsourcing*, Vol. 7. AAAI, Palo Alto, California, 2–11. doi:10.1609/hcomp.v7i1.5285

[6] Susan E. Brennan and Maurice Williams. 1995. The Feeling of Another's Knowing: Prosody and Filled Pauses as Cues to Listeners about the Metacognitive States of Speakers. *Journal of Memory and Language* 34, 3 (1995), 383–398.

[7] Stephen A. Brewster, Peter C. Wright, and Alistair D. N. Edwards. 1993. An Evaluation of Earcons for Use in Auditory Human-Computer Interfaces. In *Proceedings of the INTERACT '93 and CHI '93 Conference on Human Factors in Computing Systems*. ACM, New York, NY, USA, 222–227. doi:10.1145/169059.169179

[8] Alastair Campbell, Chuck Adams, Rachael Bradley Montgomery, Michael Cooper, and Andrew Kirkpatrick. 2024. *Web Content Accessibility Guidelines (WCAG) 2.2*. W3C Recommendation. W3C. https://www.w3.org/TR/WCAG22/

[9] J. Choi, S. Jung, D. G. Park, J. Choo, and N. Elmqvist. 2019. Visualizing for the non-visual: enabling the visually impaired to use visualization. *Computer Graphics Forum* 38, 3 (2019), 249–260. doi:10.1111/cgf.13686

[10] Wenliang Dai, Junnan Li, Dongxu Li, Anthony Meng Huat Tiong, Junqi Zhao, Weisheng Wang, Boyang Li, Pascale Fung, and Steven Hoi. 2023. InstructBLIP: towards general-purpose vision-language models with instruction tuning. In *Proceedings of the 37th International Conference on Neural Information Processing Systems* (New Orleans, LA, USA) *(NIPS '23)*. Curran Associates Inc., Red Hook, NY, USA, Article 2142, 18 pages.

[11] Direction interministérielle du numérique (DINUM). 2023. *Référentiel Général d'Amélioration de l'Accessibilité (RGAA) 4*. Technical Report. DINUM, République française. https://accessibilite.numerique.gouv.fr/

[12] K. Dumkasem, P. Srisingchai, and P. Rattanatamrong. 2019. Eyemath: increasing accessibility of mathematics to visually impaired readers. In *2019 23rd International Computer Science and Engineering Conference (ICSEC)*. IEEE, Phuket, Thailand, 197–202. doi:10.1109/ICSEC47112.2019.8974682

[13] European Parliament and Council of the European Union. 2019. *Directive (EU) 2019/882 on the Accessibility Requirements for Products and Services (European Accessibility Act)*. Technical Report 2019/882. European Parliament and Council

of the European Union. https://eur-lex.europa.eu/legal-content/EN/TXT/PDF/?uri=CELEX:32019L0882
[14] Miranda Fricker. 2007. *Epistemic Injustice: Power and the Ethics of Knowing*. Oxford University Press, Oxford. doi:10.1093/acprof:oso/9780198237907.001.0001
[15] Yarin Gal and Zoubin Ghahramani. 2016. Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning. In *Proceedings of The 33rd International Conference on Machine Learning*, Maria Florina Balcan and Kilian Q. Weinberger (Eds.), Vol. 48. PMLR, New York, New York, USA, 1050–1059. https://proceedings.mlr.press/v48/gal16.html
[16] Joshua Gorniak, Yoon Kim, Donglai Wei, and Nam Wook Kim. 2024. VizAbility: Enhancing Chart Accessibility with LLM-Based Conversational Interaction. In *Proceedings of the 37th Annual ACM Symposium on User Interface Software and Technology (UIST '24)*. ACM, New York, NY, USA, 1–19. doi:10.1145/3654777.3676414
[17] Lucrezia Guiotto Nai Fovino, Anita Zanella, Luca Di Mascolo, Michele Ginolfi, Nicolò Carpita, Francesco Trovato Manuncola, and Massimo Grassi. 2024. Evaluating the Effectiveness of Sonification in Science Education Using Edukoi. *Personal and Ubiquitous Computing* 28, 5 (2024), 693–711. doi:10.1007/s00779-024-01809-5
[18] Jonggi Hong and Hernisa Kacorri. 2024. Understanding How Blind Users Handle Object Recognition Errors: Strategies and Challenges. In *Proceedings of the 26th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS '24)*. ACM, New York, NY, USA, 1–15. doi:10.1145/3663548.3675635
[19] Lei Huang, Weijiang Yu, Weitao Ma, Weihong Zhong, Zhangyin Feng, Haotian Wang, Qianglong Chen, Weihua Peng, Xiaocheng Feng, Bing Qin, and Ting Liu. 2025. A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. *ACM Transactions on Information Systems* 43, 2 (2025), 1–55. doi:10.1145/3703155
[20] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Ye Jin Bang, Delong Chen, Wenliang Dai, Ho Shu Chan, Andrea Madotto, and Pascale Fung. 2023. Survey of Hallucination in Natural Language Generation. *Comput. Surveys* 55, 12 (2023), 1–38. doi:10.1145/3571730
[21] E. Kim, C. Onweller, and K. F. Mccoy. 2021. Information graphic summarization using a collection of multimodal deep neural networks. In *Proceedings of the 25th International Conference on Pattern Recognition (ICPR)*. IEEE, Milan, Italy, 10188–10195. doi:10.1109/ICPR48806.2021.9412146
[22] Anne Kleiner and Ray Kurzweil. 1977. A Description of the Kurzweil Reading Machine and a Status Report on Its Testing and Dissemination. *Bulletin of Prosthetics Research* 10, 27 (1977), 72–81.
[23] Vivian Lai, Chacha Chen, Alison Smith-Renner, Q. Vera Liao, and Chenhao Tan. 2023. Towards a Science of Human-AI Decision Making: An Overview of Design Space in Empirical Human-Subject Studies. In *Proceedings of the 2023 ACM Conference on Fairness, Accountability, and Transparency (FAccT '23)*. ACM, New York, NY, USA, 1369–1385. doi:10.1145/3593013.3594087
[24] Jonathan Lazar, Aaron Allen, Jason Kleinman, and Chris Malarkey. 2007. What Frustrates Screen Reader Users on the Web: A Study of 100 Blind Users. *International Journal of Human-Computer Interaction* 22, 3 (2007), 247–269. doi:10.1080/10447310709336964
[25] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. 2015. Deep Learning. *Nature* 521, 7553 (2015), 436–444. doi:10.1038/nature14539
[26] H.-N. Lee and V. Ashok. 2022. Customizable tabular access to web data records for convenient low-vision screen magnifier interaction. *Acm transactions on accessible computing* 15, 2, Article 14 (2022), 22 pages. doi:10.1145/3517044
[27] Seonghee Lee, Maho Kohga, Steve Landau, Sile O'Modhrain, and Hari Subramonyam. 2024. Altcanvas: a tile-based editor for visual content creation with generative ai for blind or visually impaired people. In *The 26th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS '24)*. ACM, New York, NY, USA, 1–22. doi:10.1145/3663548.3675600
[28] Jennifer Mankoff, Gillian R. Hayes, and Devva Kasnitz. 2010. Disability Studies as a Source of Critical Inquiry for the Field of Assistive Technology. In *Proceedings of the 12th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS '10)*. ACM, New York, NY, USA, 3–10. doi:10.1145/1878803.1878807
[29] Prerna Mishra, Santosh Kumar, Mithilesh Kumar Chaube, and Urmila Shrawankar. 2022. ChartVi: Charts Summarizer for Visually Impaired. *Journal of Computer Languages* 69 (2022), 101107. doi:10.1016/j.cola.2022.101107
[30] Ye Mo, Gang Huang, Liangcheng Li, Dazhen Deng, Zhi Yu, Yilun Xu, Kai Ye, Sheng Zhou, and Jiajun Bu. 2025. TableNarrator: Making Image Tables Accessible to Blind and Low Vision People. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. ACM, New York, NY, USA, 1–17. doi:10.1145/3706598.3714329
[31] Don Norman. 2013. *The Design of Everyday Things: Revised and Expanded Edition*. Basic Books, New York, NY, USA.
[32] Chukwunonso Henry Nwokoye, Maria J. P. Peixoto, Akriti Pandey, Lauren Pardy, Mahadeo Sukhai, and Peter R. Lewis. 2026. A Survey of Accessible Explainable Artificial Intelligence Research. *IEEE Transactions on Technology and Society* 7, 1 (2026), 60–69. doi:10.1109/TTS.2025.3636017
[33] G. Pedemonte, M. Leotta, and M. Ribaudo. 2025. Improving web accessibility with an llm-based tool: a preliminary evaluation for stem images. *IEEE Access* 13 (2025), 107566–107582. doi:10.1109/ACCESS.2025.3577519
[34] Daniel M. Russell, Mark J. Stefik, Peter Pirolli, and Stuart K. Card. 1993. The Cost Structure of Sensemaking. In *Proceedings of the INTERACT '93 and CHI '93 Conference on Human Factors in Computing Systems* (Amsterdam, The Netherlands) *(CHI '93)*. Association for Computing Machinery, New York, NY, USA, 269–276. doi:10.1145/169059.169209
[35] Madjid Sadallah and Benoît Encelle. 2026. Systematic Review Protocol: Interactive Digital Technologies for Non-Visual Access to 2D STEM Content by Blind and Low-Vision Individuals. doi:10.5281/zenodo.21137716
[36] Madjid Sadallah and Benoît Encelle. 2026. The Verification Gap in AI Accessibility: A Meta-Analysis of Architectural Paradigms and Agency Deficits. In *Proceedings of the 23rd International Web for All Conference (W4A '26)*. Association for Computing Machinery, New York, NY, USA, 211–221. doi:10.1145/3800424.3800451
[37] William Schiff and Emerson Foulke. 1982. *Tactual Perception: A Sourcebook*. Cambridge University Press, Cambridge.
[38] JooYoung Seo, Sanchita S. Kamath, Aziz Zeidieh, Saairam Venkatesh, and Sean McCurry. 2024. MAIDR Meets AI: Exploring Multimodal LLM-Based Data Visualization Interpretation by and with Blind and Low-Vision Users. In *Proceedings of the 26th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS '24)*. ACM, New York, NY, USA, 1–31. doi:10.1145/3663548.3675660
[39] Yixian Shen, Hang Zhang, Yanxin Shen, Lun Wang, Chuanqi Shi, Shaoshuai Du, and Yiyi Tao. 2025. AltGen: AI-Driven Alt Text Generation for Enhancing EPUB Accessibility. In *Proceedings of the 2025 International Conference on Artificial Intelligence and Computational Intelligence*. ACM, New York, NY, USA, 78–83. doi:10.1145/3730436.3730449
[40] Ben Shneiderman. 2020. Human-Centered Artificial Intelligence: Reliable, Safe & Trustworthy. *International Journal of Human-Computer Interaction* 36, 6 (2020), 495–504. doi:10.1080/10447318.2020.1741118
[41] Andrea C. Tricco, Erin Lillie, Wasifa Zarin, Kelly K. O'Brien, Heather Colquhoun, Danielle Levac, David Moher, Micah D. J. Peters, Tanya Horsley, Laura Weeks, Susanne Hempel, Elie A. Akl, Christine Chang, Jessie McGowan, Lesley Stewart, Lisa Hartling, Adrian Aldcroft, Michael G. Wilson, Chantelle Garritty, Simon Lewin, Christina M. Godfrey, Marilyn T. Macdonald, Etienne V. Langlois, Karla Soares-Weiser, Jo Moriarty, Tammy Clifford, Özge Tunçalp, and Sharon E. Straus. 2018. PRISMA Extension for Scoping Reviews (PRISMA-ScR): Checklist and Explanation. *Annals of Internal Medicine* 169, 7 (2018), 467–473. doi:10.7326/M18-0850
[42] S. E. Wegwerth, G. J. Manchester, and J. E. Winter. 2023. A feasibility study of the kasi learning system to support independent use of stem diagrams by students with visual impairments. *Journal of visual impairment & blindness* 117, 2 (2023), 162–174. doi:10.1177/0145482X231169713
[43] Yunfeng Zhang, Q. Vera Liao, and Rachel K. E. Bellamy. 2020. Effect of Confidence and Explanation on Accuracy and Trust Calibration in AI-Assisted Decision Making. In *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*. ACM, Barcelona, Spain, 295–305. doi:10.1145/3351095.3372852
[44] Yue Zhao. 2025. MIUI: Make Interaction Usable on Information Visualization for People with Visual Impairments. In *2025 28th International Conference on Computer Supported Cooperative Work in Design (CSCWD)*. IEEE, Compiegne, France, 104–109. doi:10.1109/cscwd64889.2025.11033608

A Justifications des scores par système

Le Tableau 5 présente, pour chacun des 17 systèmes du corpus, les scores codés sur les quatre dimensions primaires (rigueur de validation VR, agentivité Ag., complexité topologique Topo., densité de risque RD), le VCBI calculé selon la formule de la Section 3.2.3, ainsi qu'une justification synthétique de chaque score.

Table 5: Scores par système, VCBI et justifications de codage (N=17).

Système	Arch.	VR (0–10)	Ag. (1–4)	Topo. (1–4)	RD (0–10)	VCBI (0–1)	Justification synthétique
KASI [42]	Hyb.	5,1	3	2,5	2,3	0,211	Méthodes mixtes solides (n=10) mais report inférentiel partiel ; interrogation multimodale (N3) sans confiance exposée ; risque contenu par le domaine STEM restreint.
AltCanvas [27]	Trans.	6,5	3	2,0	7,0	0,220	Étude intra-sujets sans grille formelle ; vues alternatives structurées et clarification (N3) ; coordonnées spatiales perdues en sortie non visuelle.
AltGen [39]	Trans.	5,8	2	1,0	8,0	0,116	Étude inter-sujets purement descriptive ; navigation sans interrogation (N2) ; pipeline CLIP/ViT/GPT multi-étapes propice à l'hallucination.
NoVAGraphs Dialogue System [4]	Cl.CV	7,7	3	3,0	5,5	0,247	VR la plus élevée du corpus (MMAT, inférentiel complet) ; dialogue à états finis à base de règles ; le risque reflète les comparateurs LLM externes, non le système déployé.
ChartVi [29]	Cl.CV	6,1	2	1,7	4,9	0,131	Évaluation par tâches à rapport inférentiel partiel ; navigation clavier sans contestation (N2) ; erreurs de classification de barres/légendes chevauchantes.
TableView+ [26]	Hyb.	8,0	3	2,4	4,0	0,287	Intra-sujets, n=25, MMAT=90, statistiques complètes ; exploration hiérarchique et requêtes sémantiques (N3) ; meilleur VCBI du corpus.
Edukoi [17]	Cl.CV	4,7	3	1,0	4,8	0,206	Étude contrôlée sans grille formelle ; navigation gestuelle sur couche sémantique déterministe (N3) ; échecs de suivi de main sous éclairage variable.
EyeMath [12]	Cl.CV	5,1	2	2,3	4,5	0,107	Effectif UAM réduit, statistiques partielles ; navigation clavier pas à pas sans interrogation (N2) ; faible couverture des opérateurs mathématiques.
AlternAtIve [33]	Trans.	3,1	3	1,6	10,0	0,109	Étude pilote, VR la plus basse des transformeurs ; génération d'alternatives contestables par LLM (N3) ; risque maximal d'hallucination.
Multimodal DNN Summarizer [21]	Cl.CV	6,4	1	1,0	4,0	0,000	Étude contrôlée solide, mais sortie unique et fixe (N1, A=0) ; le numérateur du VCBI s'annule structurellement malgré VR= 6, 4.
Android Math. App. [1]	Cl.CV	5,8	2	1,0	1,8	0,173	Évaluation pilote ; aucun composant ML propre (TalkBack + parcours syntaxique à règles) ; risque minimal grâce à un périmètre étroit.
MAIDR AI [38]	Trans.	6,0	3	3,0	8,3	0,182	Étude utilisateur à rapport inférentiel partiel ; requêtes ouvertes au LLM avec contestation (N3) ; hallucinations fréquentes dans les tendances statistiques rapportées.
LectureAssistant [2]	Trans.	6,4	3	2,0	8,0	0,209	Étude utilisateur, reproductibilité partielle via le pipeline RAG ; navigation par sections et dialogue de suivi (N3) ; fragilité hors du domaine STEM.
MIUI [44]	Trans.	4,2	3	2,3	4,6	0,163	Effectif UAM limité, pas de statistiques inférentielles ; navigation en langage naturel multi-mode (N3) ; hallucinations fréquentes d'étiquettes d'interface.
TableNarrator [30]	Trans.	2,0	3	2,4	8,3	0,075	VR la plus basse du corpus (protocole peu spécifié, pas de grille) ; exploration interactive multi-tours (N3) ; dérive sémantique au fil des tours.
Chart Pipeline [9]	Cl.CV	4,9	2	1,0	4,2	0,123	Rapport inférentiel partiel ; restitution sonifiée passive sans interrogation (N2) ; échecs de segmentation sur graphiques à faible contraste.
VizAbility [16]	Trans.	6,4	3	2,0	6,9	0,218	Étude utilisateur à rapport inférentiel partiel ; requêtes de suivi au LLM sans accès aux données (N3) ; hallucinations de récits statistiques.
Moyenne (ET)		5,54 (1,51)	2,59 (0,62)	1,89 (0,70)	5,71 (2,30)	0,163 (0,071)	

Arch. : Cl.CV = vision classique/à base de règles ; Trans. = à base de transformeurs ; Hyb. = hybride spécialisé. **Colonnes :** VR = rigueur de validation (0–10) ; Ag. = agentivité utilisateur (1–4) ; Topo. = complexité topologique (1–4) ; RD = densité de risque (0–10) ; VCBI calculé via la formule de la Section 3.2.3, arrondi à trois décimales.